

# Đoán định cấu trúc protein với độ chính xác cao bằng AlphaFold

|                                                                                                                                              |                                                                                                                                                                                                                                                                                                                                                                                                                                         |
|----------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b><a href="https://doi.org/10.1038/s41586-021-03819-2">https://doi.org/10.1038/s41586-021-03819-2</a></b><br>Ngày nhận: 11 tháng 5 năm 2021 | <b>John Jumper<sup>1,4</sup> ✉, Richard Evans<sup>1,4</sup>, Alexander Pritzel<sup>1,4</sup>, Tim Green<sup>1,4</sup>, Michael Figurnov<sup>1,4</sup>, Olaf Ronneberger<sup>1,4</sup>, Kathryn Tunyasuvunakool<sup>1,4</sup>, Russ Bates<sup>1,4</sup>, Augustin Žídek<sup>1,4</sup>, Anna Potapenko<sup>1,4</sup>, Alex Bridgland<sup>1,4</sup>, Clemens Meyer<sup>1,4</sup>, Simon A. A. Kohl<sup>1,4</sup>,</b>                      |
| Ngày chấp nhận: 12 tháng 7 năm 2021<br>Xuất bản trực tuyến: 15 tháng 7 năm 2021                                                              | <b>Andrew J. Ballard<sup>1,4</sup>, Andrew Cowie<sup>1,4</sup>, Bernardino Romera-Paredes<sup>1,4</sup>, Stanislav Nikolov<sup>1,4</sup>, Rishub Jain<sup>1,4</sup>, Jonas Adler<sup>1</sup>, Trevor Back<sup>1</sup>, Stig Petersen<sup>1</sup>, David Reiman<sup>1</sup>, Ellen Clancy<sup>1</sup>, Michal Zielinski<sup>1</sup>, Martin Steinegger<sup>2,3</sup>, Michalina Pacholska<sup>1</sup>, Tamas Berghammer<sup>1</sup>,</b> |
| Truy cập mở                                                                                                                                  | <b>Sebastian Bodenstein<sup>1</sup>, David Silver<sup>1</sup>, Oriol Vinyals<sup>1</sup>, Andrew W. Senior<sup>1</sup>, Koray Kavukcuoglu<sup>1</sup>,</b>                                                                                                                                                                                                                                                                              |
| Kiểm tra cập nhật                                                                                                                            | <b>Pushmeet Kohli<sup>1</sup> &amp; Demis Hassabis<sup>1,4</sup> ✉</b>                                                                                                                                                                                                                                                                                                                                                                  |

Protein rất cần thiết cho sự sống, và việc hiểu cấu trúc của chúng có thể tạo điều kiện cho sự hiểu biết cơ chế về chức năng của chúng. Thông qua nỗ lực thực nghiệm khổng lồ<sup>1–4</sup>, cấu trúc của khoảng 100.000 protein độc đáo đã được xác định<sup>5</sup>, nhưng con số này chỉ chiếm một phần nhỏ trong hàng tỷ chuỗi protein đã biết<sup>6,7</sup>. Phạm vi bao phủ cấu trúc bị hạn chế bởi hàng tháng đến hàng năm nỗ lực tỉ mỉ cần thiết để xác định một cấu trúc protein duy nhất. Các phương pháp tính toán chính xác là cần thiết để giải quyết khoảng cách này và cho phép tin sinh học cấu trúc quy mô lớn. Dự đoán cấu trúc ba chiều mà một protein sẽ hình thành chỉ dựa trên trình tự axit amin của nó—thành phần đoán định cấu trúc của 'bài toán gấp protein'<sup>8</sup>—đã là một vấn đề nghiên cứu mở quan trọng trong hơn 50 năm qua<sup>9</sup>. Mặc dù có những tiến bộ gần đây<sup>10–14</sup>, các phương pháp hiện có vẫn còn kém xa độ chính xác ở cấp độ nguyên tử, đặc biệt khi không có cấu trúc tương đồng nào có sẵn. Tại đây, chúng tôi cung cấp phương pháp tính toán đầu tiên có thể thường xuyên đoán định cấu trúc protein với độ chính xác ở cấp độ nguyên tử ngay cả trong những trường hợp không có cấu trúc tương tự nào được biết đến. Chúng tôi đã xác thực một phiên bản được thiết kế lại hoàn toàn của mô hình dựa trên mạng nơ-ron của chúng tôi, AlphaFold, trong Đánh giá phê duyệt về dự đoán cấu trúc protein (CASP14) lần thứ 14 đầy thách thức<sup>15</sup>, cho thấy độ chính xác cạnh tranh với các cấu trúc thực nghiệm trong phần lớn các trường hợp và vượt trội hơn hẳn các phương pháp khác. Nền tảng của phiên bản AlphaFold mới nhất là một phương pháp học máy mới lạ kết hợp kiến thức vật lý và sinh học về cấu trúc protein, tận dụng đối sánh đa chuỗi, vào thiết kế của thuật toán học sâu.

Sự phát triển của các phương pháp tính toán để dự đoán cấu trúc protein ba chiều (3D) từ trình tự protein đã tiến triển theo hai con đường bổ sung, tập trung vào tương tác vật lý hoặc lịch sử tiến hóa. Chương trình tương tác vật lý tích hợp sâu sắc sự hiểu biết của chúng ta về các lực đẩy phân tử vào mô phỏng nhiệt động học hoặc động học của vật lý protein<sup>16</sup> hoặc các xấp xỉ thống kê của chúng<sup>17</sup>. Mặc dù về mặt lý thuyết rất hấp dẫn, phương pháp này đã chứng tỏ là cực kỳ thách thức ngay cả đối với các protein có kích thước vừa phải do tính không thể giải quyết bằng tính toán của mô phỏng phân tử, sự phụ thuộc vào ngưỡng của độ ổn định protein và khó khăn trong việc tạo ra các mô hình vật lý protein đủ chính xác. Chương trình tiến hóa đã cung cấp một giải pháp thay thế trong những năm gần đây, trong đó các ràng buộc về cấu trúc protein được suy ra từ phân tích tin sinh học về lịch sử tiến hóa của protein, sự tương đồng với các cấu trúc đã được giải quyết<sup>18,19</sup> và các tương quan tiến hóa cặp đôi<sup>20–24</sup>. Phương pháp tin sinh học

này đã được hưởng lợi rất nhiều từ

sự tăng trưởng ổn định của các cấu trúc protein thực nghiệm được lưu trữ trong Protein Data Bank (PDB)<sup>5</sup>, sự bùng nổ của giải trình tự gen và sự phát triển nhanh chóng của các kỹ thuật học sâu để diễn giải các tương quan này. Mặc dù có những tiến bộ này, các phương pháp dựa trên vật lý và lịch sử tiến hóa đương đại vẫn tạo ra các dự đoán còn kém xa độ chính xác thực nghiệm trong phần lớn các trường hợp mà một chất tương đồng gần chưa được giải quyết bằng thực nghiệm và điều này đã hạn chế tính hữu ích của chúng cho nhiều ứng dụng sinh học.


Trong nghiên cứu này, chúng tôi phát triển phương pháp tính toán đầu tiên, theo hiểu biết của chúng tôi, có khả năng dự đoán cấu trúc protein với độ chính xác gần như thực nghiệm trong phần lớn các trường hợp. Mạng nơ-ron AlphaFold mà chúng tôi phát triển đã được đưa vào đánh giá CASP14 (tháng 5–tháng 7 năm 2020; được đăng ký dưới tên nhóm ‘AlphaFold2’ và là một mô hình hoàn toàn khác so với hệ thống AlphaFold CASP13 của chúng tôi<sup>10</sup>). Đánh giá CASP được thực hiện hai năm một lần bằng cách sử dụng các cấu trúc mới được giải quyết chưa được lưu trữ trong PDB hoặc công bố công khai, do đó đây là một thử nghiệm mù

1DeepMind, London, UK. 2School of Biological Sciences, Seoul National University, Seoul, South Korea. 3Artificial Intelligence Institute, Seoul National University, Seoul, South Korea. 4Những tác giả này đóng góp ngang nhau: John Jumper, Richard Evans, Alexander Pritzel, Tim Green, Michael Figurnov, Olaf Ronneberger, Kathryn Tunyasuvunakool, Russ Bates, Augustin Židek, Anna Potapenko, Alex Bridgland, Clemens Meyer, Simon A. A. Kohl, Andrew J. Ballard, Andrew Cowie, Bernardino Romera-Paredes, Stanislav Nikolov, Rishub Jain, Demis Hassabis. ✉ e-mail: jumper@deepmind.com; dhcontact@deepmind.com

Nature | Tập 596 | 26 tháng 8 năm 2021 | **583**

## Article

Bài báo



a b c d

|                                                                                            |  |
|--------------------------------------------------------------------------------------------|--|
| N terminus                                                                                 |  |
| 4                                                                                          |  |
| C terminus                                                                                 |  |
| 3                                                                                          |  |
| 2                                                                                          |  |
| 1                                                                                          |  |
| 0 AlphaFold Experiment AlphaFold Experiment AlphaFold Experiment                           |  |
| r.m.s.d.95 = 0.8 Å; TM-score = 0.93 r.m.s.d. = 0.59 Å within 8 Å of Zn r.m.s.d.95 = 2.2 Å; |  |
| TM-score = 0.96                                                                            |  |
| e                                                                                          |  |
| Độ tin cậy cao                                                                             |  |
| MSA Single repr. ( r , c )                                                                 |  |
| Genetic + representation Độ tin cậy thấp                                                   |  |
| database ( s , r , c )                                                                     |  |
| search                                                                                     |  |
| MSA                                                                                        |  |
| Structure                                                                                  |  |
| Evoformer                                                                                  |  |
| module                                                                                     |  |
| (48 blocks)                                                                                |  |
| Input sequence (8 blocks)                                                                  |  |
| Pairing                                                                                    |  |
| Pair Pair 3D structure                                                                     |  |
| + representation representation                                                            |  |
| ( r , r , c ) ( r , r , c )                                                                |  |
| Structure                                                                                  |  |
| database                                                                                   |  |
| search                                                                                     |  |
| Templates                                                                                  |  |
| ← Recycling (three times)                                                                  |  |
| (Å)Median C r.m.s.d.α95                                                                    |  |
| G427 AlphaFold G009 G473 G129 G403 G032 G420 G480 G498 G488 G368 G324 G362                 |  |
| G253 G216                                                                                  |  |

**Hình 1 | AlphaFold tạo ra các cấu trúc có độ chính xác cao. a** , Hiệu suất của AlphaFold trên tập dữ liệu CASP14 (  $n = 87$  miền protein) so với 15 mục hàng đầu (trong số 146 mục), số nhóm tương ứng với các số được CASP gán cho những người tham gia. Dữ liệu là giá trị trung vị và khoảng tin cậy 95% của giá trị trung vị, được ước tính từ 10.000 mẫu bootstrap. **b** , Dự đoán của chúng tôi về mục tiêu CASP14 T1049 (PDB 6Y4F, màu xanh lam) so với cấu trúc thực (thực nghiệm) (màu xanh lá cây). Bốn gốc

trong đầu C của cấu trúc tinh thể là các giá trị ngoại lai *B*-factor và không được mô tả. **c** , Mục tiêu CASP14 T1056 (PDB 6YJ1).

Một ví dụ về vị trí liên kết kẽm được dự đoán tốt (AlphaFold có các chuỗi bên chính xác mặc dù nó không dự đoán rõ ràng ion kẽm). **d** , Mục tiêu CASP T1044 (PDB 6VR4)—một chuỗi đơn 2.180 gốc—được dự đoán với sự đóng gói miền chính xác (dự đoán được thực hiện sau CASP bằng AlphaFold mà không cần can thiệp). **e** , Kiến trúc mô hình. Các mũi tên cho thấy luồng thông tin giữa các thành phần khác nhau được mô tả trong bài báo này. Các hình dạng mảng được hiển thị trong ngoặc đơn với *s* , số lượng chuỗi ( *N* seq trong văn bản chính); *r* , số lượng gốc ( *N* res trong văn bản chính); *c* , số kênh.

cho các phương pháp tham gia, và từ lâu đã đóng vai trò là đánh giá tiêu chuẩn vàng cho độ chính xác của đoán định cấu trúc<sup>25,26</sup>.

Trong CASP14, các cấu trúc của AlphaFold chính xác hơn rất nhiều so với các phương pháp cạnh tranh. Các cấu trúc của AlphaFold có độ chính xác xương sống trung vị là 0,96 Å r.m.s.d.95 (độ lệch bình phương trung bình gốc Cα ở độ bao phủ 95% gốc) (khoảng tin cậy 95% = 0,85–1,16 Å) trong khi phương pháp hoạt động tốt nhất tiếp theo có độ chính xác xương sống trung vị là 2,8 Å r.m.s.d.95 (khoảng tin cậy 95% = 2,7–4,0 Å) (được đo trên các miền CASP; xem Hình 1a để biết độ chính xác xương sống và Hình bổ sung 14 để biết độ chính xác toàn nguyên tử). Để so sánh về độ chính xác này, chiều rộng của một nguyên tử carbon xấp xỉ 1,4 Å. Ngoài các cấu trúc miền rất chính xác (Hình 1b), AlphaFold còn có khả năng tạo ra các chuỗi bên có độ chính xác cao (Hình 1c) khi xương sống có độ chính xác cao và cải thiện đáng kể so với các phương pháp dựa trên khuôn mẫu ngay cả khi có sẵn các khuôn mẫu mạnh. Độ chính xác toàn nguyên tử của AlphaFold là 1,5 Å r.m.s.d.95 (khoảng tin cậy 95% = 1,2–1,6 Å) so với 3,5 Å r.m.s.d.95 (khoảng tin cậy 95% = 3,1–4,2 Å) của phương pháp thay thế tốt nhất. Các phương pháp của chúng tôi có thể mở rộng cho các protein rất dài với các miền và sự đóng gói miền chính xác (xem Hình 1d để biết dự đoán một protein 2.180 gốc không có chất tương đồng cấu trúc). Cuối cùng, mô hình có khả năng cung cấp các ước tính chính xác, trên từng gốc về độ tin cậy của nó, điều này sẽ cho phép sử dụng các dự đoán này một cách tự tin.


Chúng tôi chứng minh trong Hình 2a rằng độ chính xác cao mà AlphaFold đã thể hiện trong CASP14 mở rộng sang một mẫu lớn các cấu trúc PDB mới được phát hành; trong tập dữ liệu này, tất cả các cấu trúc đã được lưu trữ trong PDB sau thời điểm cắt dữ liệu huấn luyện của chúng tôi và được phân tích dưới dạng chuỗi đầy đủ (xem Phương pháp, Hình bổ sung 15 và Bảng bổ sung 6 để biết thêm chi tiết). Hơn nữa, chúng tôi quan sát thấy độ chính xác chuỗi bên cao khi dự đoán xương sống chính xác (Hình 2b) và chúng tôi chỉ ra rằng thước đo độ tin cậy của chúng tôi, kiểm tra khác biệt khoảng cách cục bộ dự đoán (pLDDT), dự đoán đáng tin cậy độ chính xác của kiểm tra khác biệt khoảng cách cục bộ Cα (IDDT-Cα) của dự đoán tương ứng (Hình 2c). Chúng tôi cũng nhận thấy rằng

điểm mô hình hóa khuôn mẫu (TM-score)<sup>27</sup>, một chỉ số chồng chập toàn cầu, có thể được ước tính chính xác (Hình 2d). Nhìn chung, các phân tích này xác nhận rằng độ chính xác và độ tin cậy cao của AlphaFold trên các protein CASP14 cũng chuyển sang một bộ sưu tập không được chọn lọc các bản gửi PDB gần đây, như mong đợi (xem Phương pháp bổ sung 1.15 và Hình bổ sung 11 để xác nhận rằng độ chính xác cao này mở rộng sang các cấu trúc gấp mới).

## Mạng AlphaFold

AlphaFold cải thiện đáng kể độ chính xác của đoán định cấu trúc bằng cách kết hợp các kiến trúc mạng nơ-ron mới lạ và quy trình huấn luyện dựa trên các ràng buộc tiến hóa, vật lý và hình học của cấu trúc protein. Cụ thể, chúng tôi trình bày một kiến trúc mới để cùng nhúng đối sánh đa chuỗi (MSA) và các đặc trưng cặp đôi, một biểu diễn đầu ra mới và hàm mất mát liên quan cho phép đoán định cấu trúc đầu cuối chính xác, một cơ chế chú ý bất biến mới

584 | Nature | Tập 596 | 26 tháng 8 năm 2021



a 0.30 b 1.0

0.25 0.9

0.20

0.8

0.15

0.7

0.10

0.6

0.05

0 0.5

20 40 60 80 100

IDDT-C $\alpha$  của một gốc

r.m.s.d.95 C $\alpha$  chuỗi đầy đủ (Å)

c 100

100

80

60

90

40

20

80

80 90 100

0

0 20 40 60 80 100

pLDDT trung bình trên vùng đã giải quyết

d 1.0

1.0

0.8

0.6

0.9

0.4

0.2

0.8

0.8 0.9 1.0

0

0 0.2 0.4 0.6 0.8 1.0

pTM trên vùng đã giải quyết

Tỷ lệ protein

Tỷ lệ rotamer chính xác 1

0–0.5 0.5–1 1–2 2–4 4–8 >8

IDDT-C $\alpha$

**Hình 2 | Độ chính xác của AlphaFold trên các cấu trúc PDB gần đây.** Các cấu trúc được phân tích mới hơn so với bất kỳ cấu trúc nào trong tập huấn luyện. Một bộ lọc bổ sung được áp dụng để giảm sự trùng lặp (xem Phương pháp). **a**, Biểu đồ histogram của độ lệch bình phương gốc xương (backbone r.m.s.d.) cho các chuỗi đầy đủ (C $\alpha$  r.m.s.d. đạt 95% độ phủ). Phạm vi lỗi là khoảng tin cậy 95% (Poisson). Tập dữ liệu này loại bỏ các protein có mẫu (được xác định bởi hmmsearch) từ tập huấn luyện với hơn 40% độ đồng nhất chuỗi bao phủ hơn 1% của chuỗi ( $n = 3,144$  chuỗi protein). Trung vị tổng thể là 1.46 Å (khoảng tin cậy 95% = 1.40–1.56 Å). Lưu ý rằng phép đo này sẽ rất nhạy cảm với việc đóng gói miền và độ chính xác của miền; một độ lệch bình phương gốc xương cao được mong đợi cho một số chuỗi với đóng gói không chắc chắn hoặc lỗi đóng gói. **b**, Liên hệ giữa độ chính xác của gốc xương và độ chính xác của chuỗi phụ. Bộ lọc đến các cấu trúc có bất kỳ chuỗi phụ nào được quan sát và độ phân giải tốt hơn 2.5 Å ( $n = 5,317$  chuỗi protein); chuỗi phụ được lọc thêm với  $B$ -factor  $<30 \text{ Å}^2$ . Một chuỗi phụ được phân loại là đúng nếu góc xoay dự đoán nằm trong phạm vi  $40^\circ$ . Mỗi điểm tổng hợp một dải của IDDT-C $\alpha$ , với kích thước ô là 2 đơn vị trên 70 IDDT-C $\alpha$  và 5 đơn vị khác. Điểm tương ứng với độ chính xác trung bình; phạm vi lỗi là khoảng tin cậy 95% (Kiểm định t Student) trên cơ sở mỗi vị trí. **c**, Điểm số độ tin cậy so sánh với độ chính xác thực tế trên các chuỗi. Phù hợp đường thẳng nhỏ nhất IDDT-C $\alpha = 0.997 \times \text{pLDDT} - 1.17$  (Pearson's  $r = 0.76$ ).  $n = 10,795$  chuỗi protein. Khu vực bị che của đường thẳng phù hợp đại diện cho khoảng tin cậy 95% được ước tính từ 10,000 mẫu bootstrap. Trong bài báo đi kèm<sup>39</sup>, cung cấp thêm định lượng về độ tin cậy của pLDDT như một phép đo độ tin cậy. **d**, Liên hệ giữa pTM và điểm số TM toàn bộ chuỗi. Phù hợp đường thẳng nhỏ nhất TM-score =  $0.98 \times \text{pTM} + 0.07$  (Pearson's  $r = 0.85$ ).  $n = 10,795$  chuỗi protein. Khu vực bị che của đường thẳng phù hợp đại diện cho khoảng tin cậy 95% được ước tính từ 10,000 mẫu bootstrap.

Mạng AlphaFold dự đoán trực tiếp tọa độ 3D của tất cả các nguyên tử nặng cho một protein cụ thể sử dụng chuỗi axit amin đầu vào và các chuỗi đồng nhất đã được đối sánh như đầu vào (Hình 1e; xem Phương pháp chi tiết về đầu vào bao gồm cơ sở dữ liệu, xây dựng MSA và sử dụng mẫu). Mô tả về những ý tưởng và thành phần quan trọng nhất được cung cấp dưới đây. Toàn bộ kiến trúc mạng và quy trình huấn luyện được cung cấp trong Phương pháp Phụ lục.

Mạng bao gồm hai giai đoạn chính. Đầu tiên, thân mạng xử lý đầu vào qua nhiều lớp của khối mạng thần kinh mới mà chúng tôi gọi là Evoformer để tạo ra một mảng  $N \text{ seq} \times N \text{ res}$  ( $N \text{ seq}$ , số lượng chuỗi;  $N \text{ res}$ , số

Chúng tôi cũng sử dụng một biến thể của sự chú ý theo trục trong đại diện MSA. Trong quá trình chú ý từng chuỗi trong MSA, chúng tôi chuyển đổi thêm các logits từ chồng đôi

vào để thiên hướng chú ý MSA. Điều này đóng vòng luân hồi bằng cách cung cấp luồng thông tin từ đại diện đôi trở lại vào đại diện MSA, đảm bảo rằng khối Evoformer tổng thể có thể trộn hoàn toàn thông tin giữa đại diện đôi và MSA, và chuẩn bị cho việc tạo cấu trúc trong mô-đun cấu trúc.

## Đoán định cấu trúc protein từ đầu đến cuối

Mô-đun cấu trúc (Hình 3d) hoạt động trên một cấu trúc xương 3D cụ thể sử dụng đại diện đôi và hàng chuỗi gốc (đại diện đơn) của đại diện MSA từ thân. Cấu trúc xương 3D được biểu diễn dưới dạng  $N$  res quay độc lập và dịch chuyển, mỗi cái với mỗi quan hệ tới khung toàn cục (khí chất độ) (Hình 3e). Các quay và dịch chuyển - biểu diễn hình học của các nguyên tử N-C $\alpha$ -C - ưu tiên hướng của xương protein sao cho vị trí của chuỗi phụ của mỗi độ là rất hạn chế trong khung đó. Ngược lại, hình học của liên kết peptit hoàn toàn không bị ràng buộc và mạng được quan sát thấy thường xuyên vi phạm ràng buộc chuỗi trong ứng dụng của mô-đun cấu trúc, vì việc phá vỡ ràng buộc này cho phép tinh chỉnh cục bộ tất cả các phần của chuỗi mà không cần giải quyết các vấn đề phức tạp về đóng vòng vòng. Sự hài lòng với hình học của liên kết peptit được khuyến khích trong quá trình điều chỉnh nhỏ bằng một thuật toán mất mát vi phạm. Thực thi chính xác hình học của liên kết peptit chỉ đạt được trong quá trình thư giãn sau dự đoán của cấu trúc bằng phương pháp tối thiểu bậc hai trong trường lực Amber<sup>32</sup>. Thực nghiệm cho thấy, lần thư giãn cuối cùng này không cải thiện độ chính xác của mô hình theo

586 | Nature | Tập 596 | 26 tháng 8 năm 2021

kiểm thử khoảng cách toàn cục (GDT)<sup>33</sup> hoặc IDDT-C $\alpha$ <sup>34</sup> nhưng

**Hình 5 | Tác động của độ sâu MSA và tương tác giữa các chuỗi. a)** Độ chính xác của phần tử chính (IDDT-C $\alpha$ ) cho tập dữ liệu PDB đã giảm thiểu sự trùng lặp sau ngưỡng cắt dữ liệu huấn luyện của chúng tôi, giới hạn cho các protein trong đó tối đa 25% các tương tác xa là giữa các chuỗi khác nhau của heteromer. Chúng tôi tiếp tục xem xét hai nhóm protein dựa trên độ che phủ mẫu tại 30% đồng nhất trình tự: che phủ hơn 60% chuỗi (  $n = 6,743$  chuỗi protein) và che phủ dưới 30% chuỗi (  $n = 1,596$  chuỗi protein). Độ sâu MSA được tính bằng cách đếm

tác động của độ sâu MSA đối với mỗi loại bỏ được cung cấp trong Phương pháp bổ sung 1.13 và Hình bổ sung 10.

## Độ sâu MSA và tương tác giữa các chuỗi

Mặc dù AlphaFold có độ chính xác cao trên hầu hết các cấu trúc PDB đã lưu trữ, chúng tôi nhận thấy vẫn còn các yếu tố ảnh hưởng đến độ chính xác hoặc hạn chế khả năng áp dụng của mô hình. Mô hình sử dụng MSA và độ chính xác giảm đáng kể khi độ sâu trung

biên của đối sánh là ít hơn khoảng 30 trình tự (xem Hình 5a chi tiết). Chúng tôi quan sát thấy hiệu ứng ngưỡng nơi cải thiện độ sâu MSA vượt quá khoảng 100 trình tự dẫn đến lợi ích nhỏ. Chúng tôi giả thuyết rằng thông tin MSA cần thiết để tìm cấu trúc chính xác trong giai đoạn đầu của mạng, nhưng việc tinh chỉnh dự đoán này thành một mô hình chính xác cao không phụ thuộc quan trọng vào thông tin MSA. Sự hạn chế đáng kể khác mà chúng tôi đã quan sát thấy là

17. Sippl, M. J. Tính toán tập hợp cấu hình từ lực trung bình tiềm năng. Một phương pháp tiếp cận dự đoán kiến trúc dựa trên cấu trúc cục bộ trong các protein toàn cầu. *J. Mol. Biol.* **213**, 859–883 (1990).
18. Šali, A. & Blundell, T. L. So sánh mô hình hóa protein bằng thỏa thuận ràng buộc không gian. *J. Mol. Biol.* **234**, 779–815 (1993).
19. Roy, A., Kucukural, A. & Zhang, Y. I-TASSER: một nền tảng thống nhất cho dự đoán cấu trúc và chức năng protein tự động. *Nat. Protocols* **5**, 725–738 (2010).
20. Altschuh, D., Lesk, A. M., Bloomer, A. C. & Klug, A. Liên kết sự thay đổi đồng thời của các axit amin với chức năng trong các virus liên quan đến virus mosaic lá thuốc lá. *J. Mol. Biol.* **193**, 693–707 (1987).
21. Shindyalov, I. N., Kolchanov, N. A. & Sander, C. Có thể dự đoán các điểm tương tác ba chiều trong cấu trúc protein thông qua phân tích đột biến tương quan? *Protein Eng.* **7**, 349–358 (1994).
22. Weigt, M., White, R. A., Szurmant, H., Hoch, J. A. & Hwa, T. Phân loại trực tiếp các điểm tương tác giữa các axit amin trong tương tác protein-protein thông qua truyền tin. *Proc. Natl Acad. Sci. USA* **106**, 67–72 (2009).
23. Marks, D.

BFD được xây dựng qua ba bước. Đầu tiên, đã thu thập 2,423,213,294 chuỗi protein từ UniProt (Swiss-Prot&TrEMBL, 2017-11)<sup>62</sup>, danh mục protein tham chiếu đất và danh mục tham chiếu biến động vật nguyên sinh<sup>7</sup>, và nhóm chúng lại với độ đồng nhất chuỗi 30%, đồng thời đảm bảo độ phủ đối sánh 90% của các chuỗi ngắn hơn bằng MMseqs2/Linclust<sup>63</sup>. Điều này đã tạo ra 345,159,030 cụm. Để tăng hiệu quả tính toán, chúng tôi loại bỏ tất cả các cụm có ít hơn ba thành viên, dẫn đến 61,083,719 cụm. Thứ hai, chúng tôi thêm 166,510,624 chuỗi đại diện protein từ Metaclust NR (2017-05; loại bỏ tất cả các chuỗi ngắn hơn 150 axit amin)<sup>63</sup> bằng cách đối sánh chúng với các đại diện cụm bằng MMseqs2<sup>64</sup>. Các chuỗi đáp ứng tiêu chí độ đồng nhất và độ phủ được gán vào cụm có điểm số cao nhất. 25,347,429 chuỗi còn lại không thể gán được nhóm riêng biệt và được thêm như các cụm mới, dẫn đến nhóm cuối cùng. Thứ ba, cho mỗi cụm, chúng tôi tính toán một multi-sequence alignment (MSA) sử dụng



[illegible]

Nature Research mong muốn cải thiện khả năng tái tạo của công việc mà chúng tôi xuất bản. Biểu mẫu này cung cấp cấu trúc cho sự nhất quán và minh bạch trong báo cáo. Để biết thêm thông tin về chính sách của Nature Research, xem [Chính sách Biên tập](#) và [Danh sách kiểm tra Chính sách Biên tập](#).

## Thống kê

Đối với tất cả các phân tích thống kê, xác nhận rằng các mục sau đây có mặt trong chú thích hình vẽ, chú thích bảng, nội dung chính hoặc phần Phương pháp.

- n/a Đã xác nhân

Số lượng mẫu cụ thể ( $n$ ) cho mỗi nhóm thí nghiệm/điều kiện, được đưa ra dưới dạng một số nguyên và đơn vị đo lường

Một tuyên bố về việc liệu các phép đo đã được thực hiện từ các mẫu riêng biệt hay liệu cùng một mẫu đã được đo lại nhiều lần

Thống kê sử dụng và liệu chúng có phải là một bên hay hai bên

*Thay đổi phức tạp hơn nên được mô tả chi tiết trong phần Phương pháp.*

Mô tả tất cả các biến cố định được kiểm tra

Mô tả bất kỳ giả định hoặc điều chỉnh nào, như các bài kiểm tra về tính bình thường và điều chỉnh cho nhiều so sánh

Mô tả đầy đủ các tham số thống kê bao gồm xu hướng trung tâm (ví dụ: trung bình) hoặc các ước lượng cơ bản khác (ví dụ: hệ số hồi quy) và sự biến thiên (ví dụ: độ lệch chuẩn) hoặc các ước lượng không chắc chắn liên quan

Đối với kiểm định giả thuyết, thống kê kiểm định (ví dụ:  $F$ ,  $t$ ,  $r$ ) với khoảng tin cậy, kích thước hiệu ứng, độ tự do và giá trị  $P$  được ghi rõ *Cho giá trị  $P$  dưới dạng giá trị chính xác khi phù hợp.*

Đối với phân tích Bayes, thông tin về lựa chọn tiên đề và cài đặt chuỗi Markov Monte Carlo

Đối với thiết kế phân cấp và phức tạp, xác định mức phù hợp cho các kiểm định và báo cáo đầy đủ kết quả

Kích thước hiệu ứng (ví dụ: Cohen's  $d$ , Pearson's  $r$ ), chỉ rõ cách tính toán

[Trang web của chúng tôi chứa các bài viết về nhiều điểm trên đây.](#)

## Phần mềm và mã nguồn

### Thông tin chính sách về khả năng tiếp cận mã nguồn máy tính

Dữ liệu thu thập Mã nguồn cho mô hình AlphaFold, trọng số huấn luyện và kịch bản suy luận sẽ được cung cấp dưới giấy phép nguồn mở tại <https://github.com/deepmind/> sau khi xuất bản.

Mạng thần kinh được phát triển với TensorFlow v1 (<https://github.com/tensorflow/tensorflow>), Sonnet v1 (<https://github.com/deepmind/sonnet>), JAX v0.1.69 (<https://github.com/google/jax/>) và Haiku v0.0.4 (<https://github.com/deepmind/dm-haiku>). Bộ biên dịch XLA được đóng gói với JAX và không có số phiên bản riêng biệt.

**Đối với tìm kiếm MSA trên BFD+Uniclust30 và tìm kiếm mẫu đối với PDB70, chúng tôi sử dụng HHBlits và HHSearch từ hh-suite v3.0-beta.3**

**14/07/2017 (<https://github.com/soedinglab/hh-suite>). Đối với tìm kiếm MSA trên UniRef90 và tập MGnify được nhóm, chúng tôi sử dụng jackhmmer từ HMMER v3.3 (<http://eddylab.org/software/hmmer/>). Đối với việc thư giãn cấu trúc bị ràng buộc, chúng tôi sử dụng OpenMM v7.3.1 (<https://github.com/openmm/openmm>) với trường lực Amber99sb.**

Xây dựng BFD sử dụng MMseqs2 phiên bản 925AF (<https://github.com/soedinglab/MMseqs2>) và FAMSA v1.2.5 (<https://github.com/refresh-bio/FAMSA>).

|                          |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |
|--------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Phân tích dữ liệu</b> | <b>Phân tích dữ liệu sử dụng Python v3.6 (<a href="https://www.python.org/">https://www.python.org/</a>), NumPy v1.16.4 (<a href="https://github.com/numpy/numpy">https://github.com/numpy/numpy</a>), SciPy v1.2.1 (<a href="https://www.scipy.org/">https://www.scipy.org/</a>), seaborn v0.11.1 (<a href="https://github.com/mwaskom/seaborn">https://github.com/mwaskom/seaborn</a>), Matplotlib v3.3.4 (<a href="https://github.com/matplotlib/matplotlib">https://github.com/matplotlib/matplotlib</a>),</b>                                                                                                                        |
|                          | bokeh v1.4.0 ( <a href="https://github.com/bokeh/bokeh">https://github.com/bokeh/bokeh</a> ), pandas v1.1.5 ( <a href="https://github.com/pandas-dev/pandas">https://github.com/pandas-dev/pandas</a> ), plotnine v0.8.0 ( <a href="https://github.com/has2k1/plotnine">https://github.com/has2k1/plotnine</a> ), statsmodels v0.12.2 ( <a href="https://github.com/statsmodels/statsmodels">https://github.com/statsmodels/statsmodels</a> ) và Colab ( <a href="https://research.google.com/colaboratory">https://research.google.com/colaboratory</a> ).<br>TM-align v20190822 ( <a href="https://zhanglab.dc">https://zhanglab.dc</a> |