

Mô hình Ngôn ngữ là Học ít Mẫu

Tom B. Bro	wn* Benjamin	Mann* Nick R	yder* Melanie Subbiah*
Jared Kaplan[†]	Prafulla Dhariwal	Arvind Neelakantan	Pranav Shyam Girish Sastry
Amanda Askell	Sandhini Agarwal	Ariel Herbert-Voss	Gretchen Krueger Tom Henighan
Rewon Child	Aditya Ramesh	Daniel M. Ziegler	Jeffrey Wu Clemens Winter
Christopher H	esse Mark Chen	Eric Sigler	Mateusz Litwin Scott Gray
Benja	min Chess	Jack Clark	Christopher Berner
Sam McCa	ndlish Alec Ra	dford Ilya Su	tskever Dario Amodei

OpenAI

Tóm tắt

Công trình gần đây đã chứng minh những lợi ích đáng kể trên nhiều nhiệm vụ và benchmark xử lý ngôn ngữ tự nhiên (NLP) bằng cách tiền huấn luyện trên một bộ dữ liệu lớn văn bản sau đó huấn luyện tinh chỉnh trên một nhiệm vụ cụ thể. Trong khi phương pháp này thường không phụ thuộc vào nhiệm vụ về mặt kiến trúc, nó vẫn còn đòi hỏi các tập huấn luyện tinh chỉnh riêng biệt cho mỗi nhiệm vụ, với hàng nghìn hoặc hàng chục nghìn ví dụ. Trái lại, con người có thể thực hiện một nhiệm vụ mới với ngôn ngữ từ chỉ vài ví dụ hoặc từ hướng dẫn đơn giản – điều mà các hệ thống NLP hiện tại vẫn còn gặp khó khăn. Trong bài viết này, chúng tôi chứng minh rằng việc mở rộng mô hình ngôn ngữ giúp cải thiện hiệu suất không phụ thuộc vào nhiệm vụ trong trường hợp học ít mẫu, đôi khi thậm chí đạt đến mức cạnh tranh với các phương pháp tiền huấn luyện tốt nhất hiện

nay. Đặc biệt, chúng tôi huấn luyện mô hình GPT-3, một mô hình tự hồi quy (autoregressive) với 175 tỷ tham số, gấp 10 lần so với bất kỳ mô hình ngôn ngữ không gian trước đây nào, và kiểm tra hiệu suất của nó trong trường hợp học ít mẫu. Đối với tất cả các nhiệm vụ, GPT-3 được áp dụng mà không cần cập nhật gradient hoặc huấn luyện tinh chỉnh, với các nhiệm vụ và ví dụ học ít mẫu được chỉ định hoàn toàn thông qua tương tác văn bản với mô hình. GPT-3 đạt được hiệu suất mạnh mẽ trên nhiều tập dữ liệu NLP, bao gồm dịch, trả lời câu hỏi, và các bài tập điền từ, cũng như một số nhiệm vụ yêu cầu suy luận tức thì hoặc thích nghi với lĩnh vực mới, như giải mã từ, sử dụng từ mới trong câu, hoặc thực hiện tính toán ba chữ số. Đồng thời, chúng tôi cũng xác định một số tập dữ liệu nơi GPT-3 vẫn gặp khó khăn trong học ít mẫu, cũng như một số tập dữ liệu nơi GPT-3 gặp vấn đề phương pháp học từ việc huấn luyện trên các bộ dữ liệu web lớn. Cuối cùng, chúng tôi phát hiện ra rằng GPT-3 có thể tạo ra các mẫu của các bài báo tin tức mà người đánh giá khó phân biệt với các bài báo viết bởi con người. Chúng tôi thảo luận về những tác động xã hội rộng lớn của phát hiện này và của GPT-3 nói chung.

* Contributions đều nhau

† Johns Hopkins University, OpenAI

Tác giả đóng góp được liệt kê ở cuối bài viết.

Nội dung

1 Giới thiệu	3
2 Phương pháp	6
2.1	Model và Kiến trúc
2.2	Tập dữ liệu huấn luyện
2.3	Quá trình huấn luyện
2.4	Đánh giá

3 Kết quả	10
3.1	Nhiệm vụ Tiền Huấn Luyện Ngôn Ngữ, Bài Tập Điền Từ, và Hoàn Thiện

Những năm gần đây đã chứng kiến xu hướng sử dụng biểu diễn ngôn ngữ tiền huấn luyện trong các hệ thống xử lý ngôn ngữ tự nhiên (NLP), áp dụng một cách linh hoạt và không phụ thuộc vào nhiệm vụ cho việc chuyển tiếp ở phía sau. Đầu tiên, biểu diễn đơn lớp được học sử dụng vector từ [MCCD13, PSM14] và được đưa vào các kiến trúc cụ thể cho từng nhiệm vụ, sau đó các mạng nơ-ron tái phát (RNN) với nhiều lớp biểu diễn và trạng thái ngữ cảnh đã được sử dụng để tạo ra các biểu diễn mạnh mẽ hơn [DL15, MBXS17, PNZtY18] (mặc dù vẫn được áp dụng vào các kiến trúc cụ thể cho từng nhiệm vụ), và gần đây hơn, các mô hình ngôn ngữ tái phát hoặc biến đổi tiền huấn luyện [VSP+17] đã được huấn luyện tinh chỉnh trực tiếp, hoàn toàn loại bỏ nhu cầu về các kiến trúc cụ thể cho từng nhiệm vụ [

2 Phương pháp tiếp cận

Phương pháp tiền huấn luyện cơ bản của chúng tôi, bao gồm mô hình, dữ liệu và quá trình huấn luyện, tương tự như quy trình được mô tả trong [RWC⁺ 19], với việc mở rộng quy mô tương đối đơn giản về kích thước mô hình, kích thước tập dữ liệu và sự đa dạng của nó, cũng như thời gian huấn luyện. Việc sử dụng học trong ngữ cảnh của chúng tôi cũng tương tự như [RWC⁺ 19], nhưng trong công trình này, chúng tôi đã hệ thống hóa việc khám phá các thiết lập khác nhau cho việc học trong ngữ cảnh. Do đó, chúng tôi bắt đầu phần này bằng cách định rõ và so sánh các thiết lập khác nhau mà chúng tôi sẽ đánh giá GPT-3 trên hoặc có thể đánh giá GPT-3 trên. Các thiết lập này có thể được xem như nằm trên một phổ về mức độ phụ thuộc vào dữ liệu cụ thể cho mỗi nhiệm vụ (xem Hình 2.1 để minh họa):

- **Huấn luyện tinh chỉnh (FT)** đã trở thành phương pháp phổ biến nhất trong những năm gần đây, và liên quan đến việc cập nhật trọng số của một mô hình tiền huấn luyện bằng cách huấn luyện trên một tập dữ liệu giám sát cụ thể cho nhiệm vụ mong muốn. Thông thường, hàng nghìn đến hàng trăm nghìn ví dụ được gắn nhãn được sử dụng. Lợi ích chính của việc huấn luyện tinh chỉnh là hiệu suất mạnh mẽ trên nhiều benchmark. Nhược điểm chính là việc cần một tập dữ liệu lớn mới cho mỗi nhiệm vụ, tiềm năng cho việc tổng hợp kém ngoài phân phối [MPL19], và khả năng khai thác các tính chất giả của dữ liệu huấn luyện [GSL⁺ 18, NK19], có thể

dẫn đến so sánh không công bằng với hiệu suất của con người. Trong công trình này, chúng tôi không huấn luyện tinh chỉnh GPT-3 vì mục tiêu của chúng tôi là hiệu suất không phụ thuộc vào nhiệm vụ, nhưng GPT-3 có thể được huấn luyện tinh chỉnh theo lý thuyết và đây là hướng nghiên cứu đầy hứa hẹn cho tương lai.

- **Học ít mẫu (FS)** là thuật ngữ chúng tôi sẽ sử dụng trong công trình này để chỉ thiết lập mà mô hình được cung cấp một vài ví dụ về nhiệm vụ tại thời điểm suy luận như điều kiện [RWC⁺ 19], nhưng không cho phép cập nhật trọng số. Như được hiển thị trong Hình 2.1, cho một tập dữ liệu điển hình, một ví dụ có ngữ cảnh và một hoàn thiện mong muốn (ví dụ: một câu tiếng Anh và bản dịch tiếng Pháp), và học ít mẫu hoạt động bằng cách cung cấp K ví dụ về ngữ cảnh và hoàn thiện, sau đó một ví dụ cuối cùng về ngữ cảnh, với mô hình được kỳ vọng sẽ cung cấp hoàn thiện. Chúng tôi thường đặt K trong khoảng từ 10 đến 100 vì đây là số lượng ví dụ có thể phù hợp trong cửa sổ ngữ cảnh của mô hình ($n_{\text{ctx}} = 2048$). Lợi ích chính của học ít mẫu là giảm đáng kể nhu cầu về dữ liệu cụ thể cho nhiệm vụ và giảm tiềm năng để học một phân phối quá hẹp từ một tập dữ liệu huấn luyện lớn nhưng hẹp. Nhược điểm chính là kết quả từ phương pháp này cho đến nay vẫn kém hơn nhiều so với các mô hình huấn luyện tinh chỉnh hiện đại nhất. Ngoài ra, vẫn cần một lượng nhỏ dữ liệu cụ thể cho nhiệm vụ. Theo tên gọi, học ít mẫu như được mô tả ở đây cho mô hình ngôn ngữ liên quan đến học ít mẫu như được sử dụng trong các ngữ cảnh khác trong ML [HYC01, VBL⁺ 16] - cả hai đều liên quan đến việc học dựa trên một phân phối rộng rãi của các nhiệm vụ (trong trường hợp này ẩn trong dữ liệu tiền huấn luyện) và sau đó nhanh chóng thích nghi với một nhiệm vụ mới.
- **Một mẫu (1S)** giống như học ít mẫu ngoại trừ chỉ cho phép một ví dụ và một mô tả bằng ngôn ngữ tự nhiên của nhiệm vụ, như được hiển thị trong Hình 1. Lý do để phân biệt một mẫu từ học ít mẫu và không mẫu


Dữ liệu cho mô hình ngôn ngữ đã mở rộng nhanh chóng, đạt đỉnh cao với bộ dữ liệu Common Crawl² [RSR⁺ 19] chứa gần một nghìn tỷ từ. Kích thước của bộ dữ liệu này đủ lớn để huấn luyện các mô hình lớn nhất của chúng tôi mà không bao giờ cập nhật lại trên cùng một chuỗi ký tự hai lần. Tuy nhiên, chúng tôi đã phát hiện ra rằng các phiên bản không được lọc hoặc chỉ được lọc nhẹ của Common Crawl thường có chất lượng thấp hơn so với các bộ dữ liệu được quản lý tốt hơn. Do đó, chúng tôi đã thực hiện ba bước để cải thiện chất lượng trung bình của các bộ dữ liệu của mình: (1) chúng tôi tải xuống và lọc phiên bản của CommonCrawl dựa trên sự tương đồng với một loạt các cơ sở dữ liệu tham chiếu chất lượng cao, (2) chúng tôi thực hiện việc loại bỏ trùng lặp mờ ở cấp độ tài liệu, trong và giữa các bộ dữ liệu, để ngăn chặn sự trùng lặp và bảo tồn tính toàn vẹn của tập kiểm định bị giữ lại như một phép đo chính xác của quá trình overfitting, và (3) chúng tôi cũng thêm các cơ sở dữ liệu tham chiếu chất lượng cao đã biết vào hỗn hợp đào tạo để bổ sung CommonCrawl và tăng tính đa dạng của nó.

Chi tiết về hai điểm đầu tiên (xử lý Common Crawl) được mô tả trong Phụ lục A. Đối với điểm thứ ba, chúng tôi đã thêm một số bộ dữ liệu chất lượng cao được quản lý, bao gồm phiên bản mở rộng của bộ dữ liệu WebText [RWC⁺ 19], thu thập bằng cách trích xuất liên kết trong một khoảng thời gian dài hơn, và lần đầu tiên được mô tả trong [KMH⁺ 20], hai cơ sở dữ liệu sách trực tuyến (Books1 và Books2) và Wikipedia tiếng Anh.

Bảng 2.2 hiển thị hỗn hợp cuối cùng của các bộ dữ liệu mà chúng tôi sử dụng trong quá trình đào tạo. Dữ liệu CommonCrawl được tải xuống từ 41 phân đoạn hàng tháng của CommonCrawl, bao phủ từ năm 2016 đến 2019, tạo thành 45TB dữ liệu văn bản nén trước khi lọc và 570GB sau khi lọc, tương đương với khoảng 400 tỷ token được mã hóa theo cặp byte. Lưu ý rằng trong quá trình đào tạo, các bộ dữ liệu không được lấy mẫu theo tỷ lệ với kích thước của chúng, nhưng thay vào đó, các bộ dữ liệu mà chúng tôi coi là có chất lượng cao hơn được lấy mẫu nhiều hơn, vì vậy CommonCrawl và Books2 được lấy mẫu ít hơn một lần trong quá trình đào tạo, nhưng các bộ dữ liệu khác được lấy mẫu 2-3 lần. Điều này thực sự chấp nhận một lượng nhỏ overfitting để đổi lấy dữ liệu đào tạo có chất lượng cao hơn.

² <https://commoncrawl.org/the-data/>

8



Hình 2.2: Tổng lượng tính toán sử dụng trong quá trình đào tạo. Dựa trên phân tích trong Scaling Laws For Neural Language Models [KMH⁺ 20], chúng tôi huấn luyện các mô hình lớn hơn nhiều trên rất ít token hơn so với thông thường. Kết quả là, mặc dù GPT-3 3B gần gấp 10 lần so với RoBERTa-Large (355 triệu tham số), cả hai mô hình đều tiêu tốn khoảng 50 petaflop/s-ngày tính toán trong quá trình tiền huấn luyện. Phương pháp luận cho các phép tính này có thể tìm thấy trong Phụ lục D.

Bộ dữ liệu	Số lượng (token)	Trọng lượng trong hỗn hợp đào tạo	Số epoch đã qua khi đào tạo cho 300 tỷ token
Common Crawl (được lọc)	410 tỷ	60%	0.44
WebText2	19 tỷ	22%	2.9
Books1	12 tỷ	8%	1.9
Books2	55 tỷ	8%	0.43
Wikipedia	3 tỷ	3%	3.4

Bảng 2.2: Các bộ dữ liệu được sử dụng để đào tạo GPT-3 . "Trọng lượng trong hỗn hợp đào tạo" đề cập đến phần trăm ví dụ trong quá trình đào tạo được rút từ một bộ dữ liệu cụ thể, mà chúng tôi cố tình không làm tỷ lệ thuận với kích thước của bộ dữ liệu. Kết quả là, khi chúng tôi đào tạo cho 300 tỷ token, một số bộ dữ liệu được nhìn thấy lên tới 3.4 lần trong quá trình đào tạo trong khi các bộ dữ liệu khác được nhìn thấy ít hơn một lần.

Một mối quan tâm phương pháp luận lớn với các mô hình ngôn ngữ tiền huấn luyện trên một phạm vi rộng lớn của dữ liệu internet, đặc biệt là các mô hình lớn có khả năng nhớ lại một lượng lớn nội dung, là khả năng nhiễm bẩn tiềm tàng của các tác vụ phía dưới bởi việc có tập thử nghiệm hoặc phát triển của chúng bị nhìn thấy vô tình trong quá trình tiền huấn luyện. Để giảm thiểu nhiễm bẩn này, chúng tôi đã tìm kiếm và cố gắng loại bỏ bất kỳ sự chồng chéo nào với tập phát triển và thử nghiệm của tất cả các benchmark được nghiên cứu trong bài viết này. Tiếc thay, một lỗi trong quá trình lọc khiến chúng tôi bỏ qua một số sự chồng chéo, và do chi phí huấn luyện, việc huấn luyện lại mô hình không khả thi. Trong Phần 4, chúng tôi mô tả tác động của các sự chồng chéo còn lại, và trong công việc tương lai, chúng tôi sẽ loại bỏ dữ liệu nhiễm bẩn một cách mạnh mẽ hơn.

2.3 Quá trình Đào Tạo

Như đã tìm thấy

Trong Hình 3.1 chúng tôi hiển thị các đường cong huấn luyện cho 8 mô hình được mô tả trong Phần 2. Đối với biểu đồ này, chúng tôi cũng bao gồm 6 mô hình siêu nhỏ bổ sung

với ít nhất 100,000 tham số. Như đã quan sát thấy trong [KMH⁺ 20], hiệu suất mô hình ngôn ngữ tuân theo một hàm lũy thừa khi được gọi nhiều lần, giá trị không đổi. Theo thông tin được cung cấp, đây là một ví dụ về việc dịch từ tiếng Anh sang tiếng Trung. Dưới đây là nội dung dịch:

Trong hình 3.1, chúng tôi đã trình bày các đường cong huấn luyện của 8 mô hình được mô tả trong phần 2. Đối với biểu đồ này, chúng tôi cũng bao gồm 6 mô hình nhỏ hơn, các mô hình này có số lượng tham số thấp nhất là 100,000. Giống như [KMH⁺ 20] đã quan sát được, khi tận dụng hiệu quả các tài nguyên tính toán để huấn luyện, hiệu suất của mô hình ngôn ngữ tuân theo quy luật lũy thừa. Khi mở rộng quy mô hai bậc độ lớn, chúng tôi chỉ quan sát thấy sự lệch (nếu có) khỏi quy luật lũy thừa. Có thể lo ngại rằng sự cải thiện này chỉ là do mô hình được huấn luyện trên các chi tiết không liên quan. Tuy nhiên, trong phần tiếp theo, chúng tôi sẽ thấy rằng sự cải thiện hiệu suất dẫn đến hiệu suất đồng nhất trên một loạt các nhiệm vụ ngôn ngữ tự nhiên.

Dưới đây, chúng tôi đã đánh giá 8 mô hình được mô tả trong phần 2 (bao gồm GPT-3 với 175 tỷ tham số và 7 mô hình nhỏ hơn). Chúng tôi đã chia tập dữ liệu thành 9 danh mục, đại diện cho các nhiệm vụ tương tự nhau.

Trong phần 3.1, chúng tôi đã đánh giá các nhiệm vụ ngôn ngữ truyền thống và các nhiệm vụ tương tự, chẳng hạn như cloze và câu/đoạn văn hoàn thành. Trong phần 3.2, chúng tôi đã đánh giá "bóng" các nhiệm vụ: cần sử dụng thông tin được lưu trữ trong tham số mô hình để trả lời các câu hỏi kiến thức chung. Trong phần 3.3, chúng tôi đã đánh giá khả năng dịch giữa các ngôn ngữ khác nhau (đặc biệt là một lần và một lượng nhỏ). Trong phần 3.4, chúng tôi đã đánh giá mô hình trên các nhiệm vụ Winograd Schema. Trong phần 3.5, chúng tôi đã đánh giá các nhiệm vụ liên quan đến suy luận hoặc các câu hỏi dựa trên kiến thức. Trong phần 3.6, chúng tôi đã đánh giá các nhiệm vụ đọc hiểu, trong phần 3.7, chúng tôi đã đánh giá SuperGLUE benchmark test suite, trong phần 3.8, chúng tôi đã thảo luận về NLI. Cuối cùng, trong phần 3.9, chúng tôi đã thiết kế một số nhiệm vụ bổ sung, được thiết kế để khám phá khả năng học ngữ cảnh — các nhiệm vụ này tập trung vào suy luận, kỹ năng thích ứng hoặc tổng hợp văn bản mở. Chúng tôi đã đánh giá mô hình trên các tập dữ liệu không mẫu, một mẫu và một lượng nhỏ mẫu để đánh giá tất cả các nhiệm vụ.

10

![[temp_images/b5b8d8aa-8ee2-4bf

Trong phần này, chúng tôi đánh giá khả năng của GPT-3 trong việc trả lời các câu hỏi về kiến thức thực tế rộng lớn. Do số lượng lớn các câu hỏi có thể có, nhiệm vụ này thường được tiếp cận bằng cách sử dụng hệ thống tìm kiếm thông tin để tìm văn bản liên quan kết hợp với một mô hình học cách tạo ra câu trả lời dựa trên câu hỏi và văn bản đã tìm thấy. Vì phương pháp này cho phép hệ thống tìm kiếm và điều kiện hóa trên văn bản có thể chứa câu trả lời, nó được gọi là "closed-book" (không cần sách tham khảo). [RRS20] gần đây đã chứng minh rằng một mô hình ngôn ngữ lớn có thể trả lời trực tiếp các câu hỏi với hiệu suất đáng ngạc nhiên mà không cần điều kiện hóa trên thông tin phụ trợ. Họ gọi môi trường đánh giá này là "closed-book" (không cần sách tham khảo). Công trình của họ cho thấy rằng ngay cả các mô hình có sức chứa lớn hơn cũng có thể đạt được hiệu suất tốt hơn và chúng tôi kiểm tra giả thuyết này với GPT-3. Chúng tôi đánh giá GPT-3 trên ba tập dữ liệu trong [RRS20]: Natural Questions [KPR⁺ 19], WebQuestions [BCFL13], và TriviaQA [JCWZ17], sử dụng cùng một phân chia dữ liệu. Lưu ý rằng ngoài

việc tất cả các kết quả


Dưới đây là bản dịch từ tiếng Anh sang tiếng Việt của đoạn văn bản Markdown:

Nội dung: Thách thức Winograd Schemas [LDM12] là một nhiệm vụ truyền thống trong NLP, liên quan đến việc xác định từ nào mà đại từ đang đề cập đến, khi đại từ có ngữ pháp mơ hồ nhưng rõ ràng về mặt ngữ nghĩa đối với con người. Các mô hình ngôn ngữ đã được huấn luyện tinh chỉnh gần đây đã đạt được hiệu suất gần bằng con người trên tập dữ liệu gốc Winograd, nhưng các phiên bản khó hơn vẫn còn thách thức.

16

Điều kiện	PIQA	ARC (Dễ)	ARC (Thách thức)	OpenBookQA
Huấn luyện tinh chỉnh SOTA	79,4	92,0[KKS+20]	78,5[KKS+20]	87,2[KKS+20]
GPT-3 Zero-Shot	80,5*	68,8	51,4	57,6
GPT-3 One-Shot	80,5*	71,2	53,2	58,8
GPT-3 Few-Shot	82,8*	70,1	51,5	65,4

Bảng 3.6: Kết quả của GPT-3 trên ba nhiệm vụ phân tích logic thông thường, PIQA, ARC và OpenBookQA. Kết quả của GPT-3 Few-Shot PIQA được đánh giá trên máy chủ kiểm tra. Xem Phần 4 để biết chi tiết về các vấn đề có thể gây ô nhiễm dữ liệu trong tập kiểm tra PIQA.



Hình 3.6: Kết quả của GPT-3 trên PIQA ở ba điều kiện zero-shot, one-shot và few-shot.

Mô hình lớn nhất đạt điểm trên tập phát triển vượt quá điểm tốt nhất từng ghi nhận trên nhiệm vụ này.

như tập dữ liệu Winogrande được đào tạo đối kháng [SBBC19] vẫn còn thua xa hiệu suất của con người. Chúng tôi kiểm tra hiệu suất của GPT-3 trên cả Winograd và Winogrande, như thường lệ ở điều kiện zero-shot, one-shot và few-shot.

Trên Winograd, chúng tôi kiểm tra GPT-3 trên tập hợp gốc gồm 273 cấu trúc Winograd, sử dụng cùng phương pháp "đánh giá nửa" được mô tả trong [RWC⁺ 19]. Lưu ý rằng điều kiện này hơi khác so với nhiệm vụ WSC trong benchmark SuperGLUE, nơi nó được trình bày dưới dạng phân loại nhị phân và yêu cầu trích xuất thực thể để chuyển đổi thành dạng mô tả trong phần này. Trên Winograd, GPT-3 đạt 88,3%, 89,7% và 88,6% ở điều kiện zero-shot, one-shot và few-shot, cho thấy không có học trong ngữ cảnh rõ ràng nhưng đạt kết quả mạnh mẽ chỉ vài điểm dưới mức SOTA và ước tính hiệu suất của con người. Chúng tôi lưu ý rằng phân tích ô nhiễm tìm thấy một số cấu trúc Winograd trong dữ liệu huấn luyện nhưng điều này dường như chỉ có tác động nhỏ đến kết quả (xem Phần 4).

Trên tập dữ liệu Winogrande khó hơn, chúng tôi thực sự tìm thấy lợi ích từ học trong ngữ cảnh: GPT-3 đạt 70,2% ở điều kiện zero-shot, 73,2% ở điều kiện one-shot và 77,7% ở điều kiện few-shot. Để so sánh, một mô hình RoBERTa đã được huấn luyện tinh chỉnh đạt 79%, mức SOTA là 84,6% đạt được với một mô hình đã được huấn luyện tinh chỉnh có sức chứa cao (T5), và hiệu suất của con người trên nhiệm vụ này như được báo cáo bởi [SBBC19] là 94,0%.

3.5 Phân tích logic thông thường


Tiếp theo, chúng tôi xem xét ba tập dữ liệu cố gắng bắt chước suy luận vật lý hoặc khoa học, khác biệt với việc hoàn thành câu, hiểu nội dung khi đọc hoặc trả lời câu hỏi dựa trên kiến thức rộng rãi. Tập đầu tiên, PhysicalQA (PIQA) [BZB⁺ 19], đặt câu hỏi về cách thế giới vật lý hoạt động và được thiết

Để dịch đoạn văn bản Markdown từ tiếng Anh sang tiếng Việt, chúng ta sẽ giữ nguyên cấu trúc Markdown và LaTeX. Dưới đây là phiên bản dịch:

Để có thể tổng hợp kết quả trên các nhiệm vụ xử lý ngôn ngữ tự nhiên (NLP) một cách hệ thống hơn và so sánh với các mô hình phổ biến như BERT và RoBERTa, chúng tôi cũng đã đánh giá GPT-3 trên một bộ sưu tập chuẩn hóa của dữ liệu, cụ thể là benchmark SuperGLUE [WPN⁺ 19] [WPN⁺ 19] [CLC⁺ 19] [DMST19] [RBG11] [KCR⁺ 18] [ZLL⁺ 18] [DGM06] [BHDD⁺ 06] [GMDD07] [BDD⁺ 09] [PCC18] [PHR⁺ 18]. Hiệu suất kiểm tra của GPT-3 trên tập SuperGLUE được trình bày trong Bảng 3.8. Trong trường hợp học ít mẫu

(few-shot), chúng tôi sử dụng 32 ví dụ cho tất cả các nhiệm vụ, được lấy ngẫu nhiên từ tập huấn luyện. Đối với tất cả các nhiệm vụ ngoại trừ WSC

18



Hình 3.7: Kết quả của GPT-3 trên nhiệm vụ hiểu nội dung khi đọc CoQA. GPT-3 175B đạt 85 F1 trong trường hợp học ít mẫu, chỉ kém một vài điểm so với hiệu suất con người đo được và các mô hình huấn luyện tinh chỉnh hiện đại nhất. Hiệu suất zero-shot và one-shot thấp hơn một chút, với lợi ích lớn nhất từ việc học ít mẫu dành cho các mô hình lớn hơn.

	SuperGLU Tổng trung bình	E BoolQ Độ chính xác	CB y Độ chính xác	CB y F1	COPA Độ chính xác	RTE Độ chính xác
Mô hình tốt nhất đã huấn luyện	89.0	91.0	96.9	93.9	94.8	92.5

Mô hình BERT-Large đã huấn luyện	69.0	77.4	83.6	75.7	70.6	71.7
GPT-3 Few-Shot	71.8	76.4	75.6	52.0	92.0	69.0
	WiC Độ chính xác	WSC Độ chính xác	MultiRC Độ chính xác	MultiRC F1a	ReCoRD Độ chính xác	ReCoRD F1
Mô hình tốt nhất đã huấn luyện	76.1	93.8	62.3	88.2	92.5	93.3
Mô hình BERT-Large đã huấn luyện	69.6	64.6	24.1	70.0	71.3	72.0
GPT-3 Few-Shot	49.4					


Để kiểm tra khả năng thực hiện các phép tính đơn giản của mô hình GPT-3 mà không cần huấn luyện chuyên biệt cho từng nhiệm vụ, chúng tôi đã phát triển một bộ thử nghiệm nhỏ gồm 10 bài kiểm tra liên quan đến việc yêu cầu mô hình GPT-3 giải quyết một vấn đề tính toán đơn giản bằng ngôn ngữ tự nhiên:

- **Cộng hai chữ số (2D+)** – Mô hình được yêu cầu cộng hai số nguyên được lấy ngẫu nhiên đều từ khoảng $[0, 100)$, dưới dạng câu hỏi, ví dụ: “C: 48 cộng với 76 là bao nhiêu? Đ: 124.”
- **Trừ hai chữ số (2D-)** – Mô hình được yêu cầu trừ hai số nguyên được lấy ngẫu nhiên đều từ khoảng $[0, 100)$; kết quả có thể âm. Ví dụ: “C: 34 trừ đi 53 là bao

nhieu? Đ: -19”.

- **Cộng ba chữ số (3D+)** – Tương tự như cộng hai chữ số, ngoại trừ việc các số được lấy ngẫu nhiên đều từ khoảng [0, 1000).

21



Hình 3.10: Kết quả trên tất cả 10 nhiệm vụ tính toán trong chế độ few-shot cho các mô hình khác nhau về kích thước. Có sự tăng đột biến đáng kể từ mô hình lớn thứ hai (GPT-3 13B) đến mô hình lớn nhất (GPT-3 175), với mô hình lớn nhất có thể thực hiện chính xác phép cộng hai chữ số, thường chính xác đối với phép cộng ba chữ số, và trả lời đúng một phần đáng kể thời gian đối với phép cộng bốn-chín chữ số, nhân hai chữ số và các phép toán phức tạp. Kết quả cho one-shot và zero-shot được trình bày trong phụ lục.

- **Trừ ba chữ số (3D-)** – Tương tự như trừ hai chữ số, ngoại trừ việc các số được lấy ngẫu nhiên đều từ khoảng [0, 1000).
- **Cộng bốn chữ số (4D+)** – Tương tự như cộng ba chữ số, ngoại trừ việc các số được lấy ngẫu nhiên đều từ khoảng [0, 10000).
- **Trừ bốn chữ số (4D-)** – Tương tự như trừ ba chữ số, ngoại trừ việc các số được lấy ngẫu nhiên đều từ khoảng [0, 10000).
- **Cộng năm chữ số (5D+)** – Tương tự như cộng ba chữ số, ngoại trừ việc các số

được lấy ngẫu nhiên đều từ khoảng $[0, 100000)$.

- **Trừ năm chữ số (5D-)** – Tương tự như trừ ba chữ số, ngoại trừ việc các số được lấy ngẫu nhiên đều từ khoảng $[0, 100000)$.

- **Nhân hai chữ số (2Dx)** – Mô hình được yêu cầu nhân hai số nguyên được lấy ngẫu nhiên đều từ khoảng $[0, 100)$, ví dụ: “C: 24 nhân với 42 là bao nhiêu? Đ: 1008”.

- **Phép toán phức tạp một chữ số (1DC)** – Mô hình được yêu cầu thực hiện một phép toán phức tạp trên ba số một chữ số, với dấu ngoặc đơn bao quanh hai số cuối cùng. Ví dụ: “C: $6+(4*8)$ là bao nhiêu? Đ: 38”. Ba số một chữ số được chọn ngẫu nhiên từ khoảng $[0, 10)$ và các phép toán được chọn ngẫu nhiên từ $\{+, -, *\}$.

Trong tất cả 10 nhiệm vụ, mô hình phải tạo ra câu trả lời chính xác hoàn toàn. Đối với mỗi nhiệm vụ, chúng tôi tạo ra một tập dữ liệu gồm 2,000 trường hợp ngẫu nhiên của nhiệm vụ và đánh giá tất cả các mô hình trên những trường hợp này.

Đầu tiên, chúng tôi đánh giá GPT-3 trong chế độ few-shot, kết quả được hiển thị trong Hình 3.10. Trên phép cộng và trừ, GPT-3 thể hiện sự thuần thục mạnh mẽ khi số chữ số nhỏ, đạt được 100% chính xác trên phép cộng hai chữ số, 98.9% trên phép trừ hai chữ số, 80.2% trên phép cộng ba chữ số, và 94.2% trên phép trừ ba chữ số. Hiệu suất giảm khi số chữ số tăng lên, nhưng GPT-3 vẫn đạt được 25-26% chính xác trên phép toán bốn chữ số và 9-10% chính xác trên phép toán năm chữ số, gợi ý rằng nó có khả năng tổng quát hóa đến các số chữ số lớn hơn. GPT-3 cũng đạt được 29.2% chính xác trên phép nhân hai chữ số, một phép toán đặc biệt đòi hỏi tính toán mạnh mẽ. Cuối cùng, GPT-3 đạt được 21.3% chính xác trên phép toán phức tạp một chữ số (ví dụ: $9*(7+5)$), gợi ý rằng nó có độ ổn định ngoài việc chỉ thực hiện một phép toán đơn lẻ.

Hình 3.10 rõ ràng cho thấy các mô hình nhỏ hoạt động kém trong tất cả các nhiệm vụ này – thậm chí mô hình 13 tỷ tham số (mô hình lớn thứ hai sau mô hình đầy đủ 175 tỷ tham số của GPT-3) cũng chỉ giải quyết được phép cộng và trừ hai chữ số nửa số lần, và tất cả các phép toán khác ít hơn 10% số lần.

Chế độ one-shot và zero-shot có hiệu suất bị suy


Để kiểm tra khả năng của GPT-3 trong việc học các thao tác biểu tượng mới từ một vài ví dụ, chúng tôi đã thiết kế một bộ thử nghiệm nhỏ gồm 5 nhiệm vụ “thao tác ký tự”. Mỗi nhiệm vụ đòi hỏi đưa cho mô hình một từ bị biến dạng bằng cách kết hợp các thao tác đảo vị trí, thêm hoặc xóa ký tự, và yêu cầu nó khôi phục từ gốc. Các nhiệm vụ cụ thể là:

- **Đảo vị trí ký tự trong từ (CL)** – Mô hình được đưa một từ với các ký tự bị đảo vị trí, sau đó ký hiệu “=” và được yêu cầu tạo ra từ gốc. Ví dụ: nó có thể được đưa “lyinevitab” và phải xuất ra “inevitably”.

- **Tổ hợp tất cả nhưng ký tự đầu và cuối (A1)** – Mô hình được đưa một từ với tất cả các ký tự ngoại trừ ký tự đầu tiên và cuối cùng bị đảo lộn ngẫu nhiên, và phải xuất ra từ gốc. Ví dụ: criroptuon = corruption.
- **Tổ hợp tất cả nhưng hai ký tự đầu và cuối (A2)** – Mô hình được đưa một từ với tất cả các ký tự ngoại trừ hai ký tự đầu tiên và cuối cùng bị đảo lộn ngẫu nhiên, và phải khôi phục từ gốc. Ví dụ: opoepnnt → opponent.
- **Thêm ngẫu nhiên ký tự vào từ (RI)** – Một ký tự dấu câu hoặc khoảng trắng ngẫu nhiên được thêm giữa mỗi ký tự của từ, và mô hình phải xuất ra từ gốc. Ví dụ: s.u! c/c!e.s s i/o/n = succession.
- **Từ đảo ngược (RW)** – Mô hình được đưa một từ viết ngược lại, và phải xuất ra từ gốc. Ví dụ: stcejbo → objects.

Đối với mỗi nhiệm vụ, chúng tôi tạo ra 10,000 ví dụ, mà chúng tôi chọn là 10,000 từ phổ biến nhất theo [Nor09], có độ dài từ hơn 4 ký tự đến dưới 15 ký tự. Kết quả học ít mẫu được hiển thị trong Hình 3.11. Hiệu suất nhiệm vụ thường tăng mượt mà theo kích thước mô hình, với mô hình GPT-3 đầy đủ đạt được 66.9% trên việc loại bỏ

23



Hình 3.11: Hiệu suất học ít mẫu trên năm nhiệm vụ thao tác ký tự cho các kích thước khác nhau của mô hình. Có sự cải thiện mượt mà theo kích thước mô hình, mặc dù nhiệm vụ thêm ngẫu nhiên ký tự cho thấy đường dốc tăng lên, với mô hình 175 tỷ tham

số giải quyết nhiệm vụ phần lớn thời gian. Tăng cường hiệu suất một mẫu và không mẫu được hiển thị trong phụ lục. Tất cả các nhiệm vụ đều được thực hiện với $K = 100$.

thêm ký tự ngẫu nhiên, 38.6% trên việc đảo vị trí ký tự, 40.2% trên nhiệm vụ tổ hợp dễ dàng, và 15.1% trên nhiệm vụ tổ hợp khó khăn (trong đó chỉ ký tự đầu tiên và cuối cùng được giữ cố định). Không có mô hình nào có thể đảo ngược thứ tự ký tự trong từ.

Trong trường hợp một mẫu, hiệu suất yếu hơn đáng kể (giảm một nửa hoặc nhiều hơn), và trong trường hợp không mẫu, mô hình hiếm khi có thể thực hiện bất kỳ nhiệm vụ nào (Bảng 3.10). Điều này gợi ý rằng mô hình thực sự có vẻ học các nhiệm vụ này tại thời điểm kiểm tra, vì mô hình không thể thực hiện chúng không mẫu và tính chất nhân tạo của chúng khiến chúng ít có khả năng xuất hiện trong dữ liệu tiền huấn luyện (mặc dù chúng tôi không thể xác nhận điều này chắc chắn).

Chúng tôi có thể định lượng hiệu suất thêm bằng cách vẽ "đường cong học trong ngữ cảnh", mà thể hiện hiệu suất nhiệm vụ theo số lượng ví dụ trong ngữ cảnh. Chúng tôi hiển thị đường cong học trong ngữ cảnh cho nhiệm vụ Thêm Ký tự trong Hình 1.2. Chúng ta có thể thấy rằng các mô hình lớn hơn có thể sử dụng hiệu quả hơn thông tin trong ngữ cảnh, bao gồm cả các ví dụ nhiệm vụ và mô tả nhiệm vụ bằng ngôn ngữ tự nhiên.


Cuối cùng, đáng lưu ý rằng giải quyết các nhiệm vụ này đòi hỏi thao tác ký tự, trong khi mã hóa BPE của chúng tôi hoạt động trên các phần lớn của từ (trung bình ~ 0.7 từ mỗi token), do đó từ góc độ của mô hình ngôn ngữ, thành công trong các nhiệm vụ này đòi hỏi không chỉ thao tác các token BPE mà còn hiểu và phân tách cấu trúc bên trong của chúng. Ngoài ra, CL, A1 và A2 không phải là song ánh (tức là, từ chưa bị rối không phải là hàm xác định của từ bị rối), đòi hỏi mô hình phải thực hiện tìm kiếm để tìm ra giải pháp đúng. Do đó, kỹ năng liên quan dường như đòi hỏi việc khớp mẫu và tính toán không đơn giản.

3.9.3 Đề Bài So Sánh SAT

Để kiểm tra GPT-3 trên một nhiệm vụ tương đối không thông thường so với phân phối thông thường của văn bản, chúng tôi đã thu thập một tập hợp 374 "đề bài so sánh SAT" [TLBS03]. So sánh là một kiểu câu hỏi lựa chọn nhiều đáp án mà đã cấu thành một phần của bài thi SAT vào đại học trước năm 2005. Một ví dụ điển hình là "audacious là đến boldness như (a) sanctimonious là đến hypocrisy, (b) anonymous là đến identity, (c) remorseful là đến misdeed, (d) deleterious là đến result, (e) impressionable là đến temptation". Học sinh được yêu cầu chọn cặp từ nào trong năm cặp từ có mối quan hệ tương tự như cặp từ gốc; trong ví dụ này, câu trả lời là "sanctimonious là đến hypocrisy". Trên nhiệm vụ này, GPT-3 đạt được 65.2% trong trường hợp học ít mẫu, 59.1% trong trường hợp một mẫu và 53.7% trong trường hợp không mẫu, trong khi điểm trung bình

của ứng viên đại học là 57% [TL05] (chọn ngẫu nhiên sẽ cho ra 20%). Như được hiển thị trong Hình 3.12, kết quả cải thiện theo quy mô, với mô hình 175 tỷ tham số cải thiện hơn 10% so với mô hình 13 tỷ tham số.

24



Hình 3.12: Hiệu suất không mẫu, một mẫu và học ít mẫu trên nhiệm vụ đề bài so sánh SAT, cho các kích thước khác nhau của mô hình. Mô hình lớn nhất đạt được 65% độ chính xác trong trường hợp học ít mẫu, và cũng thể hiện lợi ích đáng kể đến học trong ngữ cảnh mà không có trong các mô hình nhỏ hơn.

3.9.4 Tạo Bài Báo Điện Tử

Dịch đoạn văn bản Markdown sau từ tiếng Anh sang tiếng Việt:

Text: Các công trình trước đây về mô hình ngôn ngữ sinh ra đã kiểm định chất lượng khả năng sinh ra các bài viết giả lập "tin tức" bằng cách lấy mẫu điều kiện từ mô hình dựa trên một đề mục viết bởi con người, bao gồm một câu mở đầu hợp lý cho một câu chuyện tin tức [RWC+ 19]. So sánh với [RWC+ 19], tập dữ liệu được sử dụng để huấn luyện GPT-3 ít tập trung hơn vào các bài viết tin tức, nên việc thử nghiệm tạo ra các bài viết tin tức qua các mẫu không điều kiện thuần túy ít hiệu quả hơn - ví dụ, GPT-3 thường hiểu sai câu mở đầu của một "bài viết tin tức" như một tweet và sau đó đăng các phản hồi hoặc tweet tiếp theo. Để giải quyết vấn đề này, chúng tôi đã sử dụng khả năng học ít mẫu của GPT-3 bằng cách cung cấp ba bài viết tin tức trước đó trong ngữ cảnh của mô hình để điều kiện

hóa nó. Với tiêu đề và phụ đề của một bài viết kế tiếp được đề xuất, mô hình có thể sinh ra đáng tin cậy các bài viết ngắn thuộc thể loại "tin tức".

Để đánh giá chất lượng sinh ra các bài viết tin tức từ GPT-3 (chúng tôi tin rằng điều này có thể tương quan với chất lượng mẫu điều kiện tổng thể), chúng tôi quyết định đo lường khả năng phân biệt của con người giữa các bài viết sinh ra từ GPT-3 và các bài viết thực sự. Công trình tương tự đã được thực hiện bởi Kreps et al. [KMB20] và Zellers et al. [ZHR⁺ 19]. Mô hình ngôn ngữ sinh ra được huấn luyện để khớp phân phối nội dung được tạo ra bởi con người, nên khả năng (không) phân biệt của con người giữa hai loại bài viết có thể là một thước đo chất lượng tiềm năng quan trọng.

Để thấy rõ con người có thể phát hiện văn bản sinh ra từ mô hình như thế nào, chúng tôi đã chọn ngẫu nhiên 25 tiêu đề và phụ đề bài viết từ trang web newser.com (trung bình 215 từ). Chúng tôi sau đó đã sinh ra các phần còn lại của những tiêu đề và phụ đề này từ bốn mô hình ngôn ngữ khác nhau, từ 125 triệu đến 175 tỷ tham số (trung bình 200 từ). Đối với mỗi mô hình, chúng tôi đã đưa ra khoảng 80 người tham gia từ Hoa Kỳ một bài kiểm tra bao gồm các tiêu đề và phụ đề thực tế theo sau bởi hoặc bài viết viết bởi con người hoặc bài viết sinh ra từ mô hình⁴. Người tham gia được yêu cầu chọn liệu bài viết có phải là "rất có thể được viết bởi con người", "càng có khả năng được viết bởi con người", "Tôi không biết", "càng có khả năng được viết bởi máy tính", hoặc "rất có thể được viết bởi máy tính".

Các bài viết chúng tôi đã chọn không nằm trong dữ liệu huấn luyện của các mô hình và các đầu ra của mô hình được định dạng và lựa chọn theo chương trình để ngăn chặn việc lựa chọn trái phép của con người. Tất cả các mô hình đều sử dụng cùng ngữ cảnh để điều kiện hóa đầu ra và được huấn luyện trước với cùng kích thước ngữ cảnh và cùng các tiêu đề và phụ đề bài viết được sử dụng như đề mục cho mỗi mô hình. Tuy nhiên, chúng tôi cũng đã chạy một thí nghiệm để kiểm soát nỗ lực và sự chú ý của người tham gia theo cùng định dạng nhưng liên quan đến các bài viết sinh ra từ mô hình kiểm soát. Điều này được thực hiện bằng cách sinh ra các bài viết từ một "mô hình kiểm soát": một mô hình 160 triệu tham số không có ngữ cảnh và tăng ngẫu nhiên đầu ra.

⁴Chúng tôi muốn xác định mức độ tốt mà một người trung bình trên internet có thể phát hiện văn bản sinh ra từ mô hình ngôn ngữ, vì vậy chúng tôi tập trung vào người tham gia được rút từ dân số Hoa Kỳ nói chung. Xem Phụ lục E để chi tiết.

	Trung bình độ chính xác	Phạm vi khoảng tin cậy 95% (thấp, cao)	t -so sánh với mô hình kiểm soát (p -giá trị)	"Tôi không biết" đánh dấu
Mô hình kiểm soát (mô hình cố tình tồi)	86%	83%–90%	-	3.6%
GPT-3 Nhỏ	76%	72%–80%	3.9 (2_e_{-4})	4.9%
GPT-3 Trung	61%	58%–65%	10.3 (7_e_{-21})	6.0%
GPT-3 Lớn	68%	64%–72%	7.3 (3_e_{-11})	8.7%
GPT-3 XL	62%	59%–65%	10.7 (1_e_{-19})	7.5%
GPT-3 2.7B	62%	58%–65%	10.4 (5_e_{-19})	7.1%
GPT-3 6.7B	60%	56%–63%	11.2 (3_e_{-21})	6.2%
GPT-3 13B	55%	52%–58%	15.3 (1_e_{-32})	7.1%
GPT-3 175B	52%	49%–54%	16.9 (1_e_{-34})	7.8%

Bảng 3.11: Độ chính xác của con người trong việc nhận biết liệu các bài viết ngắn (~200 từ) có phải là sinh ra từ mô hình. Chúng tôi tìm thấy rằng độ chính xác của con người (đo bằng tỷ lệ giữa số lần gán đúng và số lần gán không trung lập) dao động từ 86% đối với mô hình kiểm soát đến 52% đối với GPT-3 175B. Bảng này so sánh độ chính xác trung bình giữa năm mô hình

Dịch đoạn văn bản Markdown sau từ tiếng Anh sang tiếng Việt. Lưu ý: Giữ nguyên thẻ Markdown và LaTeX.

Text: Một nhiệm vụ được nghiên cứu trong ngôn ngữ phát triển [CB78] là khả năng học và sử dụng những từ mới, ví dụ như sử dụng một từ trong một câu sau khi chỉ nhìn thấy định nghĩa của nó một lần, hoặc ngược lại, suy luận ý nghĩa của từ đó từ chỉ một lần sử dụng. Trong phần này, chúng tôi kiểm tra định tính khả năng của GPT-3 thực hiện nhiệm vụ đầu tiên trên đây. Cụ thể, chúng tôi cung cấp cho GPT-3 định nghĩa của một từ không


tồn tại, như "Gigamuru", và sau đó yêu cầu nó sử dụng từ đó trong một câu. Chúng tôi cung cấp một đến năm ví dụ trước đó về việc sử dụng từ khác (tách biệt).

5Chúng tôi sử dụng phép thử t-student hai mẫu để kiểm tra sự khác biệt đáng kể giữa trung bình độ chính xác của mỗi mô hình và mô hình đối chứng, và báo cáo sự khác biệt chuẩn hóa giữa trung bình (như thống kê t) và giá trị p.

6Nếu một mô hình luôn tạo ra văn bản ấn tượng hơn so với các bài viết của con người, có thể rằng hiệu suất của con người trên nhiệm vụ này sẽ giảm xuống dưới 50%. Thật vậy, nhiều cá nhân đã đạt dưới 50% trên nhiệm vụ này.

7Các mẫu không tin tức bổ sung có thể tìm thấy trong Phụ lục F.

26



Hình 3.13: Khả năng của con người để nhận biết liệu các bài báo là do mô hình sinh ra (được đo bằng tỷ lệ giữa số lần gán đúng và số lần gán không trung lập) giảm khi kích thước của mô hình tăng lên. Độ chính xác trên các đầu ra của mô hình đối chứng (một mô hình GPT-3 Small không điều kiện với độ ngẫu nhiên cao hơn) được chỉ ra bằng đường đứt điểm ở phía trên, và ngẫu nhiên (50%) được chỉ ra bằng đường đứt điểm ở phía dưới. Đường tốt nhất phù hợp là một hàm $y = ax^b$ (power function) với khoảng tin cậy 95%.

		95% Khoảng Tin Cậy	_t_so_sánh_với	mình_không_biết
	Độ chính xác trung bình	i Khoảng (thấp, cao)	đối_chứng (p-giá_trị)	gán
Đối chứng	88%	84%–91%	-	2.7%
GPT-3 175B	52%	48%–57%	12.7 (3.2_e_-23)	10.6%

Bảng 3.12: Khả năng của con người để nhận biết liệu các bài báo dài khoảng 500 từ có phải là do mô hình sinh ra (được đo bằng tỷ lệ giữa số lần gán đúng và số lần gán không trung lập) là 88% trên mô hình đối chứng và 52% trên GPT-3 175B. Bảng này hiển thị kết quả của phép thử t-student hai mẫu cho sự khác biệt giữa độ chính xác trung bình của GPT-3 175B và mô hình đối chứng (một mô hình GPT-3 Small không điều kiện với độ ngẫu nhiên cao hơn).

27

Tiêu đề: Giáo hội Giám lý United đồng ý chia tách lịch sử Phụ đề: Những người phản đối hôn nhân đồng giới sẽ thành lập giáo phái riêng Bài: Sau hai ngày tranh luận căng thẳng, Giáo hội Giám lý United đã đồng ý chia tách - một sự kiện dự kiến sẽ kết thúc bằng việc thành lập một giáo phái mới, "truyền thống và xã hội bảo thủ", theo tờ Washington Post. Phần lớn đại biểu tham dự cuộc họp hàng năm của Hội nghị Tổng của giáo hội vào tháng Năm đã bỏ phiếu để tăng cường lệnh cấm việc phong chức linh mục LGBTQ và viết các quy tắc mới sẽ "kỷ luật" các linh mục tổ chức lễ cưới đồng giới. Nhưng những người phản đối các biện pháp này có kế hoạch mới: Họ nói họ sẽ thành lập một giáo phái riêng vào năm 2020, gọi giáo phái của mình là Christian Methodist

Đoạn văn bản Markdown dưới đây đã được dịch từ tiếng Anh sang tiếng Việt. Lưu ý rằng thẻ Markdown và LaTeX đã được giữ nguyên.

Text: Khi tập dữ liệu huấn luyện của chúng tôi được lấy từ internet, có thể rằng mô hình của chúng tôi đã được huấn luyện trên một số tập kiểm tra chuẩn của chúng tôi. Việc phát hiện chính xác sự ô nhiễm từ các tập dữ liệu lớn quy mô internet là một lĩnh vực nghiên cứu mới chưa có phương pháp tốt nhất được thiết lập. Mặc dù việc huấn luyện

các mô hình lớn mà không điều tra về sự ô nhiễm là thực hành phổ biến, nhưng với quy mô ngày càng tăng của các tập dữ liệu tiền huấn luyện, chúng tôi tin rằng vấn đề này đang trở nên ngày càng quan trọng.

Lo ngại này không chỉ là lý thuyết. Một trong những bài báo đầu tiên huấn luyện mô hình ngôn ngữ trên dữ liệu Common Crawl [TL18] đã phát hiện và loại bỏ một tài liệu huấn luyện trùng lặp với một trong các tập dữ liệu đánh giá của họ. Các công trình khác như GPT-2 [RWC⁺ 19] cũng đã tiến hành phân tích trùng lặp sau khi huấn luyện. Kết quả nghiên cứu tương đối lạc quan, tìm thấy rằng

29

Dữ liệu đầu vào tiếng Anh kém: Tôi đã ăn những quả dâu tím. Dữ liệu đầu ra tiếng Anh tốt: Tôi đã ăn những quả dâu tím. Dữ liệu đầu vào tiếng Anh kém: Cảm ơn bạn đã chọn tôi làm nhà thiết kế của bạn. Tôi sẽ rất cảm kích. Dữ liệu đầu ra tiếng Anh tốt: Cảm ơn bạn đã chọn tôi làm nhà thiết kế của bạn. Tôi rất cảm kích. Dữ liệu đầu vào tiếng Anh kém: Những thay đổi đã được thực hiện. Hoặc tôi đã thực hiện sự thay đổi mà bạn yêu cầu. Hoặc tôi đã thay đổi những gì bạn muốn và thực hiện những điều chỉnh. Dữ liệu đầu ra tiếng Anh tốt: Những thay đổi đã được thực hiện. Hoặc tôi đã thực hiện sự thay đổi mà bạn yêu cầu. Hoặc tôi đã thay đổi những gì bạn

5 Hạn chế

GPT-3 và phân tích của chúng tôi về nó có một số hạn chế. Dưới đây, chúng tôi mô tả một số hạn chế này và đề xuất hướng nghiên cứu trong tương lai.

Đầu tiên, mặc dù GPT-3 có những cải thiện định lượng và định tính mạnh mẽ so với tiền nhiệm trực tiếp của nó là GPT-2, nó vẫn còn một số nhược điểm đáng kể trong việc tổng hợp văn bản và một số nhiệm vụ xử lý ngôn ngữ tự nhiên (NLP). Trong việc tổng hợp văn bản, mặc dù chất lượng tổng thể cao, nhưng GPT-3 vẫn đôi khi lặp lại ngữ nghĩa ở cấp độ tài liệu, mất sự nhất quán qua các đoạn văn dài, mâu thuẫn với chính mình và đôi khi chứa các câu hoặc đoạn văn không liên quan. Chúng tôi sẽ phát hành một bộ sưu tập gồm 500 mẫu không được kiểm duyệt để giúp cung cấp cái nhìn rõ ràng hơn về những hạn chế và ưu điểm của GPT-3 trong việc tổng hợp văn bản. Trong lĩnh vực các nhiệm vụ ngôn ngữ rời rạc, chúng tôi nhận thấy không chính thức rằng GPT-3 gặp khó khăn đặc biệt trong việc "phân tích vật lý thông thường", mặc dù nó hoạt động tốt trên một số tập dữ liệu (như PIQA [BZB⁺ 19]) kiểm tra lĩnh vực này. Đặc biệt, GPT-3 gặp khó khăn với các câu hỏi kiểu "Nếu tôi đặt phô mai vào tủ lạnh, nó có tan chảy không?". Về mặt định lượng, hiệu suất học trong ngữ cảnh của GPT-3 có một số khoảng cách đáng kể trên bộ benchmark của chúng tôi, như đã mô tả trong Phần 3, và đặc biệt là nó chỉ hơi tốt hơn

ngẫu nhiên khi được đánh giá một mẫu hoặc thậm chí học ít mẫu trên một số nhiệm vụ so sánh, như xác định liệu hai từ có được sử dụng cùng cách trong một câu, hoặc liệu một câu có hàm ý câu khác (WIC và ANLI tương ứng), cũng như trên một số nhiệm vụ hiểu nội dung khi đọc. Điều này đặc biệt đáng chú ý khi GPT-3 có hiệu suất học ít mẫu mạnh mẽ trên nhiều nhiệm vụ khác.

GPT-3 có một số hạn chế về mặt cấu trúc và thuật toán, có thể giải thích cho một số vấn đề trên. Chúng tôi tập trung vào việc khám phá hành vi học trong ngữ cảnh trong các mô hình tự hồi quy vì nó đơn giản để lấy mẫu và tính toán xác suất với loại mô hình này. Kết quả là các thí nghiệm của chúng tôi không bao gồm bất kỳ kiến trúc hai chiều nào hoặc các mục tiêu huấn luyện khác như làm sạch nhiễu. Đây là sự khác biệt đáng chú ý so với phần lớn các nghiên cứu gần đây, đã chứng minh cải thiện hiệu suất huấn luyện tinh chỉnh khi sử dụng các phương pháp này trên các mô hình ngôn ngữ tiêu chuẩn [RSR+19]. Do đó, quyết định thiết kế của chúng tôi có thể dẫn đến hiệu suất kém hơn trên các nhiệm vụ mà thực nghiệm cho thấy lợi ích từ kiến trúc hai chiều. Điều này có thể bao gồm các nhiệm vụ điền từ, nhiệm vụ đòi hỏi phải nhìn lại và so sánh hai nội dung, hoặc nhiệm vụ đòi hỏi phải đọc lại và cân nhắc kỹ lưỡng một đoạn văn dài trước khi tạo ra một câu trả lời ngắn gọn. Điều này có thể là một giải thích khả thi cho việc hiệu suất học ít mẫu của GPT-3 chậm hơn trên một số nhiệm vụ, như WIC (đòi hỏi so sánh cách sử dụng một từ trong hai câu), ANLI (đòi hỏi so sánh hai câu để xem liệu một câu có hàm ý câu kia không), và một số nhiệm vụ hiểu nội dung khi đọc (ví dụ: QuAC và RACE). Chúng tôi cũng giả thuyết, dựa trên các nghiên cứu trước đây, rằng một mô hình hai chiều lớn sẽ mạnh hơn trong việc huấn luyện tinh chỉnh so với GPT-3. Tạo ra một mô hình hai chiều ở quy mô của GPT-3, và/hoặc cố gắng áp dụng mô hình hai chiều với học ít hoặc không mẫu, là một hướng nghiên cứu đầy hứa hẹn trong tương lai, và có thể giúp đạt được "tốt nhất của cả hai thế giới".

Hạn chế cơ bản hơn của phương pháp chung được mô tả trong bài viết này - mở rộng quy mô bất kỳ mô hình tương tự ngôn ngữ (LM) nào, dù là tự hồi quy hay hai chiều - là nó có thể cuối cùng sẽ gặp phải (hoặc có thể đã gặp phải) giới hạn của

mục tiêu huấn luyện ban đầu. Mục tiêu hiện tại của chúng ta cân nhắc mỗi token đều bằng nhau và thiếu khái niệm về điều gì là quan trọng nhất để dự đoán và điều gì ít quan trọng hơn. [RRS20] chứng minh lợi ích của việc tùy chỉnh dự đoán cho các đối tượng quan tâm. Ngoài ra, với các mục tiêu tự giám sát, việc xác định nhiệm vụ phụ thuộc vào việc ép buộc nhiệm vụ mong muốn vào một vấn đề dự đoán, trong khi cuối cùng, các hệ thống ngôn ngữ hữu ích (ví dụ như trợ lý ảo) có thể được xem xét tốt hơn là thực hiện các hành động hướng mục tiêu thay vì chỉ dự đoán. Cuối cùng, các mô hình ngôn ngữ được huấn luyện trước lớn không được gắn kết với các lĩnh vực kinh nghiệm khác, như

video hoặc tương tác vật lý thực tế, và do đó thiếu rất nhiều thông tin về thế giới [BHT+ 20]. Vì tất cả những lý do này, việc mở rộng dự đoán tự giám sát thuần túy có thể sẽ gặp giới hạn, và việc bổ sung với một phương pháp khác có thể là cần thiết. Các hướng nghiên cứu đầy hứa hẹn trong lĩnh vực này có thể bao gồm việc học hàm mục tiêu từ con người [ZSW+ 19a], huấn luyện tinh chỉnh với học tăng cường, hoặc thêm các mô đun bổ sung như hình ảnh để cung cấp sự gắn kết và một mô hình tốt hơn về thế giới [CLY+ 19].

Một hạn chế khác ch

Dưới đây là bản dịch đoạn văn bản Markdown từ tiếng Anh sang tiếng Việt:

Text: Bất kỳ hoạt động gây hại cho xã hội nào dựa vào việc tạo ra văn bản đều có thể được tăng cường bởi những mô hình ngôn ngữ mạnh mẽ. Các ví dụ bao gồm thông tin sai lệch, thư rác, lừa đảo, lạm dụng quy trình pháp lý và chính phủ, viết luận văn học thuật giả mạo và kỹ thuật xã hội. Nhiều ứng dụng này bị giới hạn bởi khả năng của con người viết văn bản chất lượng cao. Những mô hình ngôn ngữ tạo ra văn bản chất lượng cao có thể giảm bớt các rào cản hiện tại để thực hiện các hoạt động này và tăng hiệu quả của chúng.

Tiềm năng sử dụng sai trái của mô hình ngôn ngữ tăng lên khi chất lượng tổng hợp văn bản cải thiện. Khả năng của GPT-3 tạo ra nhiều đoạn văn mà người ta khó phân biệt với văn bản do con người viết trong 3.9.4 đại diện cho một dấu mốc đáng lo ngại trong lĩnh vực này.

6.1.2 Phân Tích Đối Tượng Đe Dọa

Đối tượng đe dọa có thể được tổ chức dựa trên kỹ năng và nguồn lực, từ những đối tượng có kỹ năng và nguồn lực thấp hoặc vừa phải có thể xây dựng sản phẩm độc hại đến 'nguy cơ đe dọa kéo dài' (APT): nhóm có kỹ năng cao và nguồn lực tốt (ví dụ: được nhà nước tài trợ) với mục tiêu lâu dài [SBC+ 19].

Để hiểu cách đối tượng có kỹ năng thấp và trung bình nghĩ về mô hình ngôn ngữ, chúng tôi đã giám sát các diễn đàn và nhóm trò chuyện nơi chiến lược thông tin sai lệch, phân phối phần mềm độc hại và lừa đảo máy tính được thảo luận thường xuyên. Mặc dù chúng tôi đã tìm thấy nhiều thảo luận về việc sử dụng sai trái sau khi phát hành GPT-2 vào mùa xuân năm 2019, nhưng chúng tôi đã tìm thấy ít trường hợp thử nghiệm hơn và không có triển khai thành công kể từ đó. Thêm vào đó, những thảo luận về việc sử dụng sai trái này tương quan với sự chú ý của truyền thông về công nghệ mô hình ngôn ngữ. Từ đó, chúng tôi đánh giá rằng mối đe dọa từ việc sử dụng sai trái từ những đối tượng này không phải là tức thì, nhưng cải thiện đáng kể về độ tin cậy có thể thay đổi điều này.

Vì APTs thường không thảo luận về hoạt động của họ trong công khai, chúng tôi đã tham

vấn với các chuyên gia phân tích đe dọa về khả năng hoạt động của APTs liên quan đến việc sử dụng mô hình ngôn ngữ. Kể từ khi phát hành GPT-2, không có sự khác biệt rõ ràng nào trong hoạt động có thể thấy lợi ích từ việc sử dụng mô hình ngôn ngữ. Đánh giá là mô hình ngôn ngữ có thể không đáng đầu tư nguồn lực lớn vì chưa có chứng minh thuyết phục rằng các mô hình ngôn ngữ hiện tại tốt hơn nhiều so với phương pháp hiện tại để tạo ra văn bản, và vì các phương pháp "định hướng" hoặc "kiểm soát" nội dung của mô hình ngôn ngữ vẫn ở giai đoạn rất sớm.

6.1.3 Cơ Chế Khuyến Khích Ngoài

Mỗi nhóm đối tượng đe dọa cũng có một tập hợp các chiến lược, kỹ thuật và quy trình (TTPs) mà họ dựa vào để hoàn thành mục tiêu của mình. TTPs bị ảnh hưởng bởi các yếu tố kinh tế như khả năng mở rộng và dễ triển khai; lừa đảo qua điện tử rất phổ biến trong tất cả các nhóm vì nó cung cấp phương pháp triển khai phần mềm độc hại và đánh cắp thông tin đăng nhập với chi phí thấp, nỗ lực thấp và lợi nhuận cao. Sử dụng mô hình ngôn ngữ để tăng cường TTPs hiện tại sẽ có thể dẫn đến chi phí triển khai thấp hơn.

Dễ sử dụng là một khuyến khích khác đáng kể. Có cơ sở hạ tầng ổn định có tác động lớn đến việc áp dụng TTPs. Kết quả của mô hình ngôn ngữ là ngẫu nhiên, tuy nhiên, và mặc dù các nhà phát triển có thể hạn chế điều này (ví dụ: bằng cách sử dụng cắt top-k), họ không thể thực hiện một cách nhất quán mà không có phản hồi từ con người. Nếu một robot thông tin sai lệch trên mạng xã hội tạo ra kết quả đáng tin cậy 99% thời gian, nhưng tạo ra kết quả không mạch lạc 1% thời gian, điều này có thể giảm lượng lao động con người cần thiết để vận hành robot này. Nhưng vẫn cần con người để lọc kết quả, điều này hạn chế khả năng mở rộng của hoạt động.

Dựa trên phân tích của mô hình này và phân tích về đối tượng đe dọa và môi trường, chúng tôi nghi ngờ rằng các nhà nghiên cứu AI cuối cùng sẽ phát triển mô hình ngôn ngữ đủ nhất quán và kiểm soát được để thu hút sự quan tâm của các đối tượng độc hại. Chúng tôi dự đoán điều này sẽ giới thiệu thách thức cho cộng đồng nghiên cứu rộng lớn hơn, và hy vọng làm việc trên điều này thông qua sự kết hợp giữa nghiên cứu giảm thiểu, thử nghiệm và phối hợp với các nhà phát triển kỹ thuật khác.

35

6.2 Công Bằng, Biên Tệ Và Đại Diện

Những thiên lệch có trong dữ liệu huấn luyện có thể khiến mô hình tạo ra nội dung định kiến hoặc thiên vị. Điều này đáng lo ngại, vì thiên lệch của mô hình có thể gây hại cho người dân trong các nhóm liên quan theo nhiều cách khác nhau bằng cách củng cố các định kiến hiện tại và tạo ra những biểu diễn hạ thấp, cùng với các thiệt hại tiềm năng khác

[Cra17]. Chúng tôi đã tiến hành phân tích về thiên lệch trong mô hình để hiểu rõ hơn về giới hạn của GPT-3 khi nói đến công bằng, thiên lệch và đại diện.

Mục tiêu của chúng tôi không phải là mô tả đầy đủ GPT-3, mà là đưa ra phân tích ban đầu về một số giới hạn và hành vi của nó. Chúng tôi tập trung vào thiên lệch liên quan đến giới tính, chủng tộc và tôn giáo, mặc dù nhiều loại thiên lệch khác có thể hiện diện và có thể được nghiên cứu trong công việc tiếp theo. Đây là phân tích ban đầu và không phản ánh tất cả các thiên lệch của mô hình, ngay cả trong các danh mục được nghiên cứu.

Tổng quát而言，该翻译准确地遵循了指示，保留了Markdown和LaTeX的结构，并且正确地翻译了文本内容。如果有任何特定术语或进一步的要求，请告知我以便进行适当的调整。请问您是否需要后续部分进行翻译或其他帮助？

Trong nghiên cứu về thiên vị giới tính trong mô hình GPT-3, chúng tôi đã tập trung vào mối liên hệ giữa giới tính và nghề nghiệp. Chúng tôi phát hiện ra rằng, nói chung, nghề nghiệp có xác suất cao hơn được tiếp theo bởi một định danh giới tính nam hơn là nữ (tức là chúng có xu hướng nam tính) khi được đưa ra trong ngữ cảnh như "The { nghề nghiệp } là" (Phiên bản Trung lập). 83% trong số 388 nghề nghiệp mà chúng tôi đã kiểm tra đều có xác suất cao hơn được tiếp theo bởi một định danh giới tính nam bởi GPT-3. Chúng tôi đo lường điều này bằng cách cho mô hình ngữ cảnh như "The detective was a" và sau đó xem xét xác suất của mô hình tiếp theo với những từ chỉ nam (ví dụ: man, male v.v.) hoặc từ chỉ nữ (woman, female v.v.).

Thực tế, nghề nghiệp đòi hỏi trình độ giáo dục cao hơn như nghị sĩ, ngân hàng gia, hoặc giáo sư danh dự đều có xu hướng nam tính mạnh mẽ, cùng với những nghề nghiệp đòi hỏi lao động thể chất nặng nhọc như thợ xây, thợ máy, và trưởng công an. Những nghề nghiệp có xác suất cao hơn được tiếp theo bởi định danh giới tính nữ bao gồm y tá đỡ đầu, y tá, lễ tân, quản gia v.v.

Chúng tôi cũng đã kiểm tra cách xác suất này thay đổi khi chúng tôi chuyển ngữ cảnh sang "The competent { nghề nghiệp } was a" (Phiên bản Giỏi) và "The incompetent { nghề nghiệp } was a" (Phiên bản Kém). Chúng tôi phát hiện ra rằng, khi được kích hoạt với "The competent { nghề nghiệp } was a," phần lớn nghề nghiệp có xác suất cao hơn được tiếp theo bởi một định danh giới tính nam hơn nữ so với ngữ cảnh trung lập ban đầu "The { nghề nghiệp } was a". Với ngữ cảnh "The incompetent { nghề nghiệp } was a" phần lớn nghề nghiệp vẫn có xu hướng nam với xác suất tương tự như ngữ cảnh trung lập ban đầu. Trung bình thiên vị nghề nghiệp - được đo lường như $n \log(P_{\text{nam}} / P_{\text{nữ}})$ (nam^{female} / Ngữ cảnh)) - là -1.11 cho phiên bản trung lập, -2.14 cho phiên bản giỏi và -1.15 cho phiên bản kém.

Chúng tôi cũng đã thực hiện giải quyết đại từ trên tập dữ liệu Winogender [RNLVD18]

bằng hai phương pháp, giúp xác nhận xu hướng của mô hình liên kết hầu hết nghề nghiệp với nam giới. Một phương pháp đo lường khả năng chính xác của mô hình trong việc gán đúng đại từ cho nghề nghiệp hoặc người tham gia. Ví dụ, chúng tôi đã cho mô hình ngữ cảnh như "The advisor met with the advisee because she wanted to get advice about job applications. 'She' refers to the" và tìm ra lựa chọn có xác suất thấp nhất giữa hai lựa chọn có thể (Lựa chọn giữa tùy chọn nghề nghiệp: advisor; tùy chọn người tham gia: advisee).

Nghề nghiệp

Chúng tôi đã nghiên cứu những từ nào đồng xuất hiện với các thuật ngữ tôn giáo liên quan đến Atheism, Buddhism, Christianity, Hinduism, Islam và Judaism bằng cách tạo ra 800 kết quả đầu ra của mô hình có độ dài khoảng 50 với nhiệt độ là 1 và top p là 0.9 cho mỗi prompt. Các prompt của chúng tôi có dạng "`{_ Religion practitioners _}`" là (VD: "Christians là") cho mỗi trong sáu loại tôn giáo được liệt kê trên đây. Sau đó, chúng tôi cho phép mô hình tự nhiên hoàn thành các câu và tạo ra một bộ sưu tập các kết quả hoàn thành này để nghiên cứu sự đồng xuất hiện của từ.

Dưới đây là một ví dụ về kết quả đầu ra từ mô hình:

"Buddhists là chia thành hai nhánh chính - Theravada và Mahayana. Theravada là nhánh bảo thủ hơn, tập trung vào cuộc sống tu hành và những kinh điển sớm nhất và từ chối công nhận những kinh điển Mahayana sau này là chính thống."

Tương tự như vấn đề sắc tộc, chúng tôi phát hiện rằng các mô hình tạo ra mối liên kết với các thuật ngữ tôn giáo thể hiện một xu hướng nhất định phản ánh cách mà những thuật ngữ này đôi khi được trình bày trong thế giới thực. Ví dụ, với tôn giáo Islam, chúng tôi phát hiện rằng các từ như `ramadan`, `prophet` và `mosque` đồng xuất hiện ở mức độ cao hơn so với các tôn giáo khác. Chúng tôi cũng phát hiện rằng các từ như `violent`, `terrorism` và `terrorist` đồng xuất hiện ở mức độ cao hơn với Islam so với các tôn giáo khác và nằm trong top 40 từ được ưa chuộng nhất cho Islam trong GPT-3.

38

6.2.4 Thách thức về thiên lệch và công bằng trong tương lai

Chúng tôi đã trình bày phân tích ban đầu này để chia sẻ một số thiên lệch mà chúng tôi tìm thấy nhằm khích lệ nghiên cứu tiếp theo và nhấn mạnh những khó khăn nội tại trong việc xác định thiên lệch trong các mô hình sinh tổng hợp quy mô lớn; chúng tôi dự đoán đây sẽ là lĩnh vực nghiên cứu liên tục đối với chúng tôi và rất hào hứng để thảo luận về

các phương pháp luận khác nhau với cộng đồng. Chúng tôi xem công việc trong phần này như là dấu hiệu chỉ dẫn chủ quan - chúng tôi chọn giới tính, sắc tộc và tôn giáo như điểm bắt đầu, nhưng chúng tôi nhận thức được tính chủ quan nội tại trong lựa chọn này. Công việc của chúng tôi được truyền cảm bởi các nghiên cứu về việc xác định các thuộc tính của mô hình để phát triển nhãn thông tin như Card mô hình Báo cáo từ [MWZ⁺ 18].

Cuối cùng, điều quan trọng không chỉ là xác định thiên lệch trong hệ thống ngôn ngữ mà còn phải can thiệp. Văn bản về vấn đề này cũng rất phong phú [QMZH19, HZJ⁺ 19], nên chúng tôi chỉ đưa ra một vài nhận xét ngắn gọn về hướng phát triển cụ thể dành cho các mô hình ngôn ngữ lớn. Để mở đường cho việc phòng ngừa thiên lệch hiệu quả trong các mô hình mục đích chung, cần xây dựng một từ vựng chung kết nối giữa các thách thức về mặt quy phạm, kỹ thuật và thực nghiệm trong việc giảm thiểu thiên lệch cho các mô hình này. Có nhiều tiềm năng cho nghiên cứu tiếp cận với văn bản bên ngoài lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), diễn đạt rõ ràng hơn các tuyên bố về mặt quy phạm về tổn hại, và tiếp cận với trải nghiệm thực tế của các cộng đồng bị ảnh hưởng bởi các hệ thống NLP [BBDIW20]. Do đó, công việc giảm thiểu không nên được tiếp cận chỉ với mục tiêu dựa trên chỉ số để "loại bỏ" thiên lệch vì điều này đã được chứng minh là có điểm mù [GG19, NvNvdG19] mà cần được tiếp cận một cách toàn diện.

6.3 Sử dụng năng lượng

Đào tạo tiền huấn luyện quy mô lớn đòi hỏi lượng lớn tính toán, điều này tiêu tốn năng lượng: đào tạo GPT-3 175B đã tiêu thụ hàng nghìn petaflop/s-ngày tính toán trong quá trình tiền huấn luyện, so với hàng chục petaflop/s-ngày cho mô hình GPT-2 1.5 tỷ tham số (Hình 2.2). Điều này có nghĩa là chúng ta nên nhận thức về chi phí và hiệu quả của các mô hình như vậy, như được đề xuất bởi [SDSE19].

Sử dụng đào tạo tiền huấn luyện quy mô lớn cũng cung cấp góc nhìn khác về hiệu quả của các mô hình lớn - chúng ta nên xem xét không chỉ nguồn lực được sử dụng trong đào tạo chúng, mà còn cách nguồn lực này được phân bổ lại suốt thời gian tồn tại của mô hình, sau đó sẽ được sử dụng cho nhiều mục đích khác nhau và huấn luyện tinh chỉnh cho các nhiệm vụ cụ thể. Mặc dù các mô hình như GPT-3 tiêu thụ nguồn lực đáng kể trong quá trình đào tạo, chúng có thể trở nên hiệu quả bất ngờ sau khi được đào tạo: ngay cả với GPT-3 175B đầy đủ, việc tạo ra 100 trang nội dung từ một mô hình đã được đào tạo có thể tiêu tốn khoảng 0.4 kW-hr, hoặc chỉ vài xu trong chi phí năng lượng. Ngoài ra, các kỹ thuật như huấn luyện tinh chỉnh mô hình [LHCG19a] có thể giúp giảm chi phí của các mô hình như vậy, cho phép chúng tôi áp dụng một mô hình đào tạo đơn, quy mô lớn, sau đó tạo ra các phiên bản hiệu quả hơn của chúng để sử dụng trong các ngữ cảnh phù hợp. Tiến bộ thuật toán cũng có thể tự nhiên tăng cường hiệu quả của các mô hình như vậy theo thời gian, tương tự như xu hướng được quan sát trong nhận dạng hình ảnh

7 Công việc liên quan

Dưới đây là phiên bản dịch từ tiếng Anh sang tiếng Việt của đoạn văn bản Markdown trên, tuân thủ các quy tắc đã đề cập:

Text: Nhiều lĩnh vực nghiên cứu đã tập trung vào việc tăng số tham số và/hoặc tính toán trong mô hình ngôn ngữ với mục tiêu cải thiện hiệu suất sinh ra hoặc hiệu suất thực hiện nhiệm vụ. Một công trình sớm đã mở rộng mô hình ngôn ngữ dựa trên LSTM lên hơn một tỷ tham số [JVS⁺ 16]. Một hướng nghiên cứu đơn giản hóa việc tăng kích thước của mô hình biến đổi, mở rộng tham số và FLOPS-per-token tương đối đồng đều. Công trình trong lĩnh vực này đã lần lượt tăng kích thước mô hình: 213 triệu tham số [VSP⁺ 17] trong bài báo gốc, 300 triệu tham số [DCLT18], 1,5 tỷ tham số [RWC⁺ 19], 8 tỷ tham số [SPP⁺ 19], 11 tỷ tham số [RSR⁺ 19], và gần đây nhất là 17 tỷ tham số [Tur20]. Một hướng nghiên cứu khác tập trung vào việc tăng số tham số nhưng không tăng tính toán, nhằm mục đích tăng khả năng lưu trữ thông tin của mô hình mà không tăng chi phí tính toán. Các phương pháp này dựa trên khung công nghệ tính toán điều kiện [BLC13] và cụ thể, phương pháp hỗn hợp chuyên gia [SMM⁺ 17] đã được sử dụng để tạo ra các mô hình 100 tỷ tham số và gần đây nhất là các mô hình dịch 50 tỷ tham số [AJF19], mặc dù chỉ một phần nhỏ của tổng số tham số được sử dụng trong mỗi lần truyền xuôi. Một hướng tiếp cận thứ ba tăng tính toán mà không tăng số tham số; ví dụ về hướng này bao gồm thời gian tính toán thích nghi [Gra16] và biến đổi phổ quát [DGV⁺ 18]. Công trình của chúng tôi tập trung vào hướng đầu tiên (tăng tính toán và tham số cùng nhau bằng cách đơn giản làm lớn mạng thần kinh), và tăng kích thước mô hình gấp 10 lần so với các mô hình trước đó sử dụng chiến lược này.

Nhiều nỗ lực cũng đã nghiên cứu hệ thống về tác động của quy mô đối với hiệu suất của mô hình ngôn ngữ. [KMH⁺ 20, RRBS19, LWS⁺ 20, HNA⁺ 17] tìm thấy xu hướng đường cong hàm mất mát theo quy mô tăng lên của mô hình tự hồi quy. Công trình này cho thấy rằng xu hướng này tiếp tục khi mô hình tiếp tục tăng quy mô (mặc dù có thể phát hiện sự uốn cong nhẹ của đường cong trong Hình 3.1), và chúng tôi cũng tìm thấy tăng dần mượt mà trong nhiều (nhưng không phải tất cả) nhiệm vụ phụ thuộc ở quy mô 3 đơn vị.

Một hướng nghiên cứu khác đi ngược lại hướng mở rộng, cố gắng bảo tồn hiệu suất mạnh mẽ trong các mô hình ngôn ngữ nhỏ nhất có thể. Hướng này bao gồm ALBERT [LCG⁺ 19] cũng như các phương pháp tổng quát [HVD15] và

kiến trúc và kỹ thuật này có thể hỗ trợ cho công trình của chúng tôi, và có thể được áp dụng để giảm độ trễ và dấu chân bộ nhớ của các mô hình khổng lồ.

Khi các mô hình ngôn ngữ được huấn luyện tinh chỉnh đã đạt đến hiệu suất gần con người trên nhiều nhiệm vụ chuẩn, rất nhiều nỗ lực đã được dành để xây dựng các nhiệm vụ khó khăn hoặc mở rộng, bao gồm trả lời câu hỏi [KPR⁺ 19, IBGC⁺ 14, CCE⁺ 18, MCKS18], hiểu nội dung khi đọc [CHI⁺ 18, RCM19], và các tập dữ liệu được thiết kế đối kháng nhằm gây khó khăn cho các mô hình ngôn ngữ hiện tại [SBBC19, NWD⁺ </p></div>
<div data-bbox="92 230 906 295" data-label="Text"><p>Tom Brown, Ben Mann, Prafulla Dhariwal, Dario Amodei, Nick Ryder, Daniel M Ziegler, và Jeffrey Wu đã triển khai các mô hình lớn, hạ tầng đào tạo và chiến lược song song của mô hình.</p></div>
<div data-bbox="92 311 903 355" data-label="Text"><p>Tom Brown, Dario Amodei, Ben Mann, và Nick Ryder đã thực hiện các thí nghiệm tiền huấn luyện.</p></div>
<div data-bbox="92 372 910 414" data-label="Text"><p>Ben Mann và Alec Radford đã thu thập, lọc, loại bỏ trùng lặp và phân tích chồng lấn trên dữ liệu huấn luyện.</p></div>
<div data-bbox="92 432 905 497" data-label="Text"><p>Melanie Subbiah, Ben Mann, Dario Amodei, Jared Kaplan, Sam McCandlish, Tom Brown, Tom Henighan, và Girish Sastry đã triển khai các nhiệm vụ phía dưới và khung phần mềm hỗ trợ chúng, bao gồm cả việc tạo ra các nhiệm vụ tổng hợp.</p></div>
<div data-bbox="92 515 905 579" data-label="Text"><p>Jared Kaplan và Sam McCandlish ban đầu dự đoán rằng một mô hình ngôn ngữ khổng lồ nên thể hiện lợi ích tiếp tục và áp dụng các quy luật mở rộng để giúp dự đoán và hướng dẫn quyết định mở rộng mô hình và dữ liệu cho nghiên cứu.</p></div>
<div data-bbox="92 597 847 616" data-label="Text"><p>Ben Mann đã triển khai việc lấy mẫu mà không thay thế trong quá trình huấn luyện.</p></div>
<div data-bbox="92 634 853 653" data-label="Text"><p>Alec Radford ban đầu chứng minh rằng học ít mẫu xảy ra trong mô hình ngôn ngữ.</p></div>
<div data-bbox="92 671 905 736" data-label="Text"><p>Jared Kaplan và Sam McCandlish đã chứng minh rằng các mô hình lớn học nhanh hơn trong ngữ cảnh và nghiên cứu hệ thống về đường cong học ngữ cảnh, việc nhắc nhiệm vụ và phương pháp đánh giá.</p></div>
<div data-bbox="92 753 901 795" data-label="Text"><p>Prafulla Dhariwal đã triển khai phiên bản sớm của bộ mã nguồn và phát triển tối ưu hóa bộ nhớ cho việc đào tạo nửa độ chính xác hoàn toàn.</p></div>
<div data-bbox="92 812 898 854" data-label="Text"><p>Rewon Child và Mark Chen đã phát triển phiên bản sớm của chiến lược song song của mô hình.</p></div>
<div data-bbox="92 872 722 892" data-label="Text"><p>Rewon Child và Scott Gray đã đóng góp mô hình biến đổi thừa thớt.</p></div>
<div data-bbox="92 909 908 929" data-label="Text"><p>Aditya Ramesh đã thử nghiệm với các chiến lược cân bằng mất mát cho tiền huấn luyện.</p></div>

Melanie Subbiah và Arvind Neelakantan đã triển khai, thử nghiệm và kiểm tra tìm kiếm chùm.

Pranav Shyam đã làm việc trên SuperGLUE và hỗ trợ kết nối với tài liệu về học ít mẫu và học siêu.

Sandhini Agarwal đã tiến hành phân tích công bằng và đại diện.

Girish Sastry và Amanda Askell đã tiến hành đánh giá của con người đối với mô hình.

Ariel Herbert-Voss đã tiến hành phân tích mối đe dọa về việc sử dụng ác ý.

Gretchen Krueger đã chỉnh sửa và đánh giá đồ phần về chính sách của bài báo.

Benjamin Chess, Clemens Winter, Eric Sigler, Christopher Hesse, Mateusz Litwin, và Christopher Berner đã tối ưu hóa cụm của OpenAI để chạy các mô hình lớn hiệu quả.

Scott Gray đã phát triển các nhân GPU nhanh được sử dụng trong quá trình huấn luyện.

Jack Clark đã lãnh đạo phân tích về tác động đạo đức – công bằng và đại diện, đánh giá của con người đối với mô hình, và phân tích tác động rộng lớn, và tư vấn cho Gretchen, Amanda, Girish, Sandhini, và Ariel về công việc của họ.

Dario Amodei, Alec Radford, Tom Brown, Sam McCandlish, Nick Ryder, Jared Kaplan, Sandhini Agarwal, Amanda Askell, Girish Sastry, và Jack Clark đã viết bài báo.

Sam McCandlish đã lãnh đạo phân tích về mở rộng mô hình và tư vấn cho Tom Henighan và Jared Kaplan về công việc của họ.

Alec Radford đã tư vấn cho dự án từ góc nhìn xử lý ngôn ngữ tự nhiên, đề xuất các nhiệm vụ, đặt kết quả vào ngữ cảnh và chứng minh lợi ích của giảm trọng lượng khi đào tạo.

Ilya Sutskever đã là một nhà ủng hộ sớm cho việc mở rộng các mô hình khả năng sinh ra, và tư vấn cho Pranav, Prafulla, Rewon, Alec, và Aditya về công việc của họ.

Dario Amodei đã thiết kế và lãnh đạo nghiên cứu.

Chi tiết về Lọc Dữ liệu Common Crawl

Như đã đề cập trong Phần 2.2, chúng tôi đã sử dụng hai kỹ thuật để cải thiện chất lượng của tập dữ liệu Common Crawl: (1) lọc Common Crawl và (2) loại bỏ trùng lặp mờ:

1. Để cải thiện chất lượng của Common Crawl, chúng tôi đã phát triển một phương pháp lọc tự động để loại bỏ các tài liệu chất lượng thấp. Sử dụng WebText gốc như một đại diện cho các tài liệu chất lượng cao, chúng tôi đã huấn luyện một phân loại viên để phân biệt chúng với Common Crawl thô. Sau đó, chúng tôi đã sử dụng phân loại viên này để tái lấy mẫu Common Crawl bằng cách ưu tiên các tài liệu mà phân loại viên dự đoán là có chất lượng cao hơn. Phân loại viên được huấn luyện sử dụng phân loại viên hồi quy logistics với các tính năng từ bộ phân loại chuẩn của Spark và HashingTF¹⁰. Đối với các ví dụ dương, chúng tôi đã sử dụng một tập hợp các tập dữ liệu đã được quản lý như WebText, Wikipedia, và tập dữ liệu sách web của chúng tôi như ví dụ dương, và đối với các ví dụ âm, chúng tôi đã sử dụng Common Crawl chưa được lọc. Chúng tôi đã sử dụng phân loại viên này để điểm số các tài liệu Common Crawl. Chúng tôi đã giữ lại mỗi tài liệu trong tập dữ liệu của mình nếu

```
np.random.pareto( $\alpha$ ) > 1 - điểm số tài liệu
```

Chúng tôi đã chọn $\alpha = 9$ để lấy chủ yếu các tài liệu mà phân loại viên đã đánh giá cao, nhưng vẫn bao gồm một số tài liệu nằm ngoài phân phối. α đã được chọn để phù hợp với phân phối điểm số từ phân loại viên của chúng tôi trên WebText. Chúng tôi đã phát hiện rằng việc cân nhắc lại này đã tăng chất lượng như được đo bằng mất mát trên một loạt các mẫu văn bản sinh ra nằm ngoài phân phối.

2. Để cải thiện chất lượng mô hình và ngăn chặn quá mức khớp (mà trở nên ngày càng quan trọng hơn khi khả năng của mô hình tăng lên), chúng tôi đã loại bỏ trùng lặp mờ tài liệu (tức là loại bỏ các tài liệu có chồng lấn cao với các tài liệu khác) trong mỗi tập dữ liệu sử dụng thực hiện MinHashLSH của Spark với 10 hàm hash, sử dụng cùng các tính năng đã được sử dụng cho phân loại ở trên. Chúng tôi cũng đã loại bỏ WebText khỏi Common Crawl một cách mờ. Tổng cộng điều này đã giảm kích thước tập dữ liệu trung bình 10%.

Sau khi lọc trùng lặp và chất lượng, chúng tôi cũng đã loại bỏ một phần văn bản xuất hiện trong các tập dữ liệu chuẩn, được mô tả trong Phụ lục C.

Chi tiết về Huấn luyện Mô hình

Để huấn luyện tất cả các phiên bản của GPT-3, chúng tôi sử dụng Adam với $\beta_1 = 0.9$, $\beta_2 = 0.95$, và $\epsilon = 10^{-8}$, chúng tôi cắt tỉ lệ toàn cục của gradient tại 1.0, và chúng tôi sử dụng suy giảm cosin cho tốc độ học xuống còn 10% giá trị ban đầu, qua 260 tỷ token

(sau 260 tỷ token, huấn luyện tiếp tục tại 10% tốc độ học ban đầu). Có một giai đoạn ấm dần tuyến tính tốc độ học qua 375 triệu token đầu tiên. Chúng tôi cũng tăng dần kích thước lô tuyến tính từ một giá trị nhỏ (32k token

Trong mục 4, chúng tôi đã đưa ra cái nhìn tổng quan cấp cao về các nghiên cứu nhằm bản tập kiểm tra. Trong mục này, chúng tôi cung cấp chi tiết về phương pháp luận và kết quả.

Lọc tập huấn luyện ban đầu Chúng tôi đã cố gắng loại bỏ văn bản xuất hiện trong các benchmark khỏi dữ liệu huấn luyện bằng cách tìm kiếm sự trùng lặp 13-gram giữa tất cả các tập kiểm tra/phát triển được sử dụng trong công trình này và dữ liệu huấn luyện của chúng tôi, và chúng tôi đã loại bỏ 13-gram trùng khớp cũng như một cửa sổ 200 ký tự xung quanh nó, chia tài liệu gốc thành các phần. Với mục đích lọc, chúng tôi định nghĩa một gram là một từ viết thường, được phân tách bằng khoảng trắng và không có dấu câu. Các phần có độ dài dưới 200 ký tự đã bị loại bỏ. Các tài liệu được chia thành hơn 10 phần được coi là bị nhiễm bẩn và

10 <https://spark.apache.org/docs/latest/api/python/pyspark.ml.html#pyspark.ml.feature.HashingTF>

43

đã bị loại bỏ hoàn toàn. Ban đầu, chúng tôi đã loại bỏ toàn bộ tài liệu khi có một va chạm duy nhất, nhưng điều đó đã phạt quá nặng các tài liệu dài như sách vì lỗi dương tính giả. Một ví dụ về dương tính giả có thể là một tập kiểm tra dựa trên Wikipedia, trong đó bài viết trên Wikipedia trích dẫn một dòng duy nhất từ một cuốn sách. Chúng tôi đã bỏ qua các 13-gram trùng khớp với hơn 10 tài liệu huấn luyện, vì kiểm tra cho thấy phần lớn các 13-gram này chứa các cụm từ văn hóa phổ biến, các điều khoản pháp lý tiêu chuẩn hoặc nội dung tương tự mà chúng tôi có thể muốn mô hình học, thay vì các sự trùng lặp cụ thể không mong muốn với các tập kiểm tra. Các ví dụ về các tần số khác nhau có thể được tìm thấy trong kho lưu trữ phát hành GPT-3¹¹.

Phương pháp luận trùng lặp Đối với phân tích sự trùng lặp benchmark của chúng tôi trong Mục 4, chúng tôi đã sử dụng một số lượng từ N thay đổi để kiểm tra sự trùng lặp cho mỗi tập dữ liệu, trong đó N là độ dài ví dụ ở phân vị thứ 5 tính bằng từ, bỏ qua tất cả dấu câu, khoảng trắng và chữ hoa/thường. Do các va chạm giả ở các giá trị N thấp hơn, chúng tôi sử dụng giá trị tối thiểu là 8 cho các tác vụ không tổng hợp. Vì lý do hiệu suất, chúng tôi đặt giá trị tối đa là 13 cho tất cả các tác vụ. Các giá trị cho N và lượng dữ liệu được đánh dấu là bản được hiển thị trong Bảng C.1. Không giống như việc GPT-2 sử dụng bộ lọc Bloom để tính toán giới hạn xác suất cho sự nhiễm bẩn của tập kiểm tra, chúng tôi đã sử dụng Apache Spark để tính toán các va chạm chính xác trên tất cả các tập huấn luyện và kiểm tra. Chúng tôi tính toán sự trùng lặp giữa các tập kiểm tra và toàn

bộ kho ngữ liệu huấn luyện của chúng tôi, mặc dù chúng tôi chỉ huấn luyện trên 40% các tài liệu Common Crawl đã được lọc của chúng tôi theo Mục 2.2.

Chúng tôi định nghĩa một ví dụ 'bẩn' là một ví dụ có bất kỳ sự trùng lặp N -gram nào với bất kỳ tài liệu huấn luyện nào, và một ví dụ 'sạch' là một ví dụ không có va chạm.

Các phân tách kiểm tra và xác thực có mức độ nhiễm bẩn tương tự mặc dù một số phân tách kiểm tra chưa được gán nhãn. Do một lỗi được phát hiện bởi phân tích này, quá trình lọc được mô tả ở trên đã thất bại đối với các tài liệu dài như sách. Vì các cân nhắc về chi phí, không khả thi để huấn luyện lại mô hình trên một phiên bản đã sửa lỗi của tập dữ liệu huấn luyện. Do đó, một số benchmark mô hình ngôn ngữ cộng với Children's Book Test cho thấy sự trùng lặp gần như hoàn toàn, và do đó không được đưa vào bài báo này. Các sự trùng lặp được hiển thị trong Bảng C.1.

Kết quả trùng lặp Để hiểu việc đã thấy một phần dữ liệu giúp mô hình hoạt động như thế nào trên các tác vụ tiếp theo, chúng tôi lọc mọi tập xác thực và kiểm tra theo mức độ bẩn. Sau đó, chúng tôi chạy đánh giá trên các ví dụ chỉ sạch và báo cáo phần trăm thay đổi tương đối giữa điểm sạch và điểm gốc. Nếu điểm sạch kém hơn 1% hoặc 2% so với điểm tổng thể, điều đó cho thấy mô hình có thể đã quá khớp với các ví dụ mà nó đã thấy. Nếu điểm sạch *tốt hơn* đáng kể, phương pháp lọc của chúng tôi có thể đã ưu tiên đánh dấu các ví dụ dễ hơn là bẩn.

Chỉ số trùng lặp này có xu hướng cho thấy tỷ lệ dương tính giả cao đối với các tập dữ liệu chứa thông tin nền (nhưng không phải câu trả lời) được lấy từ web (chẳng hạn như SQuAD, lấy từ Wikipedia) hoặc các ví dụ dài dưới 8 từ, mà chúng tôi đã bỏ qua trong quá trình lọc của mình (ngoại trừ các tác vụ xáo trộn từ). Một trường hợp mà kỹ thuật này dường như không đưa ra tín hiệu tốt là DROP, một tác vụ hiểu nội dung khi đọc trong đó 94% các ví dụ là bẩn. Thông tin cần thiết để trả lời câu hỏi nằm trong một đoạn văn được cung cấp cho mô hình, vì vậy việc đã thấy đoạn văn trong quá trình huấn luyện nhưng không thấy các câu hỏi và câu trả lời không thực sự cấu thành hành vi gian lận. Chúng tôi đã xác nhận rằng mọi tài liệu huấn luyện trùng khớp chỉ chứa đoạn văn nguồn, và không chứa bất kỳ câu hỏi và câu trả lời nào trong tập dữ liệu. Giải thích hợp lý hơn cho sự giảm hiệu suất là 6% các ví dụ còn lại sau khi lọc đến từ một phân phối hơi khác so với các ví dụ bẩn.

Hình 4.2 cho thấy rằng khi tập dữ liệu càng bị nhiễm bẩn, phương sai của tỷ lệ sạch/tất cả tăng lên, nhưng không có xu hướng rõ ràng nào cho thấy hiệu suất được cải thiện hay suy giảm. Điều này cho thấy GPT-3 tương đối không nhạy cảm với sự nhiễm bẩn. Xem Mục 4 để biết chi tiết về các tập dữ liệu chúng tôi đã gắn cờ để xem xét thêm.

Tên	Phân tách	Chỉ số	<i>N</i>	Độ chính xác/ F1/ BLEU	Tổng số lượng	Độ chính xác/ F1/ BLEU bản	Số lượng bản	Độ chính xác/ F1/ BLEU sạch
Quac	dev	f1	13	44.3	7353	44.3	7315	54.1
SQuADv2	dev	f1	13	69.8	11873	69.9	11136	68.4
DROP	dev	f1	13	36.5	9536	37.0	8898	29.5
Symbol Insertion	dev	acc	7	66.9	10000	66.8	8565	67.1
CoQa	dev	f1	13	86.0	7983	85.3	5107	87.1
ReCoRD	dev	acc	13	89.5	10000	90.3	6110	88.2
Winograd	test	acc	9	88.6	273	90.2	164	86.2
BoolQ	dev	acc	13	76.0	3270	75.8	1955	76.3
MultiRC	dev	acc	13	74.2	953	73.4	558	75.3
RACE-h	test	acc	13	46.8	3498	47.0	1580	46.7
LAMBADA	test	acc	13	86.4	5153	86.9	2209	86.0
LAMBADA (No Blanks)	test	acc	13	77.8	5153	78.5	2209	77.2
WSC	dev	acc	13	76.9	104	73.8	42	79.0
PIQA	dev	acc	8	82.3	1838	89.9	526	79.3

RACE-m	test	acc	13	58.5	1436	53.0	366	60.4
De_→_En 16	test	bleu-sb	12	43.0	2999	47.4	739	40.8
En_→_De 16	test	bleu-sb	12	30.9	2999	32.6	739	29.9
En_→_Ro 16	test	bleu-sb	12	25.8	1999	24.9	423	26.1
Ro_→_En 16	test	bleu-sb	12	41.3	1999	40.4	423	41.6
WebQs	test	acc	8	41.5	2032	41.6	428	41.5
ANLI R1	test	acc	13	36.8	1000	40.5	200	35.9
ANLI R2	test	acc	13	34.0	1000	29.4	177	35.0
TriviaQA	dev	acc	10	71.2	7993	70.8	1390	71.3
ANLI R3	test	acc	13	40.2	1200	38.3	196	40.5
En_→_Fr 14	test	bleu-sb	13	39.9	3003	38.3	411	40.3
Fr_→_En 14	test	bleu-sb	13	41.4	3003	40.9	411	41.4
WiC	dev	acc	13	51.4	638	53.1	49	51.3
RTE	dev	acc	13	71.5	277	71.4	21	71.5
CB	dev	acc	13	80.4	56	100.0	4	78.8
Anagrams 2	dev	acc	2	40.2	10000	76.2	705	37.4

Reversed Words	dev	acc	2	0.4	10000	1.5	660	0.3
OpenBookQA	test	acc	8	65.4	500	58.1	31	65.9
ARC (Easy)	test	acc	11	70.1	2268	77.5	89	69.8
Anagrams 1	dev	acc	2	15.0	10000	49.8	327	13.8
COPA	dev	acc	9	93.0	100	100.0	3	92.8
ARC (Challenge)	test	acc	12	51.6	1144	45.2	31	51.8
HellaSwag	dev	acc	13	79.3	10042	86.2	152	79.2
NQs	test	acc	11	29.9	3610	32.7	52	29.8
Cycled Letters	dev	acc	2	38.6	10000	20.5	73	38.7
SAT Analogies	dev	acc	9	65.8	374	100.0	2	65.6
StoryCloze	test	acc	13	87.7	1871	100.0	2	87.6
Winogrande	dev	acc	13	77.7	1267	-	0	77.7

Bảng C.1: Thống kê trùng lặp cho tất cả các tập dữ liệu được sắp xếp từ bẩn nhất đến sạch nhất. Chúng tôi coi một ví dụ trong tập dữ liệu là bẩn nếu nó có một va chạm N -gram duy nhất với bất kỳ tài liệu nào trong kho ngữ liệu huấn luyện của chúng tôi. “Chênh lệch tương đối Sạch so với Tất cả” cho thấy phần trăm thay đổi về hiệu suất giữa chỉ các ví dụ sạch so với tất cả các ví dụ trong benchmark. “Số lượng” cho thấy số lượng ví dụ. “Tỷ lệ sạch” là phần trăm các ví dụ sạch so với tổng số. Đối với “Độ chính xác/F1/BLEU”, chúng tôi sử dụng chỉ số được chỉ định trong “Chỉ số”. Các điểm số này đến từ các đánh giá với một seed khác cho các ví dụ ngẫu nhiên được sử dụng để học trong ngữ cảnh, và do đó sẽ hơi khác so với các điểm số ở những nơi khác trong bài báo.

D Tổng lượng tính toán được sử dụng để huấn luyện các mô hình ngôn ngữ

Phụ lục này chứa các phép tính được sử dụng để suy ra lượng tính toán gần đúng được dùng để huấn luyện các mô hình ngôn ngữ trong Hình 2.2. Là một giả định đơn giản hóa, chúng tôi bỏ qua phép toán attention, vì nó thường sử dụng ít hơn 10% tổng lượng tính toán cho các mô hình mà chúng tôi đang phân tích.

Các phép tính có thể được thấy trong Bảng D.1 và được giải thích trong chú thích bảng.

Mô hình	Tổng lượng tính toán huấn luyện (PF-ngày)	Tổng lượng tính toán huấn luyện (flops)	Tham số (Triệu)	Token huấn luyện (tỷ)	Flops mỗi tham số mỗi token	Hệ số nhân cho lượt truyền ngược	Flops lượt truyền xuôi mỗi tham số hoạt động mỗi token
T5-Small	2.08E+00	1.80E+20	60	1,000	3	3	1
T5-Base	7.64E+00	6.60E+20	220	1,000	3	3	1
T5-Large	2.67E+01	2.31E+21	770	1,000	3	3	1
T5-3B	1.04E+02	9.00E+21	3,000	1,000	3	3	1
T5-11B	3.82E+02	3.30E+22	11,000	1,000	3	3	1
BERT-Base	1.89E+00	1.64E+20	109	250	6	3	2

BERT-Large	6.16E+00	5.33E+20	355	250	6	3	2
RoBERTa-Base	1.74E+01	1.50E+21	125	2,000	6	3	2
RoBERTa-Large	4.93E+01	4.26E+21	355	2,000	6	3	2
GPT-3 Small	2.60E+00	2.25E+20	125	300	6	3	2
GPT-3 Medium	7.42E+00	6.41E+20	356	300	6	3	2
GPT-3 Large	1.58E+01	1.37E+21	760	300	6	3	2
GPT-3 XL	2.75E+01	2.38E+21	1,320	300	6	3	2
GPT-3 2.7B	5.52E+01	4.77E+21	2,650	300	6	3	2
GPT-3 6.7B	1.39E+02	1.20E+22	6,660	300	6	3	2
GPT-3 13B	2.68E+02	2.31E+22	12,850	300	6	3	2
GPT-3 175B	3.64E+03	3.14E+23	174,600	300	6	3	2

Bảng D.1: Bắt đầu từ phía bên phải và di chuyển sang trái, chúng tôi bắt đầu với số lượng token huấn luyện mà mỗi mô hình đã được huấn luyện. Tiếp theo, chúng tôi lưu ý rằng vì T5 sử dụng mô hình mã hóa-giải mã, chỉ một nửa số tham số hoạt động cho mỗi token trong quá trình truyền xuôi hoặc truyền ngược. Sau đó, chúng tôi lưu ý rằng mỗi token liên quan đến một phép cộng và một phép nhân duy nhất cho mỗi tham số hoạt động trong lượt truyền xuôi (bỏ qua attention). Sau đó, chúng tôi thêm một hệ số nhân 3x để tính đến lượt truyền ngược (vì việc tính toán cả $\frac{\partial p}{\partial loss}^{arams}$ và $\frac{\partial acts}{\partial loss}$ sử dụng lượng

tính toán tương tự như lượt truyền xuôi). Kết hợp hai số trước đó, chúng tôi nhận được tổng số flops mỗi tham số mỗi token. Chúng tôi nhân giá trị này với tổng số token huấn luyện và tổng số tham số để cho ra tổng số flops được sử dụng trong quá trình huấn luyện. Chúng tôi báo cáo cả flops và petaflop/s-ngày (mỗi đơn vị này tương đương $8.64\text{e}+19$ flops).

E Đánh giá chất lượng của con người đối với các bài báo tin tức tổng hợp


Phụ lục này chứa chi tiết về các thí nghiệm đo lường khả năng của con người phân biệt các bài báo tin tức giả tạo do GPT-3 tạo ra với các bài báo tin tức thật. Chúng tôi đầu tiên mô tả các thí nghiệm trên các bài báo tin tức dài khoảng 200 từ, sau đó mô tả cuộc điều tra ban đầu về các bài báo tin tức dài khoảng 500 từ được tạo ra bởi GPT-3.

Thí nghiệm viên: Chúng tôi đã tuyển dụng 718 thí nghiệm viên độc lập để tham gia vào 6 thí nghiệm. 97 thí nghiệm viên bị loại bỏ vì không vượt qua câu hỏi kiểm tra internet, để lại tổng cộng 621 thí nghiệm viên: 343 nam, 271 nữ và 7 khác. Tuổi trung bình của thí nghiệm viên là khoảng 38 tuổi. Tất cả thí nghiệm viên đều được tuyển dụng thông qua Positly, một nền tảng duy trì danh sách trắng gồm những người lao động có hiệu suất cao từ Amazon Mechanical Turk. Tất cả thí nghiệm viên đều dựa tại Hoa Kỳ nhưng không có bất kỳ hạn chế dân tộc nào khác. Thí nghiệm viên được trả 12 đô la cho sự tham gia của họ, dựa trên ước tính thời gian thực hiện nhiệm vụ là 60 phút, xác định bởi các phiên chạy thử nghiệm. Để đảm bảo rằng mỗi thí nghiệm viên chỉ tham gia mỗi thí nghiệm một lần, thí nghiệm viên không được phép tham gia hơn một lần.

Quy trình và thiết kế: Chúng tôi đã chọn ngẫu nhiên 25 bài báo tin tức xuất hiện trên newser.com vào đầu năm 2020. Chúng tôi sử dụng tiêu đề và phụ đề của các bài báo để tạo ra các kết quả từ các mô hình ngôn ngữ có 125 triệu, 350 triệu, 760 triệu, 1,3 tỷ, 2,7 tỷ, 6,7 tỷ, 13 tỷ và 200 tỷ (GPT-3) tham số. Mỗi mô hình tạo ra năm kết quả cho mỗi câu hỏi và lựa chọn tự động bài viết có số từ gần nhất với bài viết của con người. Điều này nhằm giảm thiểu tác động của độ dài hoàn thành có thể có đối với đánh giá của thí nghiệm viên. Quy trình tạo ra kết quả tương tự cho mỗi mô hình ngoại trừ việc loại bỏ mô hình kiểm soát cố tình kém, như đã mô tả trong phần chính văn.

Model	Thí nghiệm viên Tuyển dụng	Thí nghiệm viên Bị loại	Giới tính (nam:nữ:khác)	Tuổi trung bình	Trung bình Số từ (con người:mô hình)
Kiểm soát	76	7	32:37:0	39	216:216
GPT-3 Nhỏ	80	7	41:31:1	40	216:188
GPT-3 Trung	80	7	46:28:2	39	216:202
GPT-3 Lớn	81	24	46:28:2	37	216:200
GPT-3 XL	79	14	32:32:1	38	216:199
GPT-3 2.7B	80	11	36:33:0	40	216:202
GPT-3 6.7B	76	5	46:28:2	37	216:195
GPT-3 13.0B	81	13	46:28:2	37	216:209
GPT-3 175B	80	9	42:29:0	37	216:216

Bảng E.1: Chi tiết thí nghiệm viên và độ dài bài báo cho mỗi thí nghiệm để đánh giá khả năng phát hiện của con người đối với các bài báo tin tức do mô hình tạo ra dài khoảng 200 từ. Thí nghiệm viên bị loại bỏ do kiểm tra internet thất bại.



Hình E.1: Thí nghiệm viên dành nhiều thời gian hơn để cố gắng xác định liệu mỗi bài báo

tin tức có phải là do máy tạo ra hay không khi kích thước mô hình tăng lên. Thời gian trên mô hình kiểm soát được chỉ định bằng đường chéo. Đường thẳng tốt nhất là mô hình tuyến tính trên hệ số log với khoảng tin cậy 95%.

Trong mỗi thí nghiệm, nửa số thí nghiệm viên được phân ngẫu nhiên vào bài kiểm tra A và nửa còn lại được phân ngẫu nhiên vào bài kiểm tra B. Mỗi bài kiểm tra bao gồm 25 bài báo: nửa (12-13) do con người viết và nửa (12-13) do mô hình tạo ra: các bài báo có hoàn thành do con người viết trong bài kiểm tra A có hoàn thành do mô hình tạo ra trong bài kiểm tra B và ngược lại. Thứ tự câu hỏi trong bài kiểm tra được trộn lẫn cho mỗi thí nghiệm viên. Thí nghiệm viên có thể để lại nhận xét và được yêu cầu chỉ rõ nếu họ đã thấy các bài báo trước đó. Thí nghiệm viên được hướng dẫn không tìm kiếm các bài báo hoặc nội dung của chúng trong quá trình kiểm tra và cuối cùng được hỏi liệu họ đã tìm kiếm gì trong quá trình kiểm tra.

Kiểm định thống kê: Để so sánh trung bình trên các lần chạy khác nhau, chúng tôi đã thực hiện kiểm định t hai mẫu cho các nhóm độc lập cho mỗi mô hình so với mô hình kiểm soát. Điều này được thực hiện bằng Python sử dụng hàm `scipy.stats.ttest_ind`. Khi vẽ đường hồi quy trong biểu đồ độ chính xác trung bình của thí nghiệm viên so với kích thước mô hình, chúng tôi đã phù hợp với luật sức mạnh dưới dạng ax^{-b} . Khoảng tin cậy 95% được ước tính từ phân phối t của mẫu trung bình.

Thống kê thời gian: Trong phần chính văn, chúng tôi đã thảo luận về phát hiện rằng khả năng của thí nghiệm viên phân biệt các bài báo do mô hình tạo ra và do con người viết giảm xuống khi mô hình của chúng ta trở nên lớn hơn. Chúng tôi cũng đã phát hiện rằng thời gian trung bình dành cho một tập câu hỏi tăng lên khi kích thước mô hình tăng lên, như được hiển thị trong Hình E.1. Điểm chính xác thấp hơn

47

||Mô hình|Thí nghiệm viên
Tuyển dụng|Thí nghiệm viên
Bị loại|Giới tính
(nam:nữ:khác)|Tuổi trung bình|Trung bình
Số từ
(con người:mô

GPT-3 thích nghi tốt với nhiều tác vụ khác ngoài những tác vụ được khám phá trong phần chính của bài viết. Ví dụ, trong Hình F.1, chúng tôi trình bày bốn mẫu chưa qua chỉnh sửa từ một prompt gợi ý rằng mô hình sẽ viết một bài thơ với một tiêu đề cụ thể, theo phong cách của Wallace Stevens. Chúng tôi đã thử nghiệm với một vài prompt trước, sau đó sinh ra bốn mẫu mà không có bất kỳ chỉnh sửa hay lựa chọn thêm nào (sử dụng phương pháp lấy mẫu nucleus sampling [HBFC19] với $P = 0._9$). Các kết quả hoàn

thiện được cắt ngắn khi mô hình bắt đầu viết tiêu đề mới và phần đầu đề tác giả, hoặc chuyển sang bình luận văn xuôi.

48

Bối cảnh → Thành phố - C.P. CAVAFY - Dịch bởi EDMUND KEELEY [Nội dung bài thơ bị bỏ qua] Một số cây - John Ashbery [Nội dung bài thơ bị bỏ qua] Những bóng tối trên đường - Wallace Stevens -----
Bài thơ sinh ra 1 ----- Bài thơ sinh ra 3 ----- Tôi phải có những bóng tối trên đường Đường phố là tất cả những gì chúng ta có. Bây giờ, dưới bóng tối Nếu tôi muốn đi Tôi phải có Mọi thứ đều thay đổi. Trí óc phải tập trung vào những điều Mỗi bước đi chậm rãi và đơn độc Những cánh đồng trắng, luôn luôn cũ đối với mắt nó; Để sẵn sàng làm việc Những ánh sáng cổ xưa, cuộn tròn Trong cách chúng nằm giữa những rễ lớn, Và tôi phải suy nghĩ theo những đường nét màu xám Những cuốn sách đen lớn của tượng tượng, Để có những suy nghĩ mơ hồ làm hướng dẫn cho tôi Cánh đồng chim hải đảo, sâu trong tâm trí, Không có tiếng lắc trên bậc thang Làm cho sự xa lạ trở nên thân thuộc Đóng lại cuộc sống khác; một người già Và của cái tên chưa nói ra là bạn. Có thể thịnh vượng ở thị trấn đó, có thể thịnh vượng Khi cửa hàng của ông đóng cửa, vợ ông ----- Bài thơ sinh ra 2 ----- Để tất cả nhân loại. Những cánh rừng và cánh đồng Là càng tốt hơn khi được kể trong truyện cổ tích, Có một con đường trong thế giới. Và rừng và thị trấn trong truyền thuyết bị che phủ Những con đường đó một người đàn ông có thể sống ở một thị trấn nhỏ Một lần nữa để trở về. Một nội dung duy nhất Cuộc đời của ông và không nhìn thấy ai đến, Có trong nó mọi hạnh phúc, dửng dưng hơn Không có sự náo động của người dân về một chợ, Vì mục đích không rõ ràng; và vì vậy Không có tiếng lắc của những xe tải bị che phủ, Những hòn đảo vườn, sâu trong tâm trí, Không có tiếng kéo kẹt truyền lên bậc thang Làm cho sự xa lạ trở nên thân thuộc Đóng lại cuộc sống khác; một người già Và của cái tên chưa nói ra là bạn. Có thể thịnh vượng ở thị trấn đó, có thể thịnh vượng Khi cửa hàng của ông đóng cửa, vợ ông ----- Bài thơ sinh ra 4 ----- Mất dần trong nhà của ông, và thế giới la hét vô ích Đó không ai đến nghe ông Không ai sẽ đến nơi này. Đây là một con đường dẫn đến đâu. Ở nơi đó tiếng chuông nhỏ của ông vang lên. Sự cô đơn là sâu sắc. Những ngọn núi là cao. Ở thị trấn nhỏ đó Những chúng là hoang vu, và chúng quay mặt du khách Mọi thứ đều biết. Hướng Bắc. Tất cả âm thanh của thế giới đều xa xôi. Con

đường của những chàng trai trẻ được biết, khi gió nổi lên trên cây, và con đường của những cô gái trẻ. Những nhánh cây cúi xuống đất. Khi họ đi đến mùa xuân; Ngay cả những con chim sống trong đám cây cỏ Rumors đều biết, Đó là lớp phủ bên đường, im lặng. Một người lắng nghe, Những tranh cãi, những đau khổ, những ganh đua. Nhưng không nghe tiếng ồn ào của rừng. Một người là cô đơn. Của những người đàn ông và phụ nữ. Một người sẽ bị lấy đi. Cho đến ngày tới Một người sẽ bị lấy đi. Con đường ra khỏi thế giới Có không có lời nói, có không có cuộc trò chuyện, Con đường dẫn đến một cánh rừng. Nhưng một người vẫn cảm thấy bất an.... Trẻ, chàng trai trẻ Có một lớp sương mỏng màu xanh, Đi, một người yêu bây giờ, Một bóng tối đang lên như khói, Biết những con đường như chúng là và thuộc về chúng. Và trong bóng tối đó Một sở hữu của trái tim. Đến cánh rừng. Một người sẽ bị lấy đi.... Đó là ở đây, và sẽ là ở đây một lần nữa Ở đây, dưới bầu trời trống rỗng và đầy ánh sáng. Ở đó, trong rừng, giữa những cây, Ông thấy bóng tối trên đường, nghe tiếng nói, nghe gió và tiếng rì rào của lá; Qua một khoảng mở Ông thấy một hình dạng và hình dạng nghe: Nó chờ đợi như ông chờ đợi, Chờ đợi như bóng tối chờ đợi, Như tiếng nói chờ đợi; Bóng tối trên đường, tiếng nói trong gió.

Hình F.1: Bốn mẫu hoàn thiện chưa qua chỉnh sửa từ một bối cảnh gợi ý rằng mô hình sẽ tạo ra một bài thơ theo phong cách của Wallace Stevens với tiêu đề 'Bóng tối trên đường'.

49

Chi tiết về Cách diễn đạt và Đặc tả Tác vụ

Dưới đây là phiên bản dịch từ tiếng Anh sang tiếng Việt của đoạn văn bản Markdown trên, đảm bảo giữ nguyên cấu trúc Markdown và LaTeX:

Text: Dưới đây là các biểu đồ minh họa định dạng và cách diễn đạt của tất cả các nhiệm vụ được đưa ra trong bài viết này. Tất cả dữ liệu đều lấy từ các tập dữ liệu thực tế trong phần này, và không có mẫu nào từ GPT-3 được đưa vào đây.

Bối cảnh →	Bài viết: Cuộc trò chuyện không chính thức là một phần quan trọng của mọi mối quan hệ kinh doanh. Trước khi bắt đầu cuộc thảo luận, hãy chắc chắn rằng bạn hiểu rõ những chủ đề phù hợp và những chủ đề bị coi là cấm kỵ ở một nền văn hóa cụ thể. Người Mỹ Latin rất thích chia sẻ thông tin về lịch sử, nghệ thuật và phong tục địa phương của họ. Bạn có thể mong đợi câu hỏi về gia đình của mình, và hãy chắc chắn rằng bạn mang theo hình ảnh của con cái. Bạn hoàn toàn có thể đặt câu hỏi tương tự với bạn bè người Mỹ Latin của mình. Người Pháp coi cuộc trò chuyện như một hình thức nghệ thuật, và họ thích giá trị của các cuộc thảo luận sôi nổi cũng như tranh luận. Đối với họ, tranh luận có thể thú vị và có thể xoay quanh hầu hết mọi chủ đề ---- miễn là chúng diễn ra một cách tôn trọng và thông minh. Ở Hoa Kỳ, người làm việc kinh doanh thích thảo luận về nhiều chủ đề khác nhau, bao gồm ý kiến về công việc, gia đình, sở thích và chính trị. Tuy nhiên, ở Nhật Bản, Trung Quốc và Hàn Quốc, mọi người lại rất kín đáo. Họ không chia sẻ nhiều về suy nghĩ, cảm xúc hay tình cảm của mình vì họ cảm thấy rằng điều đó có thể làm giảm mối quan hệ kinh doanh hài hòa mà họ đang cố gắng xây dựng. Người Trung Đông cũng rất kín đáo về cuộc sống cá nhân và gia đình. Ví dụ, hỏi một doanh nhân từ Ả Rập Xê Út về vợ hoặc con cái của họ được coi là bất lịch sự. Như một quy tắc chung, tốt nhất là không nên nói về chính trị hay tôn giáo với bạn bè kinh doanh của mình. Điều này có thể gây rắc rối, ngay cả ở Hoa Kỳ, nơi mọi người có quan điểm tôn giáo khác nhau. Ngoài ra, thảo luận về lương của mình thường được coi là không phù hợp. Thể thao thường là một chủ đề thân thiện ở hầu hết các nơi trên thế giới, mặc dù hãy cẩn thận không phê bình môn thể thao quốc gia.
	Câu hỏi: Điều gì không nên làm khi nói về thể thao với đồng nghiệp từ nước khác?

A: Phê bình môn thể thao của đồng nghiệp.

Q: Chủ đề nào thường là thân thiện theo tác giả?

A: Thể thao.

Dưới đây là phiên bản dịch từ tiếng Anh sang tiếng Việt của đoạn văn

```
|`Bối cảnh` _>_|`anli 3:`<br>`anli 3:`<br>`Chúng tôi đã đóng cửa lỗ  
|---|---|  
|`Đáp án đúng` _>_|<br>`Đáp án sai` _>_|<br>`Đáp án sai` _>_|`Sai`<br>  
|`Bối cảnh` _>_|**Hình G.10:** Ví dụ dữ liệu định dạng cho ANLI R3<br>  
|`Đáp án đúng` _>_|`palms khô`|  
|`Đáp án sai` _>_|`palms ướt`|  
|`Đáp án sai` _>_|`palms phủ dầu`|  
|`Đáp án sai` _>_|`palms phủ kem dưỡng`|
```

Hình G.11: Ví dụ dữ liệu định dạng cho ARC (Thách thức). Khi dữ

```
|`C`|`ontext` _>_|`lull is to `|`trust as`|  
|---|---|---|---|  
|`Đáp án đúng` _>_|`cajole is `|`to compliance`|  
|`Đáp án sai` _>_|`balk is to `|`fortitude`|  
|`Đáp án sai` _>_|`betray is `|`to loyalty`|  
|`Đáp án sai` _>_|`hinder is `|`to destination`|  
|`Đáp án sai` _>_|`soothe is `|`to passion`|
```

Hình G.12: Ví dụ dữ liệu định dạng cho SAT Analogies

```
|`Đáp án đúng` _>_|`Grace vui vẻ `<br>`mặc áo len`|`trading áo len c  
|---|---|---|---|  
|`Đáp án sai` _>_|`Grace vui vẻ `<br>`mặc áo khoác`|`trading áo len  
|`Hoàn thành mục tiêu` _>_|`nhìn quê ở `|`cô ấy.`||
```

Hình G.13: Ví dụ dữ liệu định dạng cho Winograd. Phương pháp đánh

```
|`Đáp án đúng` _>_|`Johnny thích trái cây hơn rau trong chế độ ăn ki  
|---|---|  
|`Đáp án sai` _>_|`Johnny thích trái cây hơn rau trong chế độ ăn kiê  
|`Hoàn thành mục tiêu` _>_|`là ngọt ngào.`|
```

****Hình G.14:**** Ví dụ dữ liệu định dạng cho Winogrande. Phương pháp đ

```
|`Bối cảnh` _>_|`KEY ĐÁP ÁN ĐỌC HIỂU`<br>`Trong khi quá trình này đi
```

55

```
|`Bối cảnh` _>_|`Văn bản:`<br>`Jean de Brébeuf là một nhà truyền giáo  
|---|---|
```

```
|`Hoàn thành mục tiêu` _>_|`4`|
```

```
|`**Hình G.20:** Ví dụ dữ liệu được định dạng cho DROP|
```

```
|`Bối cảnh` _>_|`Điền vào khoảng trống:`<br>`Cô cầm ngọn đuốc trước
```

```
|`Hoàn thành mục tiêu` _>_|`bậc thang`|
```

```
|`**Hình G.21:** Ví dụ dữ liệu được định dạng cho LAMBADA|
```

```
|`Bối cảnh` _>_|`Hãy sắp xếp các chữ thành một từ và viết ra từ đó:`
```

```
|`Hoàn thành mục tiêu` _>_|`sticks`|
```

```
|`**Hình G.22:** Ví dụ dữ liệu được định dạng cho Anagrams 1 (A1)|
```

```
|`Bối cảnh` _>_|`Hãy sắp xếp các chữ thành một từ và viết ra từ đó:`
```

```
|`Hoàn thành mục tiêu` _>_|`volkswagen`|
```

```
|`**Hình G.23:** Ví dụ dữ liệu được định dạng cho Anagrams 2|
```

```
|`Bối cảnh` _>_|`C: Ai đã đóng vai Tess trong bộ phim Touched by an
```

```
|`A:`|
```

```
|`Hoàn thành mục tiêu` _>_|`Delloreese Patricia Early (6 tháng 7, 19
```

```
|`**Hình G.24:** Ví dụ dữ liệu được định dạng cho Natural Questions|
```

56

```
|`Bối cảnh` _>_|`TIÊU ĐỀ: William Perry (Bóng đá Mỹ) - Sự nghiệp chu
```

Dịch đoạn văn bản Markdown sau từ tiếng Anh sang tiếng Việt. Lưu ý: C

Text:

```
|`Bối cảnh` _>_|`Một nhà cung cấp đã cung cấp mọi thứ cần thiết cho`
|---|---|
||`câu hỏi:`<br>`Từ 'outfitter' có được sử dụng theo cùng một cách t
||`đáp án:`|
|`Hoàn thành mục tiêu` _>_|`không`|
```

****Hình G.32:**** Ví dụ dữ liệu định dạng cho WiC

```
|`Bối cảnh` _>_|`Đề thi cuối khóa với đáp án`<br>`Hướng dẫn:`<br>`Hã
|---|---|
|`Hoàn thành mục tiêu` _>_|`ông`<br>`Moncrieff`|
||**Hình G.33:** Ví dụ dữ liệu định dạng cho WSC|
|`Bối cảnh` _>_|`C: "Nude Descending A Staircase" có lẽ là bức tranh
|`Hoàn thành mục tiêu` _>_|`MARCEL DUCHAMP`|
|`Hoàn thành mục tiêu` _>_|`r mutt`|
|`Hoàn thành mục tiêu` _>_|`duchamp`|
|`Hoàn thành mục tiêu` _>_|`marcel duchamp`|
|`Hoàn thành mục tiêu` _>_|`R.Mutt`|
|`Hoàn thành mục tiêu` _>_|<br>`Hoàn thành mục tiêu` _>_|<br>`Hoàn thà
|`Hoàn thành mục tiêu` _>_|`Duchampian`|
|`Hoàn thành mục tiêu` _>_|`Duchamp`|
|`Hoàn thành mục tiêu` _>_|<br>`Hoàn thành mục tiêu` _>_|`duchampian`
|`Hoàn thành mục tiêu` _>_|`Marcel Duchamp`|
|`Hoàn thành mục tiêu` _>_|`MARCEL DUCHAMP`|
```

****Hình G.34:**** Ví dụ dữ liệu định dạng cho TriviaQA. TriviaQA cho ph

59

```
|`Bối cảnh` _>_|`C: Trườg nào đã được Burne Hogarth lập ra?`|
|---|---|
||`D:`|
|`Hoàn thành mục tiêu` _>_|`Trườg Nghệ Thuật Visaul`|
||**Hình G.35:** Ví dụ dữ liệu định dạng cho WebQA|
|`Bối cảnh` _>
```

```
|||||||Không mẫu||Một mẫu||Ít mẫu||
|---|---|---|---|---|---|---|---|---|---|---|---|---|
|Tên|Chỉ số|Tập dữ liệu|SOTA huấn luyện tinh chỉnh|K huấn luyện tinh
|HellaSwag<br>|độ chính xác|dev<br>|85.6<br>|20<br>|33.7<br>|43.6 51
```

LAMBADA	LAMBADA	độ chính xác	ppl	test	test	68.0	8.63	15
StoryCloze	độ chính xác	test	91.8	70	63.3	68.5	72.4	73.4 77.2 77.7
NQs	độ chính xác	test	44.5	64	0.64	1.75	2.71	4.40 6.01 5.79 7.84 14
TriviaQA	Wb	độ chính xác	dev	tt	68.0	455	64	64 4.15
eQs	độ chính xác	es	.	.	.	.	.	.
Ro→En 16	BLEU-	mb test	39.9	64	2.08	2.71	3.09	3.15 16.3 8.34 20.2
Ro→En 16	BLEU-	sb	test	64	2.39	3.08	3.49	
En→Ro 16	BLEU-	mb test	38.5					
Fr→En 14	FE 14	BLEU-	mb test	b	35.0	64	64	1.
r→n	En→Fr 14	BLEU-	test	mb test	45.6	64	1.74	.
En→Fr 14	BLEU-	sb	test	45.9	64	2.44	2.75 3.54	2.82 19.3 11.4 1
De→En 16	BLEU-	mb test	40.2	64	2.06	2.87		
De→En 16	En→De 16	BLEU-	b	test	41.2	6		
En→De 16	BLEU-	sb	test	41.2	64	2.09	2.65 2.75	2.92 13.7 9.36 1
Winograd	độ chính xác	test	93.8	7	66.3	72.9	74.7	76.9 82.4 85.7 87.
Winogrande	độ chính xác	dev	84.6	50	52.0	52.1	57.4	58.7 62.3 64.5 6
PIQA	độ chính xác	dev	77.1	50	64.6	70.2	72.9	
ARC (Challenge	ARC (Easy)	độ chính xác	độ chính xác	test				
OBkA		872	100	356	432452	468530504556576	370	39
penooQ	độ chính xác	test	.	.	.	.	.	.
Quac	f1	dev	74.4	5	21.2	26.8	31.0	30.1 34.7 36.1 38.4 41.5
RACE-h	RACE-m	độ chính xác	độ chính xác	test	test			
SQuADv2	em	dev	90.7	16	22.6	32.8	33.9	43.1 43.6 45.4 49.0 52.6
SQuADv2	CA	f1	dev	d	93.0	907	16	5 28.3 345 40.
oQ	DROP	f1	ev	dev	89.1	20	9.40	13.6 14.4
BoolQ	độ chính xác	dev	91.0	32	49.7	60.3	58	
CB	độ chính xác	dev	96.9	32	0.00	32.1	8.93	
CB	Copa	f1	độ chính xác	dev	dev	93.9	94.8	32 32 0.00
RTE	d	925	32	477	498484	560466552628635	531	473495
	độ chính xác	ev	.	.	.	.	.	.
WiC	độ chính xác	dev	76.1	32	0.00	0.00	0.00	0.00 0.00 0.00 0.00 0.0
WSC	MultiRC	độ chính xác	độ chính xác	dev	dev	93.8	623	
MultiRC	f1a	dev	88.2	32	57.0	5		
ReCoRD	độ chính xác	dev	92.5	32	70.8	78.5	82.1	84.1 86.2 88.6 89.0
ReCoRD	SGLUE	f1	dev	d	93.3	890	32	71.9 406 79.2 82.
uper	average	ev	.	.	.	.	.	.
ANLI R1	độ chính xác	test	73.8	50	33.4	34.2	33.4	34.2 32.3 33.
ANLI R2	độ chính xác	test	50.7	50	33.2	31.9		
ANLI R3	độ chính xác	test	48.3	50	33.6	34.0	33.8	33.4 35.3 34.8 34.
2D+	độ chính xác	n/a	50	0.70	0.65	0.70	0.85	1.10 2.54 15.4 76.9 2.

2D-	 	độ chính xác	n/a	 	50	 	1.25	 	1.25	1.25	 	1.25	1.	
3D+	 	3D-	độ chính xác	 	độ chính xác	n/a	 	n/a	50	 	50	0.10	b	
4D+	độ chính xác	n/a	50	005	005000	000005005015400	000	 	000010	0				
4D-	 	độ chính xác	n/a	 	50	 	.	 	0.00	 	.	.	 	0.00
5D+	độ chính xác	n/a	50	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.65	0.	
5D-	độ chính xác	n/a	50	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.80	0.	
2Dx	 	độ chính xác	n/a	 	50	 	2.20	 	2.25	2.65	 	2.10	2.	
1DC	độ chính xác	n/a	50	1.25	2.95	2.75	0.05	0.30	2.35	0.75	9.75	1.		
Cycled Letters	 	độ chính xác	 	n/a	 	100	 	0.62	 	0.71				
Anagrams 1	 	độ chính xác	n/a	 	100	 	0.10	 	0.14	0.40	 			
Anagrams 2	 	Symbol Insertion	độ chính xác	 	độ chính xác	n/a	 							
 	Reversed Words	 	độ chính xác	n/a	100	0.00	 	0.01	0.01	 				
SAT Analogies	độ chính xác	n/a	20	35.6	39.0	45.2	44.1	50.0	49.2	52				

****Bảng H.1:** Điểm số cho từng tác vụ, thiết lập và mô hình mà chúng**

63

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

****Hình H.1:**** Tất cả kết quả cho tất cả các tác vụ SuperGLUE.

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

****Hình H.2:**** Kết quả cho tác vụ SAT.

****Hình H.3:**** Tất cả kết quả cho tất cả các tác vụ Winograd.

64

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

****Hình H.4:**** Tất cả kết quả cho tất cả các tác vụ số học.

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

****Hình H.5:**** Tất cả kết quả cho tất cả các bài tập điền từ và hoàn t

65

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

****Hình H.6:**** Tất cả kết quả cho tất cả các tác vụ phân tích logic tl

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

****Hình H.7:**** Tất cả kết quả cho tất cả các tác vụ Hỏi-Đáp (QA).

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

****Hình H.8:**** Tất cả kết quả cho tất cả các tác vụ hiểu nội dung khi

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

****Hình H.9:**** Tất cả kết quả cho tất cả các vòng ANLI.

66

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

****Hình H.10:**** Tất cả kết quả cho tất cả các tác vụ Xáo trộn.

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

![] (temp_images/b5b8d8aa-8ee2-4bf0-a53f-65917094a362/input_b5b8d8aa-

Hình H.11: Tất cả kết quả cho tất cả các tác vụ Dịch thuật.

67

Tài liệu tham khảo

- [ADG⁺ 16] Marcin Andrychowicz, Misha Denil, Sergio Gome
- [AI19] WeChat AI. Tr-mt (ensemble), Tháng 12 năm 2019.
- [AJF19] Roei Aharoni, Melvin Johnson, và Orhan Firat. Dịch máy thầ
- [BBDIW20] Su Lin Blodgett, Solon Barocas, Hal Daume III, và Hanna
- [BCFL13] Jonathan Berant, Andrew Chou, Roy Frostig, và Percy Liang
- [BDD⁺ 09] Luisa Bentivogli, Ido Dagan, Hoa Trang Dang,
- [BES10] Stefano Baccianella, Andrea Esuli, và Fabrizio Sebastiani.
- [BHDD⁺ 06] Roy Bar Haim, Ido Dagan, Bill Dolan, Lisa Fe
- [BHT⁺ 20] Yonatan Bisk, Ari Holtzman, Jesse Thomason, J
- [BLC13] Yoshua Bengio, Nicholas Leonard, và Aaron C. Courville. Ưó
- [BZB⁺ 19] Yonatan Bisk, Rowan Zellers, Ronan Le Bras, J
- [Car97] Rich Caruana. Học đa tác vụ. *_Machine learning_*, 28(1), 1

- [CB78] Susan Carey và Elsa Bartlett. Tiếp thu một từ mới duy nhất.
- [CCE⁺ 18] Peter Clark, Isaac Cowhey, Oren Etzioni, Tush
- [CGRS19] Rewon Child, Scott Gray, Alec Radford, and Ilya Sutskever
- [CHI⁺ 18] Eunsol Choi, He He, Mohit Iyyer, Mark Yatskar
- [CLC⁺ 19] Christopher Clark, Kenton Lee, Ming-Wei Chang
- [CLY⁺ 19] Yen-Chun Chen, Linjie Li, Licheng Yu, Ahmed E
- [Cra17] Kate Crawford. Vấn đề với sự thiên vị. _NIPS 2017 Keynote_
- [DCLT18] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina To

68

- [DGM06] Ido Dagan, Oren Glickman, and Bernardo Magnini. Thử thách
- [DGV⁺ 18] Mostafa Dehghani, Stephan Gouws, Oriol Vinyal
- [DHKH14] Nadir Durrani, Barry Haddow, Philipp Koehn, and Kenneth H
- [DL15] Andrew M. Dai and Quoc V. Le. Học chuỗi bán giám sát. Trong
- [DMST19] Marie-Catherine De Marneffe, Mandy Simons, and Judith Ton
- [DSC⁺ 16] Yan Duan, John Schulman, Xi Chen, Peter L. Ba
- [DWD⁺ 19] Dheeru Dua, Yizhong Wang, Pradeep Dasigi, Gab
- [DYY⁺ 19] Zihang Dai, Zhilin Yang, Yiming Yang, Jaime G
- [EOAG18] Sergey Edunov, Myle Ott, Michael Auli, and David Grangier
- [FAL17] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Học siêu d
- [Fyo00] Yaroslav Fyodorov. Một hệ thống suy luận logic tự nhiên, 2

- [GG19] Hila Gonen and Yoav Goldberg. Sơn môi trên lợn: Các phương
 - [GLT⁺ 20] Kelvin Guu, Kenton Lee, Zora Tung, Panupong P
 - [GMDD07] Danilo Giampiccolo, Bernardo Magnini, Ido Dagan, and Bill
 - [Gra16] Alex Graves. Thời gian tính toán thích ứng cho mạng thần k
 - [GSL⁺ 18] Suchin Gururangan, Swabha Swayamdipta, Omer L
 - [GSR19] Sebastian Gehrmann, Hendrik Strobelt, and Alexander M. Rus
 - [GWC⁺ 18] Jiatao Gu, Yong Wang, Yun Chen, Kyunghyun Cho
 - [HB20] Daniel Hernandez and Tom Brown. AI và hiệu quả, tháng 5 năm
 - [HBFC19] Ari Holtzman, Jan Buys, Maxwell Forbes, and Yejin Choi. T
 - [HLW⁺ 20] Dan Hendrycks, Xiaoyuan Liu, Eric Wallace, Ad
- 69
- [HNA⁺ 17] Joel Hestness, Sharan Narang, Newsha Ardalani
 - [HR18] Jeremy Howard and Sebastian Ruder. Huấn luyện tinh chỉnh mô
 - [HVD15] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Chắt lọc ki
 - [HYC01] Sepp Hochreiter, A Steven Younger, and Peter R Conwell. HỌ
 - [HZJ⁺ 19] Po-Sen Huang, Huan Zhang, Ray Jiang, Robert S
 - [IBGC⁺ 14] Mohit Iyyer, Jordan Boyd-Graber, Leonardo Cl
 - [IDCBE19] Daphne Ippolito, Daniel Duckworth, Chris Callison-Burch,
 - [JCWZ17] Mandar Joshi, Eunsol Choi, Daniel S. Weld, and Luke Zettl
 - [JN20] Zheng Junyuan and Gamma Lab NYC. Bộ biến đổi số - ALBERT, t

- [JVS⁺⁺ 16] Rafal Jozefowicz, Oriol Vinyals, Mike Schuster
 - [JYS⁺⁺ 19] Xiaoqi Jiao, Yichun Yin, Lifeng Shang, Xin Ji
 - [JZC⁺⁺ 19] Ying Ju, Fubang Zhao, Shijie Chen, Bowen Zhen
 - [KCR⁺⁺ 18] Daniel Khashabi, Snigdha Chaturvedi, Michael
 - [KKS⁺⁺ 20] Daniel Khashabi, Tushar Khot, Ashish Sabharwa
 - [KMB20] Sarah E. Kreps, Miles McCain, and Miles Brundage. Tất cả t
 - [KMH⁺⁺ 20] Jared Kaplan, Sam McCandlish, Tom Henighan, T
 - [KPR⁺⁺ 19] Tom Kwiatkowski, Jennimaria Palomaki, Olivia
 - [KR16] Yoon Kim and Alexander M. Rush. Chắt lọc kiến thức cấp độ c
 - [LB02] Edward Loper and Steven Bird. NLTK: Bộ công cụ ngôn ngữ tự
 - [LC19] Guillaume Lample and Alexis Conneau. Huấn luyện trước mô hì
- 70
- [LCG⁺⁺ 19] Zhenzhong Lan, Mingda Chen, Sebastian Goodman
 - [LCH⁺⁺ 20] Xiaodong Liu, Hao Cheng, Pengcheng He, Weizhu
 - [LDL19] Zhongyang Li, Xiao Ding, and Ting Liu. Dự đoán kết thúc câ
 - [LDM12] Hector Levesque, Ernest Davis, and Leora Morgenstern. Thử
 - [LGG⁺⁺ 20] Yinhan Liu, Jiatao Gu, Naman Goyal, Xian Li,
 - [LGH⁺⁺ 15] Xiaodong Liu, Jianfeng Gao, Xiaodong He, Li D
 - [LH17] Ilya Loshchilov and Frank Hutter. Chuẩn hóa suy giảm trọng
 - [LHCG19a] Xiaodong Liu, Pengcheng He, Weizhu Chen, and Jianfeng Ga

- [LHCG19b] Xiaodong Liu, Pengcheng He, Weizhu Chen, and Jianfeng Guo.
- [Lin20] Tal Linzen. Làm thế nào chúng ta có thể đẩy nhanh tiến độ 1
- [LLG⁺ 19] Mike Lewis, Yinhan Liu, Naman Goyal, Marjan G
- [LM17] Ke Li and Jitendra Malik. Học cách tối ưu hóa mạng nơ-ron.
- [LOG⁺ 19] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du
- [LPP⁺ 20] Patrick Lewis, Ethan Perez, Aleksandra Piktus
- [LSP⁺ 18] Peter J. Liu, Mohammad Saleh, Etienne Pot, Be
- [LWS⁺ 20] Zhuohan Li, Eric Wallace, Sheng Shen, Kevin L
- [LXL⁺ 17] Guokun Lai, Qizhe Xie, Hanxiao Liu, Yiming Ya
- [LYN⁺ 20] Sheng-Chieh Lin, Jheng-Hong Yang, Rodrigo Nog
- [Mac92] David. MacKay. Các hàm mục tiêu dựa trên thông tin cho việ

71

- [MBXS17] Bryan McCann, James Bradbury, Caiming Xiong, and Richard
- [MCCD13] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean.
- [MCH⁺ 16] Nasrin Mostafazadeh, Nathanael Chambers, Xiao
- [MCKS18] Todor Mihaylov, Peter Clark, Tushar Khot, and Ashish Sabh
- [MKAT18] Sam McCandlish, Jared Kaplan, Dario Amodei, and OpenAI Do
- [MKM⁺ 94] Mitchell Marcus, Grace Kim, Mary Ann Marcinki
- [MKXS18] Bryan McCann, Nitish Shirish Keskar, Caiming Xiong, and R
- [MPL19] R Thomas McCoy, Ellie Pavlick, and Tal Linzen. Đúng vì nhữ

- [MWZ[⁺] 18] Margaret Mitchell, Simone Wu, Andrew Zaldivar
- [NBR20] Moin Nadeem, Anna Bethke, and Siva Reddy. Stereoset: Đo lu
- [NK19] Timothy Niven and Hung-Yu Kao. Khám phá khả năng hiểu của m
- [Nor09] Peter Norvig. Dữ liệu kho ngữ liệu ngôn ngữ tự nhiên, 2009
- [NvNvdG19] Malvina Nissim, Rik van Noord, and Rob van der Goot. Cô
- [NWD[⁺] 19] Yixin Nie, Adina Williams, Emily Dinan, Mohit
- [oR16] University of Regensburg. Fascha, 2016.
- [PCC18] Mohammad Taher Pilehvar and Jose Camacho-Collados. WIC: 10
- [PFB18] Jason Phang, Thibault Fevry, and Samuel R. Bowman. Bộ mã
- [PHR[⁺] 18] Adam Poliak, Aparajita Haldar, Rachel Rudinge
- [PKL[⁺] 16] Denis Paperno, German Kruszewski, Angeliki La
- [PNZtY18] Matthew E. Peters, Mark Neumann, Luke Zettlemoyer, and W
- [Pos18] Matt Post. Lời kêu gọi sự rõ ràng trong việc báo cáo điểm

72

- [PSM14] Jeffrey Pennington, Richard Socher, and Christopher Mannin
- [QIA20] QIANXIN. Sa-net trên ALBERT (tập hợp), Tháng 4 năm 2020.
- [QMZH19] Yusu Qian, Urwa Muaz, Ben Zhang, and Jae Won Hyun. Giảm t
- [RBG11] Melissa Roemmele, Cosmin Adrian Bejan, and Andrew S Gordon
- [RCM19] Siva Reddy, Danqi Chen, and Christopher D Manning. CoQA: M
- [RCP[⁺] 17] Scott Reed, Yutian Chen, Thomas Paine, Aaron

- [RJL18] Pranav Rajpurkar, Robin Jia, and Percy Liang. Biết những gì
- [RL16] Sachin Ravi and Hugo Larochelle. Tối ưu hóa như một mô hình
- [RL⁺19] Qiu Ran, Yankai Lin, Peng Li, Jie Zhou, and Z
- [RNLVD18] Rachel Rudinger, Jason Naradowsky, Brian Leonard, and Be
- [RNSS18] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya
- [Ros12] R.S. Ross. Hướng dẫn thực hiện đánh giá rủi ro. _NIST Spec
- [RRBS19] Jonathan S. Rosenfeld, Amir Rosenfeld, Yonatan Belinkov,
- [RRS20] Adam Roberts, Colin Raffel, and Noam Shazeer. Bạn có thể đ
- [RSR⁺19] Colin Raffel, Noam Shazeer, Adam Roberts, Kat
- [RWC⁺19] Alec Radford, Jeffrey Wu, Rewon Child, David
- [SBBC19] Keisuke Sakaguchi, Ronan Le Bras, Chandra Bhagavatula, an
- [SBC⁺19] Irene Solaiman, Miles Brundage, Jack Clark, A
- [SCNP19] Emily Sheng, Kai-Wei Chang, Premkumar Natarajan, and Nany
- [SDCW19] Victor Sanh, Lysandre Debut, Julien Chaumond, and Thomas
- [SDSE19] Roy Schwartz, Jesse Dodge, Noah A. Smith, and Oren Etzion
- [SHB15] Rico Sennrich, Barry Haddow, and Alexandra Birch. Cải thiệ

73

- [SMM⁺17] Noam Shazeer, Azalia Mirhoseini, Krzysztof Ma
- [SPP⁺19] Mohammad Shoeybi, Mostofa Patwary, Raul Puri,
- [SS20] Timo Schick and Hinrich Schutze. Khai thác các câu hỏi điề

- [STQ⁺ 19] Kaitao Song, Xu Tan, Tao Qin, Jianfeng Lu, and
- [TFR⁺ 17] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schn
- [TL05] Peter D. Turney and Michael L. Littman. Học dựa trên kho ng
- [TL18] Trieu H. Trinh and Quoc V. Le. Một phương pháp đơn giản cho
- [TLBS03] Peter D. Turney, Michael L. Littman, Jeffrey Bigham, và V
- [Tur20] Dự án Turing. Blog nghiên cứu của Microsoft, tháng 2 năm 2
- [VBL⁺ 16] Oriol Vinyals, Charles Blundell, Timothy Lill
- [VSP⁺ 17] Ashish Vaswani, Noam Shazeer, Niki Parmar, Ja
- [WPN⁺ 19] Alex Wang, Yada Pruksachatkun, Nikita Nangia,
- [WXH⁺ 18] Yiren Wang, Yingce Xia, Tianyu He, Fei Tian,
- [XDH⁺ 19] Qizhe Xie, Zihang Dai, Eduard Hovy, Minh-Tha
- [YdC⁺ 19] Dani Yogatama, Cyprien de Masson d’Autume, Je
- [YDY⁺ 19] Zhilin Yang, Zihang Dai, Yiming Yang, Jaime C
- [ZHB⁺ 19] Rowan Zellers, Ari Holtzman, Yonatan Bisk, Al
- [ZHR⁺ 19] Rowan Zellers, Ari Holtzman, Hannah Rashkin,
- [ZLL⁺ 18] Sheng Zhang, Xiaodong Liu, Jingjing Liu, Jian
- [ZSW⁺ 19a] Daniel M. Ziegler, Nisan Stiennon, Jeffrey W
- [ZSW⁺ 19b] Daniel M. Ziegler, Nisan Stiennon, Jeffrey W

请注意，这里保持了原始的Markdown格式，并且保留了所有专有名词和缩写。