

Tiến bộ các mô hình ngôn ngữ lớn cho việc chỉnh sửa sau dịch ở cấp độ tài liệu bằng dữ liệu monolingual

Li Tông Yếu*, Nghi Trí Trương*, Thăng Chào Thương*,
Guo Jiǎxiān, Lí Thiếu Quân, Vệ Đại Mẫn, Dương Hào Dịch
Thuật Trung Tâm, Huawei, Bắc Kinh, Trung Quốc {lizongyao,raoz
hiqiang,shanghengchao,
guojiaxin1,lishaojun18,weidaimeng,yanghao30}@huawei.com

Tóm Lược

Kỹ năng dịch của các mô hình dịch máy thần kinh (NMT) dựa trên khung công cụ mã-hướng xuất-nhập cực kỳ mạnh mẽ. Dù rằng các Mô Hình Ngôn Ngữ Lớn (LLM) đã đạt được kết quả đáng kể trong nhiều tác vụ, họ chưa đạt đến hiệu suất hàng đầu trong NMT. Tuy nhiên, NMT truyền thống vẫn đối mặt với những thách thức đáng kể trong các lĩnh vực như sự nhất quán ngữ cảnh, thời điểm và giải quyết đại từ trong dịch tài liệu, nơi mà LLMs tự nhiên sở hữu những lợi thế đáng kể. Thay vì sử dụng trực tiếp LLMs cho dịch, việc sử dụng chúng cho Chỉnh sửa Tự Động Sau Khi Dịch (APE) để chỉnh sửa sau NMT chứng tỏ là một lựa chọn khả thi. Tuy nhiên, dữ liệu song ngữ cấp độ tài liệu cực kỳ hiếm hoi. Bài viết này đề xuất một phương pháp có thể tận dụng hiệu quả khả năng của LLMs để tối ưu hóa dịch tài liệu chỉ bằng dữ liệu đơn ngữ. Bằng cách sử dụng hai mô hình NMT trong hai hướng ngược nhau (Từ Ngôn Ngữ Nguồn đến Ngôn Ngữ Mục Tiêu và Từ Ngôn Ngữ Mục Tiêu đến Ngôn Ngữ Nguồn), chúng tôi tạo ra dữ liệu huấn luyện giả lập tài liệu cho việc huấn luyện APE. Chúng tôi đã xác định và giải quyết vấn đề không đồng nhất giữa chế độ huấn luyện và suy luận do dữ liệu huấn luyện giả lập tài liệu gây ra. Kết quả thí nghiệm cuối cùng cho thấy rằng bằng cách sử dụng chỉ dữ liệu đơn ngữ cấp độ tài liệu, chúng ta có thể cải thiện đáng kể chất lượng của NMT và tăng cường đáng kể các vấn đề như sự nhất quán tham chiếu và ngữ cảnh trong NMT.

1 Giới thiệu

Mô hình ngôn ngữ lớn (LLMs) thể hiện hiệu suất xuất sắc trong nhiều tác vụ (Touvron et al., 2023; Anil et al., 2023; Bahak et al., 2023). Dù vậy, trong các lĩnh vực khác nhau, các mô hình Dịch Máy Ngữ nghĩa cấp từ câu (NMT) không thua kém LLMs về các chỉ số như BLEU (Papinini et al., 2002) và COMET (Rei et al., 2022), nhưng họ vẫn gặp nhiều thách thức trong việc dịch tài liệu, đặc biệt là về mặt ngữ cảnh.

tính nhất quán, thời gian và tham chiếu. Vì các mô hình ngôn ngữ lớn (LLM) chủ yếu được huấn luyện bằng dữ liệu đơn ngữ ở mức độ tài liệu, chúng chắc chắn có lợi thế đáng kể về độ mạch lạc của biểu đạt văn bản.

Gần đây, một lượng lớn nghiên cứu (Wang và cộng sự, 2023; Zhang và cộng sự, 2023a; Guo và cộng sự, 2024) đã được dành cho việc sử dụng LLM nhằm nâng cao chất lượng MT. Nghiên cứu chủ yếu sử dụng LLM trực tiếp cho dịch thuật và tập trung giải quyết các vấn đề sau: 1) Các LLM đều tập trung vào tiếng Anh và cần được căn chỉnh đa ngôn ngữ (Zhang và cộng sự, 2023b; Alves và cộng sự, 2023) để cải thiện khả năng dịch của chúng. Các phương pháp hiện tại chủ yếu dựa vào dữ liệu căn chỉnh song ngữ chất lượng cao cho việc tiền huấn luyện hoặc tinh chỉnh có giám sát (SFT) để đạt được mục tiêu này, nhưng kết quả cuối cùng không cho thấy lợi thế đáng kể so với các mô hình NMT mức câu về các chỉ số BLEU và COMET. 2) Cần khảo sát chất lượng của LLM trong các kịch bản đa ngôn ngữ (Liu và cộng sự, 2024) và chuyên ngành (Zheng và cộng sự, 2024), đặc biệt trong các kịch bản chuyên ngành mà các mô hình NMT truyền thống đã đạt hiệu suất tốt. Không có phương pháp nào trong số trên tích hợp mô hình NMT truyền thống với LLM, dẫn đến việc không khai thác được ưu điểm riêng của cả hai.

Koneru et al. (2024) sử dụng các mô hình ngôn ngữ lớn (LLMs) để thực hiện việc chỉnh sửa tự động (APE) trên các bản dịch được sinh ra bởi mô hình dịch máy (NMT), thay vì sử dụng trực tiếp các mô hình ngôn ngữ lớn cho việc dịch. Đầu tiên, dữ liệu dạng tài liệu song ngữ được sử dụng với các mô hình NMT để xây dựng dữ liệu huấn luyện dạng triplet (SRC, NMT→PE). Thứ hai, dữ liệu huấn luyện này được sử dụng để huấn luyện lại các mô hình LLM, cho phép chúng cải thiện các bản dịch được tạo ra bởi các mô hình NMT. Cuối cùng, mô hình LLM đã được huấn luyện lại được sử dụng để tối ưu hóa các kết quả của mô hình NMT, nâng cao tính nhất quán và sự mạch lạc của các bản dịch. Tuy nhiên, hạn chế của phương pháp được mô tả trong bài viết là sự thiếu hụt dữ liệu song ngữ ở cấp độ tài liệu, đặc biệt là trong các trường hợp nguồn lực thấp, điều này hạn chế

*These authors contributed equally to this work.

Tính khả dụng của phương pháp trong các môi trường đa ngôn ngữ và thiếu tài nguyên.

So sánh với việc thu thập dữ liệu song ngữ ở cấp độ tài liệu, việc thu thập dữ liệu đơn ngữ ở cấp độ tài liệu dễ dàng hơn nhiều. Trong Voita et al. (2019), phương pháp DocRepair được đề xuất, chỉ yêu cầu dữ liệu đơn ngữ ở cấp độ tài liệu trong ngôn ngữ mục tiêu. Đây là một mô hình trình tự đến trình tự mà ánh xạ các nhóm câu không nhất quán sang các nhóm nhất quán. Nhóm nhất quán đến từ dữ liệu đơn ngữ cấp độ tài liệu gốc; nhóm không nhất quán được thu được bằng cách lấy mẫu từ các phiên dịch đi lui của mỗi câu riêng lẻ. Phương pháp được đề xuất cũng có thể cải thiện sự nhất quán của các bản dịch NMT cấp độ câu rất tốt ngay cả khi chỉ sử dụng dữ liệu đơn ngữ. Tuy nhiên, đây là một hệ thống chuỗi, có thể làm tăng lỗi; ngoài ra, không có tham chiếu đến văn bản nguồn và thông tin như sự nhất quán của thực thể trong văn bản nguồn không được tận dụng hiệu quả.

Chúng tôi đề xuất một phương pháp tối ưu hóa dịch tài liệu bằng cách tận dụng khả năng của các mô hình ngôn ngữ lớn (LLMs) sử dụng chỉ dữ liệu tài liệu đơn ngữ. Phương pháp này bao gồm việc huấn luyện lại LLMs đến APE thông qua LoRA (Hu et al., 2021) để tối ưu hóa đầu ra hệ thống dịch câu. Tương tự như DocRepair, bằng cách dịch văn bản phía mục tiêu đi lại hai lần, chúng tôi thu được dữ liệu định tuyến cho các nhóm câu không nhất quán và nhất quán. Khác với DocRepair, chúng tôi cũng bao gồm dữ liệu dịch máy nguồn đã sinh ra trong nhóm định tuyến, tạo thành dữ liệu ba phần (SRC, MT→PE). Vì không có sử dụng dữ liệu tài liệu song ngữ, SRC trong dữ liệu ba phần của chúng tôi là dữ liệu dịch máy giả, trong khi trong quá trình suy luận, SRC là dữ liệu tự nhiên, gây ra vấn đề không phù hợp giữa mẫu huấn luyện và suy luận ảnh hưởng đến chất lượng dịch. Wei et al. (2023) đề cập đến sự khác biệt phong cách đáng kể giữa dữ liệu dịch máy và dữ liệu tự nhiên. Để giải quyết vấn đề không phù hợp này, chúng tôi tiến hành chuyển phong cách trên dữ liệu SRC giả để kết nối với dữ liệu tự nhiên. Bằng cách sử dụng đồng thời dữ liệu tài liệu đơn ngữ từ nguồn và mục tiêu, chúng tôi cho phép LLMs cải thiện đầu ra hệ thống dịch câu và tạo ra văn bản nhất quán và mạch lạc bằng cách tận dụng khả năng của chúng để tạo ra tài liệu dài và trôi chảy.

Kết quả chính và những đóng góp của bài viết này là như sau:

1. Chúng tôi đề xuất một paradigma mới cho phép các mô hình ngôn ngữ lớn (LLMs) có khả năng dịch máy ở cấp độ tài liệu thông qua khả năng APE chỉ bằng dữ liệu đơn ngữ ở cấp độ tài liệu. Đặc biệt trong các trường hợp tài nguyên hạn chế,

Chất lượng của các mô hình dịch máy(sentence-level MT) có thể được cải thiện bằng cách tận dụng dữ liệu đơn ngữ có chi phí thấp. Đồng thời, chúng tôi chứng minh rằng bằng cách tăng lượng dữ liệu đơn ngữ ở cấp độ tài liệu(document-level monolingual data), chất lượng dịch có thể đạt hoặc thậm chí vượt quá hiệu quả của việc sử dụng dữ liệu song ngữ cấp độ tài liệu(bilin-gual data) hạn chế.

2. Chúng tôi đã đề xuất các phương pháp khác nhau (Xích, Đầu cuối đến đầu cuối) sử dụng Mạng Lỗi Lớn (LLMs) cho chuyển phong cách để giải quyết vấn đề không phù hợp giữa huấn luyện và suy luận, và kết quả thử nghiệm đã chứng minh hiệu quả của phương pháp của chúng tôi.

3. Chúng tôi đã phân tích bản dịch sau khi sử dụng APE và đạt được độ chính xác 80,2% trên tập thử nghiệm ContraPro từ tiếng Anh sang tiếng Đức, cho thấy phương pháp của chúng tôi có thể cải thiện đáng kể sự nhất quán của thực thể.

Phương pháp 2

Chúng tôi sử dụng mô hình ngôn ngữ lớn (LLM) như một công cụ chỉnh sửa tự động (APE) để cải thiện chất lượng dịch của các mô hình dịch máy thần kinh (NMT) cấp câu. Chúng tôi chỉ sử dụng dữ liệu đơn ngữ cấp tài liệu và kết hợp với hai mô hình NMT cấp câu để xây dựng dữ liệu huấn luyện giả cấp tài liệu thông qua một vòng dịch ngược và một vòng dịch xuôi, để tinh chỉnh LLM. Do có sự khác biệt giữa dữ liệu giả và dữ liệu thực, trong giai đoạn huấn luyện, chúng tôi sử dụng LLM để vượt qua khoảng cách này. Quy trình suy luận của hệ thống dịch dựa trên APE là một quá trình dây chuyền: 1) Thu được bản dịch bằng mô hình NMT cấp câu. 2) Chỉnh sửa bản dịch bằng mô hình APE.


2.1 Sử dụng Mô hình Ngôn ngữ Lớn như APE

APE là một lĩnh vực con của dịch máy tự động sửa chữa các lỗi tồn tại trong kết quả dịch máy. Dữ liệu huấn luyện cho mô hình APE bao gồm dữ liệu ba phần: câu nguồn (SRC), kết quả dịch máy (MT) và câu sau khi được chỉnh sửa (PE). Trong quá trình huấn luyện, APE có thể được chia thành hai chế độ dựa trên việc có sử dụng câu nguồn (SRC) hay không.

$$L(\theta) = \arg \max_{\theta} \log P(PE|MT; \theta) \quad (1)$$

$$L(\theta) = \arg \max_{\theta} \log P(PE|(SRC, MT); \theta) \quad (2)$$

trong đó θ là tham số của mô hình APE.



Hình 1: Phía bên trái là quy trình xây dựng dữ liệu đào tạo APE với ngôn ngữ đơn và sử dụng mô hình dịch máy (NMT), và phía bên phải là hai chế độ dữ liệu cần thiết để đào tạo APE.

Lợi thế của công thức 1 là khả năng xây dựng dữ liệu huấn luyện mà không cần dữ liệu song ngữ, bằng cách tận dụng mô hình NMT ngược và dữ liệu đơn ngữ từ phía đích. Tuy nhiên, cách tiếp cận này có thể làm tăng lỗi trong dịch máy. Ngược lại, công thức 2 có thể đồng thời sử dụng cả thông tin SRC và MT, nhưng yêu cầu dữ liệu song ngữ đã được căn chỉnh.

2.2 Tạo dữ liệu song ngữ cấp độ pseudo-dữ liệu

Như được minh họa trong hình 1, chúng tôi xây dựng dữ liệu song ngữ giả cấp tài liệu thông qua các bước sau:

1. Chọn các corpus đơn ngữ trong ngôn ngữ mục tiêu và trích xuất một chuỗi n câu liên tiếp $D_{tgt}^{natural} = \{tgt_1^{natural}, tgt_2^{natural}, \dots, tgt_n^{natural}\}$ từ nó.

2. Đối với tất cả các câu từ 1 đến n , dịch chúng sử dụng mô hình dịch máy mục tiêu đến nguồn để thu được $D_{src}^{mt} = \{src_1^{mt}, src_2^{mt}, \dots, src_n^{mt}\}$. Sau đó, dịch D_{src}^{mt} đã được dịch sử dụng mô hình dịch máy nguồn đến mục tiêu để thu được $D_{tgt}^{mt} = \{tgt_1^{mt}, tgt_2^{mt}, \dots, tgt_n^{mt}\}$. Việc giải mã của các mô hình dịch mạng đều dựa trên thuật toán tìm kiếm chùm và kích thước chùm là 5.

3. Đối với việc đào tạo APE, D_{src}^{mt} và D_{tgt}^{mt} được sinh ra bởi mô hình NMT là SRC và MT, trong khi dữ liệu đơn ngữ $D_{tgt}^{natural}$ tương ứng với PE. Hình thức dữ liệu huấn luyện tương ứng với công thức 1 là chỉ chế độ MT: $D_{tgt}^{mt} \rightarrow D_{tgt}^{natural}$, trong khi đó tương ứng với công thức 2 là chế độ SRC với MT: $D_{src}^{mt}, D_{tgt}^{mt} \rightarrow D_{tgt}^{natural}$.

2.3 Hợp Lỗ Giữa Giai Đoạn Huấn Luyện và Suy luận

Từ trực giác, SRC với chế độ MT nên hoạt động tốt hơn vì nó tận dụng thông tin từ văn bản gốc. Thật ra, mô hình APE của chúng tôi cũng dựa trên SRC với

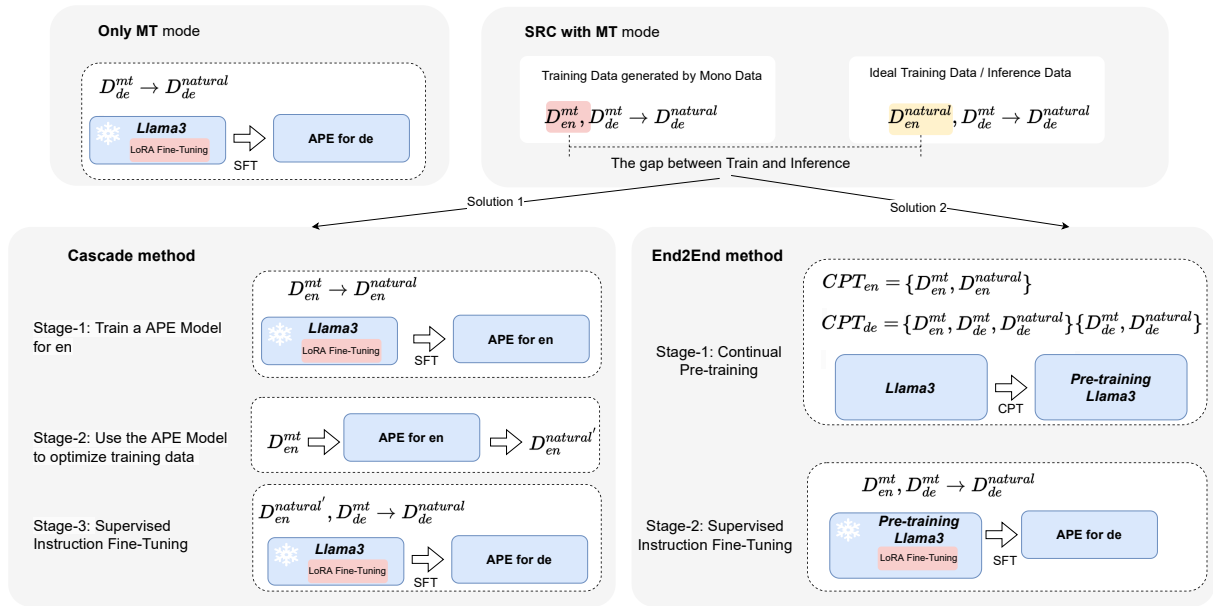
Chế độ MT. Tuy nhiên, kết quả thí nghiệm sau đó cho thấy việc huấn luyện trực tiếp trên dữ liệu giả sử sử dụng SRC với chế độ MT dẫn đến lợi ích tiêu cực. Lý do chính của vấn đề này là sự khác biệt đáng kể giữa SRC trong dữ liệu huấn luyện, đó là D_{src}^{mt} , và SRC trong quá trình suy luận, đó là $D_{src}^{natural}$. Để vượt qua khoảng cách này, chúng tôi đề xuất hai phương pháp (để diễn đạt rõ ràng hơn, chúng tôi cung cấp một ví dụ sử dụng nhiệm vụ dịch thuật nơi ngôn ngữ nguồn là tiếng Anh (en) và ngôn ngữ mục tiêu là tiếng Đức (de)). Hình 2 chi tiết về hai phương pháp huấn luyện của chúng tôi:

Phương pháp thác nước: Đầu tiên, chúng ta lấy tiếng Anh làm ngôn ngữ mục tiêu và xây dựng dữ liệu huấn luyện $D_{en}^{mt} \rightarrow D_{en}^{natural}$ chỉ với chế độ dịch máy (MT), và sử dụng công thức 1 để huấn luyện mô hình ngôn ngữ lớn (LLM) như APE_{en} .

Sau đó, lấy tiếng Đức làm ngôn ngữ mục tiêu, chúng tôi xây dựng dữ liệu huấn luyện $D_{de}^{mt}, D_{de}^{mt} \rightarrow D_{de}^{natural}$ với SRC trong chế độ MT, sử dụng APE_{en} để chỉnh sửa sau dịch trên D_{en}^{mt} và thu được $D_{en}^{natural}$, thu được dữ liệu huấn luyện cuối cùng $D_{de}^{natural}, D_{de}^{mt} \rightarrow D_{de}^{natural}$, và tinh chỉnh trên mô hình ngôn ngữ lớn (LLM) với dữ liệu huấn luyện cuối cùng để thu được mô hình APE cuối cùng.

Phương pháp End2End: Chúng tôi sử dụng tiếng Anh làm ngôn ngữ mục tiêu và xây dựng dữ liệu huấn luyện $CPT_{en} = \{D_{en}^{mt}, D_{en}^{natural}\}$, bằng chế độ Chỉ MT. Đồng thời, chúng tôi sử dụng tiếng Đức làm ngôn ngữ mục tiêu và xây dựng $CPT_{de} = \{\{D_{de}^{mt}, D_{de}^{natural}\}, \{D_{en}^{mt}, D_{de}^{mt}, D_{de}^{natural}\}\}$, bằng cả hai chế độ.

Đối với dữ liệu huấn luyện trong giai đoạn tiền huấn luyện liên tục (CPT), chúng tôi giới thiệu thể dòng mới giữa các câu dịch máy (MT) và các câu ngôn ngữ tự nhiên. Chúng tôi trước tiên tiền huấn luyện mô hình ngôn ngữ lớn (LLM) như LLM_{pre} với dữ liệu này. Dữ liệu CPT_{en} được thiết kế để giúp LLM điều chỉnh sự khác biệt về phong cách giữa văn bản gốc dịch máy và tự nhiên; dữ liệu CPT_{de} nhằm trang bị cho LLM một số khả năng APE của ngôn ngữ mục tiêu trong quá trình tiền huấn luyện. Trong quá trình tiền huấn luyện



Hình 2: Ở phần trên của hình này có hai chế độ áp dụng APE để tối ưu hóa MT sử dụng LLM: Chế độ chỉ MT và chế độ SRC với MT. Dưới đây là hai phương pháp được đề xuất để giải quyết khoảng cách giữa huấn luyện và suy luận trong chế độ SRC với MT, xuất phát từ việc sử dụng dữ liệu huấn luyện đơn ngữ được xây dựng. Phía bên trái là phương pháp Cascade, nơi mô hình LLM đầu tiên tối ưu hóa văn bản nguồn trước khi huấn luyện mô hình. Phía bên phải là phương pháp End2End, trong đó bao gồm hai loại dữ liệu khác nhau (MT và dữ liệu tự nhiên) trong giai đoạn tiền huấn luyện, cho phép mô hình LLM học các mối quan hệ cơ bản giữa hai loại dữ liệu này và sau đó đạt được kết quả tốt hơn ở giai đoạn SFT.

during training, we utilize a word dropout ($=0.1$) (Sen-nrich et al., 2016) strategy to ensure training convergence.

Tiếp theo, bằng cách lấy tiếng Đức làm ngôn ngữ mục tiêu, chúng tôi sử dụng SRC với chế độ MT để xây dựng dữ liệu huấn luyện $D_{en}^{mt}, D_{de}^{mt} \rightarrow D_{de}^{natural}$. Chúng tôi áp dụng trực tiếp dữ liệu huấn luyện đã xây dựng để fine-tune mô hình tiền huấn luyện LLM_{pre} với kỹ thuật huấn luyện fine-tune giám sát (SFT), kết quả là một mô hình APE.

2.4 Kết luận

Vì việc dịch tài liệu liên quan đến ngữ cảnh, nên việc giải mã nó tương đối phức tạp và hiện nay có một số phương pháp giải mã: 1) Chunk-Based, đây là một phương pháp đơn giản chia tài liệu cần dịch thành các đoạn có kích thước gần như bằng nhau không chồng lấp và dịch chúng độc lập; 2) Batched Sliding Window, được đề xuất bởi Post và Junczys-Dowmunt (2024), dịch tài liệu bằng cách thêm câu cần dịch với ngữ cảnh trước đó, sử dụng phương pháp cửa sổ trượt với tải trọng và lấy ra câu cuối cùng sau khi dịch toàn bộ đoạn; 3) Sequential Decoding, được đề xuất bởi Herold và Ney (2023), thêm ngữ cảnh nguồn bên trái và sử dụng giải mã bắt buộc của bản dịch câu trước đó làm ngữ cảnh mục tiêu trong bước tiếp theo, dịch

Kết quả của Koneru et al. (2024) cho thấy các hiệu ứng của ba phương pháp giải mã này tương tự nhau, vì vậy trong bài viết này, chúng tôi chỉ sử dụng phương pháp giải mã dựa trên khối (chunk-based), trong đó kích thước của mỗi khối liên quan đến độ dài chuỗi tối đa trong quá trình suy luận.

3 Thiết Bị Thí Nghiệm

Mô hình: Chúng tôi sử dụng hai mô hình NMT cấp câu, từ nguồn đến mục tiêu và từ mục tiêu đến nguồn, để hỗ trợ trong việc tạo dữ liệu huấn luyện. Cấu trúc của mô hình NMT cấp câu là transformer-big, với bộ mã hóa và bộ giải mã gồm 25 và 6 lớp tương ứng. Nó được huấn luyện ban đầu trên dữ liệu tiếng Anh-Giảm thể từ WMT2023¹, sau đó được tinh chỉnh bằng tập dữ liệu MuST-C V3 (Di Gangi et al., 2019). Đối với mô hình MLL, chúng tôi tiến hành các thí nghiệm sử dụng mô hình nguồn mở mới nhất Llama3-8B² của Meta. Trong quá trình huấn luyện, chúng tôi đã che mắt trên prompt, có nghĩa là mô hình MLL chỉ được huấn luyện để dự đoán tham chiếu dựa trên nguồn và giả thuyết được cung cấp. Chúng tôi đã sử dụng thư viện transformers để huấn luyện và suy luận với Llama3. Khi huấn luyện các adapter, chúng tôi tiếp tục

¹<https://www2.statmt.org/wmt23/translation-task.html>

²<https://llama.meta.com/llama3/>

Xác định các siêu tham số với thứ tự hạng 8, alpha 32, dropout 0.1 và đặt độ lệch như 'LoRA_only'. Theo phương pháp của Dettmers et al. (2023) để tăng cường khả năng chống chịu của mô hình đối với siêu tham số LoRA, chúng tôi đã điều chỉnh trên tất cả các lớp. Các mô-đun được thêm vào adapter bao gồm q_proj , k_proj , v_proj , $gate_proj$, up_proj và $down_proj$. Trong quá trình huấn luyện và suy luận, chúng tôi đặt số lượng tối đa của token là 1024.

Dữ liệu tập tin: Chúng tôi sử dụng bộ dữ liệu MuST-C V3 làm dữ liệu huấn luyện và kiểm thử chính; ngoài ra, để xác minh xem dữ liệu monolingual cấp độ tài liệu quy mô lớn hơn có thể cải thiện kết quả hay không, chúng tôi chọn 100,000 tài liệu từ bộ dữ liệu MC4 (Xue et al., 2021).

Tiêu Chuẩn Đánh Giá Chúng tôi sử dụng COMET-22 (COMET) (Rei et al., 2022) làm tiêu chuẩn đánh giá chính, và thêm vào đó sử dụng BLEU cấp câu (sentence-level BLEU) (Papineni et al., 2002) và SacreBLEU cấp tài liệu (document-level SacreBLEU) (Liu et al., 2020) để đánh giá chất lượng dịch, được ký hiệu là s-bleu và d-bleu tương ứng.

Đánh giá Sự nhất quán Chúng tôi cũng báo cáo điểm số của ContraPro (Müller et al., 2018) để đánh giá giải pháp cụ thể về ngữ cảnh cho sự mơ hồ của đại từ. Chúng tôi đã xây dựng tập dữ liệu kiểm tra dựa trên phương pháp được đề xuất trong Koneru et al. (2024) và công cụ gắn nhãn MuDA (Fernandes et al., 2023), và đã đánh giá ba tiêu chí: Đại từ, Ngôn ngữ trang trọng, và Liên kết từ vựng.

4 Kết quả chính

Để kiểm chứng hiệu quả của phương pháp mà chúng tôi đề xuất, chúng tôi đã chọn một nhiệm vụ dịch từ tiếng Anh sang tiếng Đức trên tập dữ liệu MUST-C V3. Chúng tôi đánh giá các cấu hình sau: Translated Text:

Sen2Sen: Đây là mô hình NMT cấp độ câu. Quy trình sinh ra của nó bao gồm việc huấn luyện ban đầu trên tập dữ liệu tiếng Anh-tiếng Đức được cung cấp bởi WMT2023, sau đó là việc tinh chỉnh trên MuST-C V3. Đây là một mô hình cơ sở mạnh mẽ và chất lượng của các bản dịch sinh ra tương đương với một số mô hình NMT thương mại.

Llama3 Few shot APE: Chúng tôi xây dựng một số prompt để hướng dẫn Llama3 thực hiện post-edit trên MT. Mọi prompt của chúng tôi đều tuân theo định dạng của Koneru et al. (2024).

Dữ liệu llama3 MT Sen2Sen: Chúng tôi xử lý tập dữ liệu của MuST-C V3 thành dữ liệu huấn luyện được định dạng ở cấp độ câu và sử dụng llama3 để tinh chỉnh LoRA.

Llama3 MT Doc2Doc: Chúng tôi xử lý tập dữ liệu MuST-C V3 thành dữ liệu huấn luyện song ngữ thực tế.

Dữ liệu tập C V3 được chuyển đổi thành dữ liệu tài liệu đồng bộ hóa độ dài gần như bằng nhau sử dụng phương pháp dựa trên Chunk, và thực hiện việc fine-tuning Lora sử dụng Llama3.

APE cho tài liệu-Doc: Chúng tôi sử dụng dữ liệu song ngữ cấp độ tài liệu trong MuST-C V3 để tái tạo phương pháp được đề xuất trong Koneru et al. (2024) dựa trên Llama3 và mô hình dịch máy từ-ngôn ngữ đích.

APE cho Cascade: Dựa trên phương pháp Cascade, chúng tôi đầu tiên sử dụng dữ liệu tiếng Anh từ MuST-C V3 để huấn luyện APE_{en} , sau đó sử dụng dữ liệu tiếng Đức từ MuST-C V3 để xây dựng dữ liệu pseudo-document, và sử dụng APE_{en} để thực hiện PE trên dữ liệu tương ứng $D_{en}^{mt}, D_{de}^{mt} \rightarrow D_{de}^{natural}$, cuối cùng thu được mô hình đã được huấn luyện bởi công thức 2.

APE cho End2End: Dựa trên phương pháp End2End, chúng tôi đầu tiên sử dụng riêng biệt en và de từ MuST-C V3 làm ngôn ngữ mục tiêu để sinh dữ liệu huấn luyện cho Only MT, tiền huấn luyện trên Llama3. Sau đó, chúng tôi sử dụng dữ liệu pseudo-document sinh ra với de làm ngôn ngữ mục tiêu từ SRC với MT và thu được mô hình huấn luyện với công thức 2.

APE cho Mô hình Đơn lớn: Đầu tiên, một thể tích lớn hơn của dữ liệu Mono (100.000) được trích xuất từ tập dữ liệu MC4, và sau đó huấn luyện được thực hiện dựa trên phương pháp APE cho End2End.

4.1 Tự động sau chỉnh sửa là cần thiết.

Vì Llama3 đã đạt được những cải tiến đáng kể so với Llama2 (Touvron và cộng sự, 2023) cả về phương pháp huấn luyện lẫn khối lượng dữ liệu, chúng ta cần đánh giá lại liệu APE cho các mô hình ngôn ngữ lớn (LLM) vẫn còn hiệu quả hay không. Như được trình bày trong Bảng 1, chúng tôi đầu tiên sử dụng một lời nhắc để hướng dẫn Llama3 thực hiện chỉnh sửa hậu kỳ trên MT, đây là kết quả của Llama3 Few-shot APE. Rõ ràng Llama3 thực sự sở hữu khả năng chỉnh sửa hậu kỳ mạnh mẽ, có thể nâng cao chất lượng bản dịch. Ngoài ra, phương pháp APE vượt trội hơn so với việc sử dụng trực tiếp các LLM cho dịch thuật, chẳng hạn như Llama3 MT Doc2Doc và Llama3 MT Sen2Sen, với mức cải thiện hơn 0,5 điểm trên các chỉ số s-bleu, d-bleu và COMET. Kết luận "Chỉnh sửa hậu kỳ tự động là cần thiết", được Koneru và cộng sự (2024) đưa ra trên Llama2, đã được xác nhận thêm trên Llama3.

4.2 Dữ liệu Đơn ngôn ngữ Cấp Tài liệu Có Hiệu quả

Như được trình bày trong Bảng 1, trong trường hợp chỉ sử dụng dữ liệu đơn ngôn ngữ, các phương pháp Cascade và End2End mà chúng tôi đề xuất có thể đạt gần kết quả thu được bởi (Koneru et al., 2024) khi sử dụng dữ liệu song ngữ thực tế.

Hệ thống s-bleu d-bleu	COMET	Từ loại	Ngữ điệu	Từ vựng	Liên kết từ	P R F1	P R F1	P R F1	
Khoản đoạn đến đoạn	34,63	38,78	84,68	0,67	0,77	0,72	0,70	0,72	0,71
phỏng APE	34,70	38,84	84,85	0,67	0,78	0,72	0,71	0,73	0,71
đoạn đến đoạn	31,29	35,52	85,03	0,66	0,76	0,71	0,68	0,71	0,69
Khoản tài liệu đến tài liệu	34,30	38,60	85,62	0,69	0,81	0,75	0,72	0,80	0,76
đoạn-Đoc	35,03	39,27	85,85	0,70	0,83	0,76	0,75	0,82	0,78
APE cho chuỗi	34,85	38,81	85,76	0,69	0,81	0,75	0,73	0,80	0,76
	34,74	38,71	85,71	0,69	0,80	0,74	0,72	0,80	0,76
	0,71	0,82	0,76	0,75	0,81	0,78	0,63	0,78	0,70

Bảng 1: So sánh các phương pháp tối ưu hóa dịch thuật với Llama3. Đối với việc giải mã tài liệu, chúng tôi sử dụng giải mã dựa trên đoạn. Chúng tôi báo cáo các chỉ số như s-bleu, d-bleu, COMET, MuDA tagger. Điểm số tốt nhất trong mỗi chỉ số được gạch chân đậm.

Hệ thống Contra(%) Sen2Sen	Hệ thống s-bleu d-bleu COMET Sen2Sen
66,7 APE cho para-Đoc	87,3
APE cho Cascade	80,2 APE
cho End2End	79,5

34,63	38,78	84,68	APE cho đoạn-Đoc	35,03	39,27
85,85	APE cho chỉ MT	34,64	38,87	85,16	APE
cho SRC với MT	32,90	37,03	84,60	APE cho	
Cascade	34,85	38,81	85,76	APE cho End2End	
34,74	38,71	85,71			

Bảng 2: So sánh độ chính xác của APE trong tài liệu trên tập thử nghiệm ContraPro tiếng Anh→Đức.

So sánh với kết quả của Sen2Sen, các bản dịch NMT sau khi được cải thiện bằng LLM được huấn luyện lại theo phương pháp mà chúng tôi đề xuất cho APE, chỉ có những thay đổi nhỏ về s-bleu và d-bleu, nhưng có sự tăng 1 điểm trong COMET cùng với mức độ cải thiện khác nhau về các chỉ số Pronouns, Formality và Lexical Cohesion. Sau khi giới thiệu 100,000 dữ liệu đơn ngữ cấp độ tài liệu, phương pháp của chúng tôi (APE for Large Mono) có thể vượt trội đáng kể so với kết quả từ dữ liệu song ngữ trên nhiều chỉ số. Điều này chứng minh rằng việc sử dụng dữ liệu đơn ngữ cấp độ tài liệu cho APE là hiệu quả.

4.3 Nâng cao APE cho hiện tượng ngữ cảnh

Trong bảng 1, ba chỉ số về Đại từ, Sự trang trọng và Liên kết từ vựng được xây dựng trong tập thử nghiệm của chúng tôi bằng cách tham chiếu các phương pháp được đề xuất bởi Koneru et al. (2024) và công cụ gắn nhãn MuDA (Fernandes et al., 2023). Chúng tôi cũng chọn các bài phát biểu có số lượng nhân cao nhất cho mỗi hiện tượng, dẫn đến 14 bài phát biểu trong tập thử nghiệm của chúng tôi, giải quyết các trường hợp liên quan đến đại từ, sự trang trọng và liên kết từ vựng. Sau đó, chúng tôi loại bỏ các bài phát biểu đã chọn khỏi dữ liệu huấn luyện và sử dụng chúng để kiểm tra. Kết quả thí nghiệm cho thấy cả hai phương pháp Cascade và End2End đều cải thiện diễn ngôn

Bảng 3: So sánh tác động của việc sử dụng các dạng khác nhau của SRC trong dữ liệu huấn luyện.

thuộc tính của NMT.

Chúng tôi tiếp tục xác thực việc cải thiện APE trong việc phân giải nghĩa cho đại từ sử dụng tập dữ liệu thử nghiệm ContraPro, đây là một chuẩn đánh giá đặc biệt được thiết kế để đánh giá khả năng phân giải nghĩa cho đại từ, cụ thể là "Er" (nam tính), "Sie" (nữ tính) và "Es" (trung tính) khi dịch từ tiếng Anh sang tiếng Đức. Chúng tôi tham chiếu phương pháp đánh giá từ Post và Junczys-Dowmunt (2024); Koneru et al. (2024). Bảng 2 cho thấy, mặc dù phương pháp được đề xuất của chúng tôi có 7 khác biệt so với APE cho para-Đoc, cả Cascade và End2End đều cho thấy sự cải thiện hơn 13 điểm trên cơ sở Sen2Sen.

Kết quả trên cho thấy rằng LLM rất phù hợp để xử lý các tác vụ liên quan đến thông tin ngữ cảnh và đóng một vai trò rất nổi bật trong các hiện tượng ngữ cảnh.

5 Phân tích

5.1 Xây dựng cây cầu giữa giai đoạn huấn luyện và suy luận

Trong Phần 2.3, đã đề cập đến vấn đề không phù hợp giữa quá trình đào tạo và suy luận, và đã nêu lên vài tập dữ liệu thử -

Dữ liệu huấn luyện s-bleu d-bleu COMET
cơ sở (Sen2Sen) 34,63 38,78 84,68 APE cho
End2End 34,74 38,71 85,71 mẫu ngẫu nhiên
34,48 38,54 84,71 mẫu lĩnh vực 34,62 38,67
85,42

Bảng 4: Kết quả của việc tiến hành thí nghiệm trên các tập dữ liệu khác nhau sử dụng phương pháp End2End.

Thí nghiệm được thiết kế để minh họa và giải quyết vấn đề này. Như được hiển thị trong Bảng 3, APE cho Only MT và APE cho SRC với MT được thu được bằng cách tạo dữ liệu sử dụng Only MT và SRC với MT tương ứng trong Phần 2.2, sau đó huấn luyện APE. APE cho Only MT có thể cải thiện COMET bằng 0,5; tuy nhiên, với sự thêm vào của SRC, D_{src}^{mt} kết quả của APE cho SRC với MT đã giảm hơn 1 điểm ở cả s-bleu và d-bleu, và cũng có một sự giảm nhẹ ở COMET. Điều này cho thấy việc sử dụng trực tiếp D_{src}^{mt} không mang lại lợi ích tích cực cho APE.

Quá trình đào tạo của APE cho SRC với MT và APE cho tài liệu phụ (para-Doc) hoàn toàn giống nhau, nhưng mang lại kết quả khác biệt đáng kể, chỉ ra khoảng cách đáng kể giữa D_{src}^{mt} được sử dụng trong quá trình đào tạo và $D_{src}^{natural}$ được sử dụng trong quá trình suy luận. Trong các thí nghiệm tiếp theo của chúng tôi, chúng tôi so sánh và phân tích sự khác biệt giữa văn bản nguồn giả và văn bản nguồn thực tế. Chúng tôi đã đào tạo một phân loại nhị phân cho D_{src}^{mt} và $D_{src}^{natural}$ sử dụng fast-text, và phát hiện rằng 87% dữ liệu có thể được phân biệt. Tuy nhiên, sau khi áp dụng phương pháp Cascade vào D_{src}^{mt} , chỉ có 58% dữ liệu có thể được phân loại chính xác. Kết quả của APE cho Cascade cho thấy so với APE cho SRC với MT, s-bleu, d-bleu và COMET đều cho thấy cải thiện hơn 1 điểm, chỉ ra rằng phương pháp Cascade mà chúng tôi đề xuất có thể kết nối khoảng cách giữa D_{src}^{mt} và $D_{src}^{natural}$ hiệu quả.

Vấn đề của APE cho Cascade nằm ở chỗ việc sử dụng mô hình ngôn ngữ lớn (LLM) để tạo dữ liệu huấn luyện là một phương pháp tốn kém và thiếu gọn gàng. Chúng tôi tin rằng LLM có thể ẩn chứa khả năng khớp của D_{src}^{mt} và $D_{src}^{natural}$. Kết quả của APE cho End2End cho thấy, thông qua quá trình huấn luyện trong giai đoạn tiền huấn luyện, LLM có thể giải quyết khoảng cách này, mặc dù vẫn còn một sự khác biệt rất nhỏ so với Cascade.

5.2 Dữ liệu rò rỉ có dẫn đến những kết quả tích cực không?

Trong phương pháp End2End, chúng tôi sử dụng cả Nguồn và Mục tiêu của dữ liệu MuST-C V3 như dữ liệu đơn ngữ. Liệu điều này có thể gây rò rỉ dữ liệu song ngữ hay không?

Vấn đề nào xảy ra trong giai đoạn tiền huấn luyện? Chúng tôi đã thiết lập các thí nghiệm sau để xác minh điều này:

Mẫu ngẫu nhiên: Để duy trì tính nhất quán với tập dữ liệu của MuST-C, đã ngẫu nhiên rút ra 2500 tài liệu tiếng Anh và 2500 tài liệu tiếng Đức từ tập dữ liệu mC4.

Tiểu mục mẫu miền: fast-text³ được sử dụng để phân loại tập MC4 theo miền, và đã chọn lần lượt 2500 tài liệu tiếng Anh và 2500 tài liệu tiếng Đức gần với miền của MuST-C.

Tiếp theo, phương pháp APE cho End2End được sử dụng để thử nghiệm trên hai phương pháp lựa chọn dữ liệu được đề cập ở trên. Như được hiển thị trong bảng 4, cải thiện của mẫu ngẫu nhiên tương đối nhỏ, trong khi kết quả của mẫu miền có thể tiếp cận cơ bản với kết quả thu được bằng cách sử dụng dữ liệu MuST-C (APE cho End2End). Điều này cho thấy không có vấn đề về rò rỉ dữ liệu, và việc cải thiện chất lượng chủ yếu liên quan đến việc thích ứng miền trong MLL.

5.3 Tác động của quy mô dữ liệu huấn luyện

Chúng tôi cũng đã thực nghiệm về tác động của lượng dữ liệu monolingual khác nhau đối với chất lượng APE. Số lượng dữ liệu của MUST-C V3 là 2537 tài liệu. Chúng tôi cũng sử dụng phương pháp lấy mẫu từ MC4 để chọn 2500, 5000, 10000, 20000, 40000 và 100000 tài liệu cho các thí nghiệm quy mô dữ liệu khác nhau. Bảng 5 cho thấy rằng khi số lượng dữ liệu tăng lên, chất lượng APE thực sự được cải thiện. Khi sử dụng 20000 tài liệu, chất lượng mô hình đã vượt qua kết quả của para-Doc. Tăng thêm số lượng dữ liệu dẫn đến sự cải thiện chất lượng giảm dần, và không có cải thiện đáng kể nào trong kết quả sau 40000 tài liệu.

5.4 Tính linh hoạt của APE

Chúng tôi muốn biết liệu hệ thống APE được đào tạo bằng pseudo-corpus được xây dựng bởi một hệ thống NMT có thể được thích nghi cho các hệ thống NMT khác hay không. Chúng tôi đã chia dữ liệu huấn luyện của NMT thành hai phần và đào tạo hai mô hình NMT: nmt_1 và nmt_2 . Sau đó, chúng tôi sử dụng hai mô hình NMT này với phương pháp End2End để đào tạo APE riêng biệt, thu được ape_2 và ape_1 . Bảng 6 cho thấy các hệ thống NMT khác nhau chỉ có thể đạt được sự thích nghi tốt hơn khi được đào tạo bằng pseudo-corpus do chính hệ thống NMT của họ tạo ra; khi nmt_1 được kết hợp với ape_2 và nmt_2 được kết hợp với ape_1 , sự cải thiện trong hiệu suất của COMET có phần giảm đi. Điều này cho thấy

³<https://github.com/facebookresearch/fastText>

Độ lớn dữ liệu huấn luyện	2500	5000	10000	20000	40000	100000	para-Doc
COMET	85.42	85.64	85.76	86.16	86.42	86.50	85.85

Bảng 5: So sánh tác động của việc sử dụng các quy mô dữ liệu mẫu miền khác nhau.

NMT	APE	COMET
nmt_1	84,52	nmt_2 84,55
nmt_1	ape_1	85,61
nmt_1	ape_2	85,23
nmt_2	ape_1	85,30
nmt_2	ape_2	85,58

Bảng 6: Kết quả của COMET khi ghép cặp hai mô hình dịch máy học và APE trong các kết hợp đôi.

đó là hệ thống APE của chúng tôi có một số độ tổng quát, nhưng kết quả tối ưu chỉ có thể đạt được khi sử dụng cùng với NMT được sử dụng để xây dựng dữ liệu huấn luyện.

6 Related WorkTrở thành:6 Công trình liên quan

Trong thời đại huấn luyện các mô hình NMT với mẫu sequence-to-sequence, nhiều phương pháp đã được đề xuất để tối ưu hóa việc dịch tài liệu. Bắt đầu từ Tiedemann và Scherrer (2017), các câu liên kết trong ngữ cảnh đã được sử dụng để hỗ trợ việc dịch câu hiện tại. Agrawal et al. (2018); Zhang et al. (2022) và những người khác cũng đã chứng minh rằng việc dịch nhiều câu cùng một lúc có thể cải thiện chất lượng dịch. Thêm vào đó, nhiều phương pháp mới về kiến trúc mô hình như HAN (Miculicich et al., 2018), SAN (Maruf et al., 2019), HYBRID (Zheng et al., 2020), FLATTRANS (Ma et al., 2020), GTRANS (Bao et al., 2021) đã được đề xuất để mã hóa thông tin tài liệu tốt hơn; do thiếu dữ liệu tài liệu tương ứng, các phương pháp tăng cường dữ liệu như MULTIRRES (Sun et al., 2022), IADA (Wu et al., 2024b) cũng đã được đề xuất để tận dụng hiệu quả dữ liệu tương ứng hạn chế; ngoài ra, phương pháp DocRepair (Voita et al., 2019) có thể sử dụng dữ liệu đơn ngữ ở cấp độ tài liệu, kết hợp với chế độ encoder-decoder của mô hình APE, để cải thiện sự nhất quán của dịch; Feng et al. (2022) sử dụng công nghệ bộ nhớ đệm để lưu trữ thông tin toàn cục nhằm tăng cường thông tin cục bộ của câu hiện tại; và phương pháp DocRerank do Yu et al. (2020) đề xuất đã sắp xếp lại kết quả của các mô hình cấp câu trong giai đoạn giải mã, chọn các câu hoặc token có độ nhất quán tài liệu cao.

Chương trình đào tạo sau đại học (LLM) đã đạt được kết quả rất ấn tượng trong một số lượng lớn các nhiệm vụ xử lý ngôn ngữ tự nhiên. Đồng thời, ngày càng nhiều người đang nghiên cứu về các mô hình lớn trong lĩnh vực dịch máy. Xu et al. (2024); Guo et al. (2024) tập trung chủ yếu vào nghiên cứu dịch máy cấp câu, tập trung vào cách tăng cường khả năng định vị đa ngôn ngữ của các mô hình lớn. Cũng có một số công việc (Ding et al., 2024; Gao et al., 2023) giới thiệu phương pháp Augmented Retrieval (RAG), kết hợp với bộ nhớ dịch (Mu et al., 2023; Moslem et al., 2023) hoặc để sửa chữa đầu ra hệ thống dịch máy (NMT) trong các prompt (Raunak et al., 2023; Chen et al., 2024). Wu et al. (2024a); Wang et al. (2023) đã nghiên cứu kỹ lưỡng việc cải thiện dịch tài liệu cấp độ bằng cách sử dụng các mô hình lớn; Koneru et al. (2024) đề xuất sử dụng LLM cho APE thay vì dịch trực tiếp, cũng mang lại kết quả tốt.

Kết luận7 Kết luận

Chúng tôi giới thiệu một phương pháp mới để nâng cao chất lượng dịch tài liệu bằng cách sử dụng chỉ dữ liệu đơn ngữ và mô hình ngôn ngữ lớn. Phương pháp này điều chỉnh chi tiết các mô hình ngôn ngữ lớn trên việc tự động chỉnh sửa sau dịch sử dụng các chiến lược mới để cải thiện kết quả của dịch máy thần kinh cấp câu. Chúng tôi đã xác định và giải quyết vấn đề không đồng nhất giữa chế độ huấn luyện và chế độ suy luận do việc sử dụng dữ liệu huấn luyện tổng hợp gây ra. Phương pháp này cải thiện đáng kể chất lượng và sự đồng nhất của dịch, như được xác nhận bởi điểm số đáng chú ý trên tập kiểm tra ContraPro, làm cho nó đặc biệt hữu ích trong các trường hợp mà dữ liệu song ngữ hiếm hoi.

8 Hạn chế

Phương pháp của chúng tôi, một hệ thống dây chuyền, bao gồm việc giải mã ban đầu với NMT sau đó là giải mã với LLM, dẫn đến độ trễ suy luận cao hơn và khuếch đại lỗi. Nó lý tưởng cho các trường hợp nguồn lực thấp, đặc biệt trong các lĩnh vực chuyên môn như sinh y, nơi dữ liệu song ngữ hạn chế. Nghiên cứu tương lai sẽ tập trung vào lĩnh vực này.

Tham chiếu

Ruchit Agrawal, Marco Turchi, và Matteo Negri. 2018. Xử lý ngữ cảnh trong dịch máy thần kinh: Nhìn về phía sau, phía trước và cả hai bên. Trong *Proceedings of the 21st Annual Conference of the European Association for Machine Translation*, trang 31–40, Alicante, Tây Ban Nha.

Alves Duarte M., Guerreiro Nuno M., Alves João, Pombal José, Rei Ricardo, de Souza José G. C., Colombo Pierre, và Martins André F. T. 2023. Điều khiển các mô hình ngôn ngữ lớn cho dịch máy với việc huấn luyện lại và học trong ngữ cảnh. *Preprint*, arXiv:2310.13448.

Rohan Anil, Andrew M. Dai, Orhan Firat, Melvin Johnson, Dmitry Lepikhin, Alexandre Passos, Siamak Shakeri, Emanuel Taropa, Paige Bailey, Zhifeng Chen, Eric Chu, Jonathan H. Clark, Laurent El Shafey, Yanping Huang, Kathy Meier-Hellstern, Gaurav Mishra, Erica Moreira, Mark Omernick, Kevin Robinson, Sebastian Ruder, Yi Tay, Kefan Xiao, Yuanzhong Xu, Yujing Zhang, Gustavo Hernández Abrego, Junwhan Ahn, Jacob Austin, Paul Barham, Jan Botha, James Bradbury, Siddhartha Brahma, Kevin Brooks, Michele Catasta, Yong Cheng, Colin Cherry, Christopher A. Choquette-Choo, Aakanksha Chowdhery, Clément Crépy, Shachi Dave, Mostafa Dehghani, Sunipa Dev, Jacob Devlin, Mark Díaz, Nan Du, Ethan Dyer, Vlad Feinberg, Fangxiaoyu Feng, Vlad Fienber, Markus Freitag, Xavier García, Sebastian Gehrmann, Lucas González, Guy Gur-Ari, Steven Hand, Hadi Hashemi, Le Hou, Joshua Howland, Andrea Hu, Jeffrey Hui, Jeremy Hurwitz, Michael Isard, Abe Ittycheriah, Matthew Jagiel-ski, Wenhao Jia, Kathleen Kenealy, Maxim Krikun, Sneha Kudugunta, Chang Lan, Katherine Lee, Benjamin Lee, Eric Li, Music Li, Wei Li, YaGuang Li, Jian Li, Hyeontaek Lim, Hanzhao Lin, Zhongtao Liu, Frederick Liu, Marcello Maggioni, Aroma Mahendru, Joshua Maynez, Vedant Misra, Maysam Moussalem, Zachary Nado, John Nham, Eric Ni, Andrew Nyström, Alicia Parrish, Marie Pellat, Martin Polacek, Alex Polozov, Reiner Pope, Siyuan Qiao, Emily Reif, Bryan Richter, Parker Riley, Alex Castro Ros, Aurko Roy, Brennan Saeta, Rajkumar Samuel, Renee Shelby, Ambrose Slone, Daniel Smilkov, David R. So, Daniel Sohn, Simon Tokumine, Dasha Valter, Vijay Vasudevan, Kiran Vodrahalli, Xuezhi Wang, Pidong Wang, Zirui Wang, Tao Wang, John Wieting, Yuhuai Wu, Kelvin Xu, Yunhan Xu, Linting Xue, Pengcheng Yin, Jiahui Yu, Qiao Zhang, Steven Zheng, Ce Zheng, Weikang Zhou, Denny Zhou, Slav Petrov, và Yonghui Wu. 2023. Báo cáo kỹ thuật Palm 2. *Preprint*, arXiv:2305.10403.

Hossein Bahak, Farzaneh Taheri, Zahra Zojaji, và Arefeh Kazemi. 2023. Đánh giá ChatGPT như một hệ thống trả lời câu hỏi: Một phân tích toàn diện và so sánh với các mô hình hiện có. *Preprint*, arXiv:2312.07592.

Quangsheng Bao, Yuê Trương, Chí Dương Tăng, Bóing Xích, và Vị Hứa Lỗ. 2021. G-transformer cho

Chuyển đổi văn bản cấp độ tài liệu tự động. Trong *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, trang 3442–3455, Trục tuyến. Hiệp hội Ngôn ngữ Tính toán.

Chén Binzhen, Guo Zhicheng, Barry Haddow, và Kenneth Heafield. 2024. Tinh chỉnh dịch thuật lặp lại với mô hình ngôn ngữ lớn. *Preprint*, arXiv:2306.03856.

Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, và Luke Zettlemoyer. 2023. Qlora: Tinh chỉnh hiệu quả các mô hình ngôn ngữ lớn đã được lượng hóa. *Preprint*, arXiv:2305.14314.

Mattia A. Di Gangi, Roldano Cattoni, Luisa Bentivogli, Matteo Negri, và Marco Turchi. 2019. MuST-C: một tập dữ liệu đa ngôn ngữ cho dịch thuật tiếng nói. Trong *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, trang 2012–2017, Minneapolis, Minnesota. Hiệp hội Ngôn ngữ Tính toán.

Ding Yujuan, Fan Wenqi, Ning Liangbo, Wang Shijie, Li Hengyun, Yin Dawei, Chua Tat-Seng, và Li Qing. 2024. Tổng quan về rag gặp llms: Hướng tới các mô hình ngôn ngữ lớn được tăng cường bằng hệ thống tìm kiếm. *Preprint*, arXiv:2405.06211.

Feng Yukun, Li Feng, Song Ziang, Zheng Boyuan, và Philipp Koehn. 2022. Học để nhớ: Transformer với bộ nhớ tái phát cho dịch máy cấp độ tài liệu. Trong *Findings of the Association for Computational Linguistics: NAACL 2022*, trang 1409–1420, Seattle, Hoa Kỳ. Hiệp hội Ngôn ngữ Tính toán.

Patrick Fernandes, Kayo Yin, Emmy Liu, André Martins, và Graham Neubig. 2023. Khi nào dịch thuật cần ngữ cảnh? một nghiên cứu đa ngôn ngữ dựa trên dữ liệu. Trong *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, trang 606–626, Toronto, Canada. Hiệp hội Ngôn ngữ Tính toán.

Gao Yunfan, Xiong Yun, Gao Xinyu, Jia Kangxiang, Pan Jinliu, Bi Yuxi, Dai Yi, Sun Jiawei, và Wang Haofen. 2023. Tổng quan về phương pháp tăng cường truy xuất cho mô hình ngôn ngữ lớn: *arXiv preprint arXiv:2312.10997*.

Guo Jiǎxiān, Yáng Hào, Lǐ Zōngyǎo, Wèi Dài Méng, Shàng Hénghào, và Chen Xiàoyǔ. 2024. Một phương án mới nâng cao khả năng dịch của các mô hình ngôn ngữ lớn. *Preprint*, arXiv:2403.11430.

Christian Herold và Hermann Ney. 2023. Nâng cao dịch máy cấp độ tài liệu với ngữ cảnh dài. Trong *Proceedings of the 4th Workshop on Computational Approaches to Discourse (CODI 2023)*, trang 112–125, Toronto, Canada. Hiệp hội Ngôn ngữ Tính toán.

Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, và Weizhu Chen. 2021. Lora: Tối ưu hóa hạng thấp của các mô hình ngôn ngữ lớn. *Preprint*, arXiv:2106.09685.

Sai Koneru, Miriam Exel, Matthias Huck, và Jan Niehues. 2024. Tinh chỉnh ngữ cảnh của bản dịch: Các mô hình ngôn ngữ lớn cho việc sửa đổi sau khi dịch ở cấp câu và cấp tài liệu. *Preprint*, arXiv:2310.14855.

Liu Chaoqun, Zhang Wenxuan, Zhao Yiran, Liu Anh Tuan, và Bing Lidong. 2024. Liệu dịch thuật có phải là tất cả mà chúng ta cần không? một nghiên cứu về giải quyết các tác vụ đa ngôn ngữ với mô hình ngôn ngữ lớn. *Preprint*, arXiv:2403.10258.

Yinhan Liu, Jiatao Gu, Naman Goyal, Xian Li, Sergey Edunov, Marjan Ghazvininejad, Mike Lewis và Luke Zettlemoyer. 2020. Tiên huấn luyện loại bỏ nhiễu đa ngôn ngữ cho dịch máy thần kinh. *Preprint*, arXiv:2001.08210.

Shuming Ma, Dongdong Zhang, và Ming Zhou. 2020. Một mã hóa viên thống nhất đơn giản và hiệu quả cho dịch máy cấp độ tài liệu. Trong *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, trang 3505–3511, Trực tuyến. Hiệp hội Ngôn ngữ Tính toán.

Sameen Maruf, André F. T. Martins, và Gholamreza Haffari. 2019. Chú ý chọn lọc cho dịch máy thần kinh nhận thức ngữ cảnh. Trong *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, trang 3092–3102, Minneapolis, Minnesota. Hiệp hội Ngôn ngữ Tính toán.

Lesly Miculicich, Dhananjay Ram, Nikolaos Pappas và James Henderson. 2018. Dịch máy thần kinh cấp độ tài liệu với mạng lưới chú ý phân cấp. Trong *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, trang 2947–2954, Brussels, Bỉ. Hiệp hội Ngôn ngữ Tính toán.

Yasmin Moslem, Rejwanul Haque, John D. Kelleher, và Andy Way. 2023. Dịch máy thích ứng với mô hình ngôn ngữ lớn. Trong *Proceedings of the 24th Annual Conference of the European Association for Machine Translation*, trang 227–237, Tampere, Phần Lan. Hiệp hội châu Âu về Dịch máy.

Mỗ Mu Yongyu, Abudurexiti Rehehan, Cao Zhiqian, Fan Yuchun, Li Bei, Li Yinqiao, Xiao Tong, Zhang Chun-liang, và Zhu Jingbo. 2023. Tăng cường dịch máy ngôn ngữ lớn thông qua bộ nhớ dịch. Trong *Findings of the Association for Computational Linguistics: ACL 2023*, trang 10287–10299, Toronto, Canada. Hiệp hội Ngôn ngữ Tính toán.

Mathias Müller, Annette Rios, Elena Voita, và Rico Sennrich. 2018. Một tập kiểm tra quy mô lớn cho việc đánh giá dịch từ của đại từ có ý thức ngữ cảnh trong dịch máy thần kinh. Trong *Proceedings of the Third*

Conference on Machine Translation: Research Paper trang 61–72, Brussels, Belgium. Hiệp hội Ngôn ngữ Tính toán.

Kishore Papineni, Salim Roukos, Todd Ward và Wei-Jing Zhu. 2002. Bleu: một phương pháp đánh giá tự động dịch máy. Trong *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, trang 311–318, Philadelphia, Pennsylvania, Hoa Kỳ. Hiệp hội Ngôn ngữ Tính toán.

Matt Post và Marcin Junczys-Dowmunt. 2024. Tránh khỏi mô thức dựa trên câu trong dịch máy. *Preprint*, arXiv:2304.12959.

Raunak Vikas, Sharaf Amr, Wang Yiren, Awadallah Hany Hassan, và Menezes Arul. 2023. Sử dụng gpt-4 cho việc chỉnh sửa tự động sau dịch thuật. *Preprint*, arXiv:2305.14878.

Ricardo Rei, José G. C. de Souza, Duarte Alves, Chrysoula Zerva, Ana C Farinha, Taisiya Glushkova, Alon Lavie, Luisa Coheur, và André F. T. Martins. 2022. COMET-22: Unbabel-IST 2022 submission cho nhiệm vụ chia sẻ chỉ số. Trong *Proceedings of the Seventh Conference on Machine Translation (WMT)*, trang 578–585, Abu Dhabi, United Arab Emirates (Hybrid). Hiệp hội Ngôn ngữ Tính toán.

Rico Sennrich, Barry Haddow và Alexandra Birch. 2016. Edinburgh neural machine translation systems for WMT 16. Trong *Proceedings of the First Conference on Machine Translation: Volume 2, Shared Task Papers*, trang 371–376, Berlin, Đức. Hiệp hội Ngôn ngữ Tính toán.

Zewei Sun, Mingxuan Wang, Hao Zhou, Chengqi Zhao, Shujian Huang, Jiajun Chen, và Lei Li. 2022. Xem lại dịch máy thần kinh cấp độ tài liệu. Trong *Findings of the Association for Computational Linguistics: ACL 2022*, trang 3537–3548, Dublin, Ireland. Hiệp hội Ngôn ngữ Tính toán.

Jörg Tiedemann và Yves Scherrer. 2017. Dịch máy thần kinh với ngữ cảnh mở rộng. Trong *Proceedings of the Third Workshop on Discourse in Machine Translation*, trang 82–92, Copenhagen, Đan Mạch. Hiệp hội Ngôn ngữ Tính toán.

Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, Dan Bikel, Lukas Blecher, Cristian Canton Ferrer, Moya Chen, Guillem Cucurull, David Esiobu, Jude Fernandes, Jeremy Fu, Wenyin Fu, Brian Fuller, Cynthia Gao, Vedanuj Goswami, Naman Goyal, Anthony Hartshorn, Saghar Hosseini, Rui Hou, Hakan Inan, Marcin Kardas, Viktor Kerkez, Madian Khabsa, Isabel Kloumann, Artem Korenev, Punit Singh Koura, Marie-Anne Lachaux, Thibaut Lavril, Jenya Lee, Diana Liskovich, Yinghai Lu, Yuning Mao, Xavier Martinet, Todor Mihaylov, Pushkar Mishra, Igor Molybog, Yixin Nie, Andrew Poulton, Jeremy Reizenstein, Rashi Rungta, Kalyan Saladi, Alan Schelten,

- Ruan Silva, Eric Michael Smith, Ranjan Subramanian, Xiaoqing Ellen Tan, Binh Tang, Ross Taylor, Adina Williams, Jian Xiang Kuan, Puxin Xu, Zheng Yan, Iliyan Zarov, Yuchen Zhang, Angela Fan, Melanie Kambadur, Sharan Narang, Aurelien Rodriguez, Robert Stojnic, Sergey Edunov, và Thomas Scialom. 2023. Llama 2: Mô hình trò chuyện nền tảng mở và được huấn luyện tinh vi. *Preprint*, arXiv:2307.09288.
- Voita Elena, Rico Sennrich, và Ivan Titov. 2019. Sửa đổi đa ngữ nhận thức cho dịch máy thần kinh. Trong *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, trang 877–886, Hong Kong, Trung Quốc. Hiệp hội Ngôn ngữ Tính toán.
- Vương Dài Biển, Lý Thừa Dương, Tích Thiên Bỗ, Trương Tự Trí, Ngử Diên, Thị Thăm Phong, và Tu Trác Bằng. 2023. Dịch máy cấp độ tài liệu với các mô hình ngôn ngữ lớn. Trong *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, trang 16646–16661, Singapore. Hiệp hội Ngôn ngữ Tính toán Tính toán.
- Daimeng Wei, Zhanglin Wu, Hengchao Shang, Zongyao Li, Minghan Wang, Jiaxin Guo, Xiaoyu Chen, Zhengzhe Yu, và Hao Yang. 2023. Chuyển đổi phong cách văn bản qua lại. Trong *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, trang 7944–7959, Toronto, Canada. Hiệp hội Ngôn ngữ Tính toán.
- Wu Minh Hào, Vũ Thụy Tràng, Chu Lệ Trân, Foster Джордж, và Haffari Golamrezā. 2024a. Tối ưu hóa mô hình ngôn ngữ lớn cho dịch máy cấp độ tài liệu. *Preprint*, arXiv:2401.06468.
- Wu Minh Hào, Vương Dật Phàm, Foster George, Khuất Lệ Thân, và Haffari Golamreza. 2024b. Tăng cường dữ liệu nhận thức quan trọng cho dịch máy thần kinh cấp độ tài liệu. Trong *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, trang 740–752, St. Julian's, Malta. Hiệp hội Ngôn ngữ Tính toán.
- Haoran Xu, Young Jin Kim, Amr Sharaf và Hany Hassan Awadalla. 2024. Một sự chuyển đổi mô hình trong dịch máy: Nâng cao hiệu suất dịch của các mô hình ngôn ngữ lớn. *Preprint*, arXiv:2309.11674.
- Xu Lin, Noah Constant, Adam Roberts, Mihir Kale, Rami Al-Rfou, Aditya Siddhant, Aditya Barua, và Colin Raffel. 2021. mt5: Một mô hình Transformer tiền huấn luyện đa ngôn ngữ quy mô lớn. *Preprint*, arXiv:2010.11934.
- Lei Yu, Laurent Sartran, Wojciech Stokowiec, Wang Ling, Lingpeng Kong, Phil Blunsom, và Chris Dyer. 2020. Tối ưu hóa dịch máy cấp độ tài liệu với quy tắc Bayes. *Preprint*, arXiv:1910.00553.
- Trần Bião, Ankur Bapna, Melvin Johnson, Ali Dabirmoghaddam, Naveen Arivazhagan, và Orhan Firat. 2022. Dịch thuật cấp tài liệu đa ngôn ngữ cho phép chuyển giao không cần huấn luyện từ câu thành tài liệu. *Preprint*, arXiv:2109.10341.
- Trần Bião, Barry Haddow và Alexandra Birch. 2023a. Kích hoạt mô hình ngôn ngữ lớn cho dịch máy: Một nghiên cứu trường hợp. *Preprint*, arXiv:2301.07069.
- Trần Xuân Trường, Navid Rajabi, Kevin Duh, và Philipp Koehn. 2023b. Dịch máy với các mô hình ngôn ngữ lớn: Gợi ý, học ít dữ liệu và fine-tuning với QLoRA. Trong *Proceedings of the Eighth Conference on Machine Translation*, trang 468–481, Singapore. Hiệp hội Ngôn ngữ Tính toán Kỹ Thuật Số.
- Jiawei Zheng, Hanghai Hong, Xiaoli Wang, Jingsong Su, Yonggui Liang, và Shikai Wu. 2024. Tinh chỉnh các mô hình ngôn ngữ lớn cho dịch máy chuyên ngành. *Preprint*, arXiv:2402.15061.
- Zaixiang Zheng, Xiang Yue, Shujian Huang, Jiajun Chen và Alexandra Birch. 2020. Hướng tới việc tận dụng tối đa ngữ cảnh trong dịch máy thần kinh. *Preprint*, arXiv:2002.07982.